

Факультет компьютерных наук | Машинное обучение | Москва 2026

Лекция 5
Кластерный анализ

Преподаватель: Меликян Алиса Валерьевна, amelikyan@hse.ru
кандидат наук, доцент Департамента программной инженерии ФКН НИУ ВШЭ

Кластерный анализ

Кластерный анализ – это метод машинного обучения и анализа данных, который сам находит группы (кластеры) похожих объектов на основании их характеристик. Объекты в одном кластере должны быть похожи по заданным характеристикам, а объекты из разных кластеров должны иметь существенные отличия.

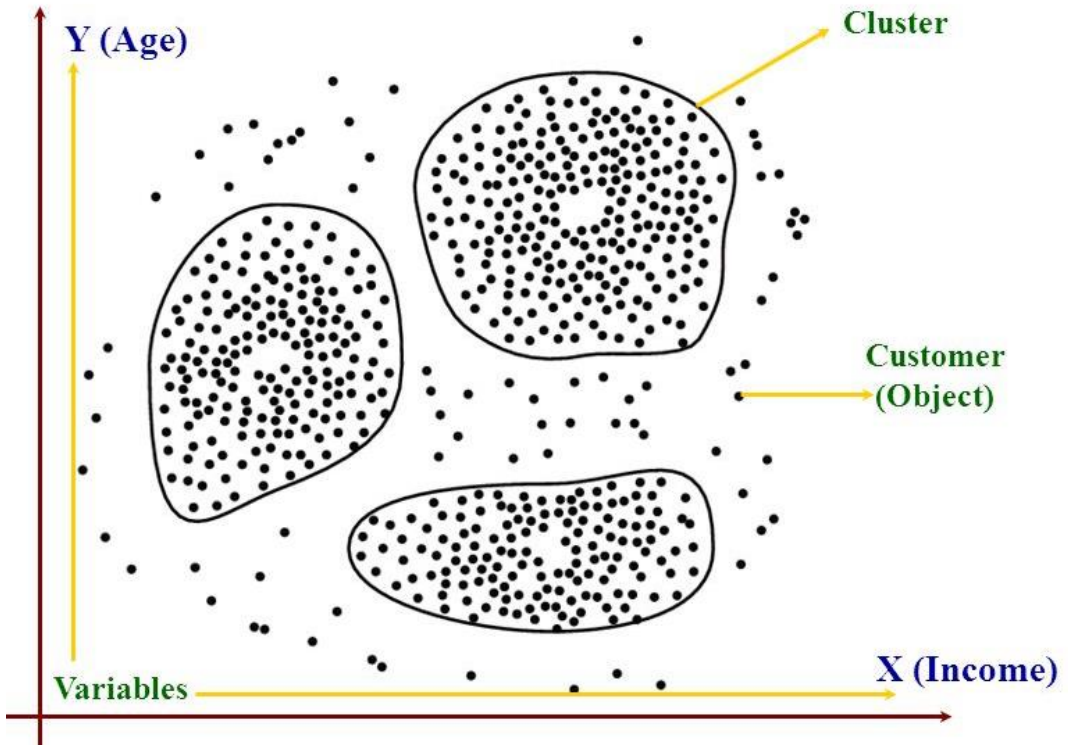
Внутри – похожие, снаружи – разные.

Это алгоритм обучения без учителя. Мы не знаем заранее сколько у нас будет кластеров, каковы их характеристики, как мы их назовем. Нет единственной метрики оценки качества кластеризации.

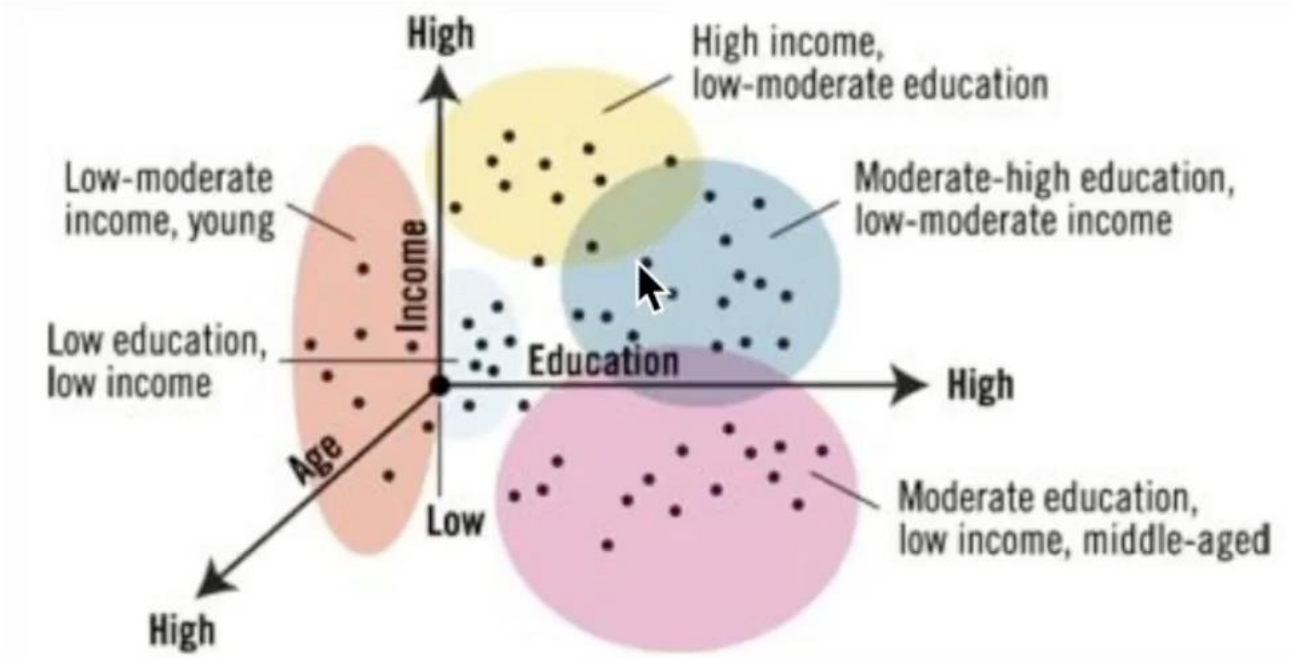
Кластерный анализ

Возможные цели:

- Выявить скрытую структуру в данных;
- Разделить объекты на однородные группы без заранее заданных меток;
- Упростить дальнейший анализ больших массивов данных.



Кластерный анализ

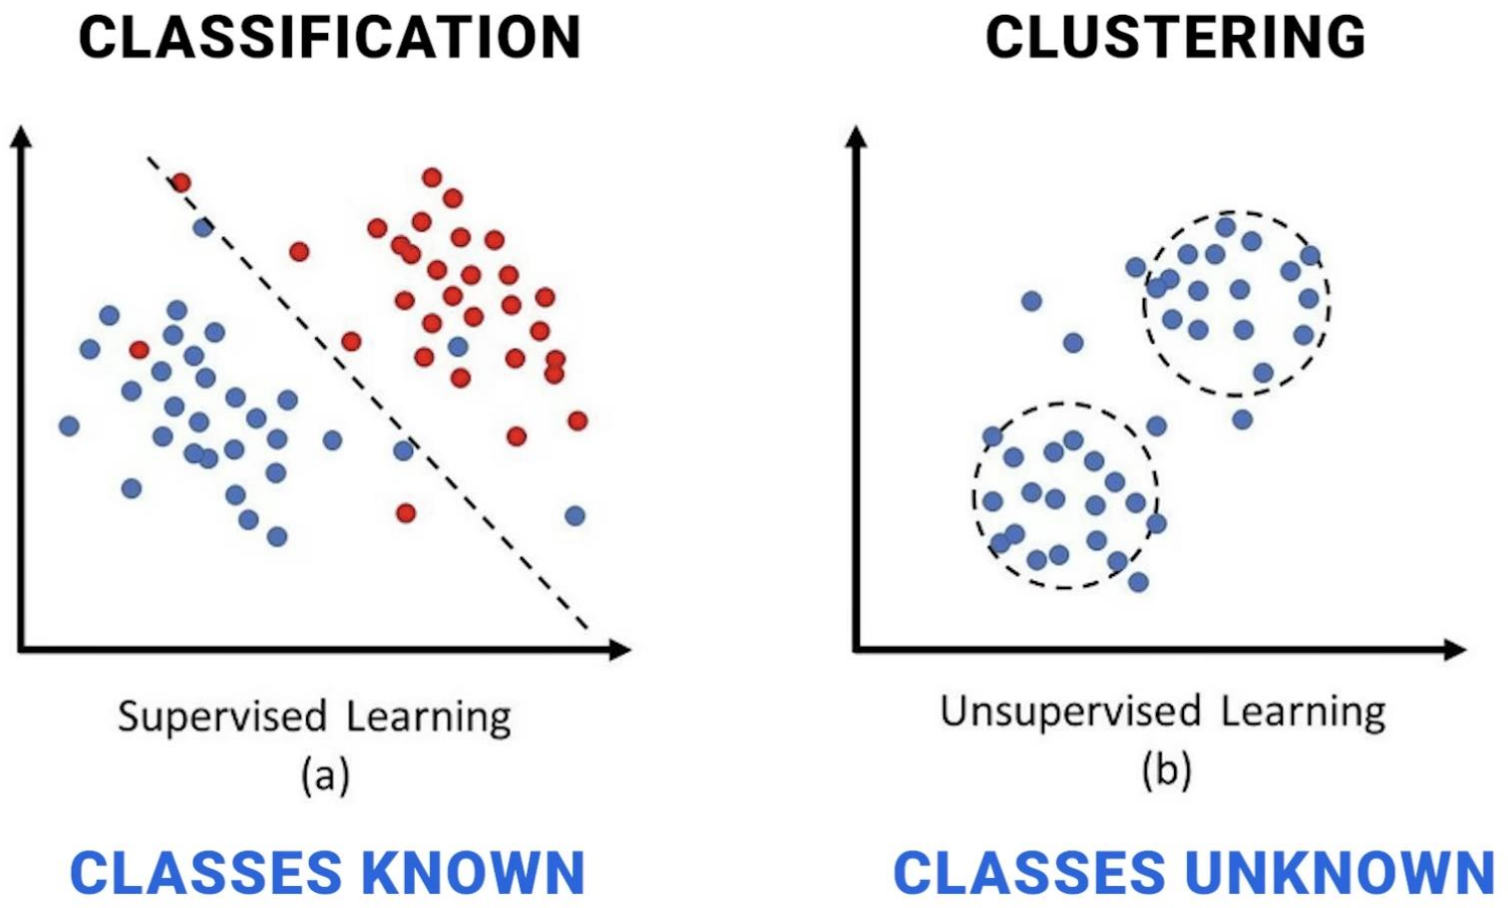


Кластерный анализ

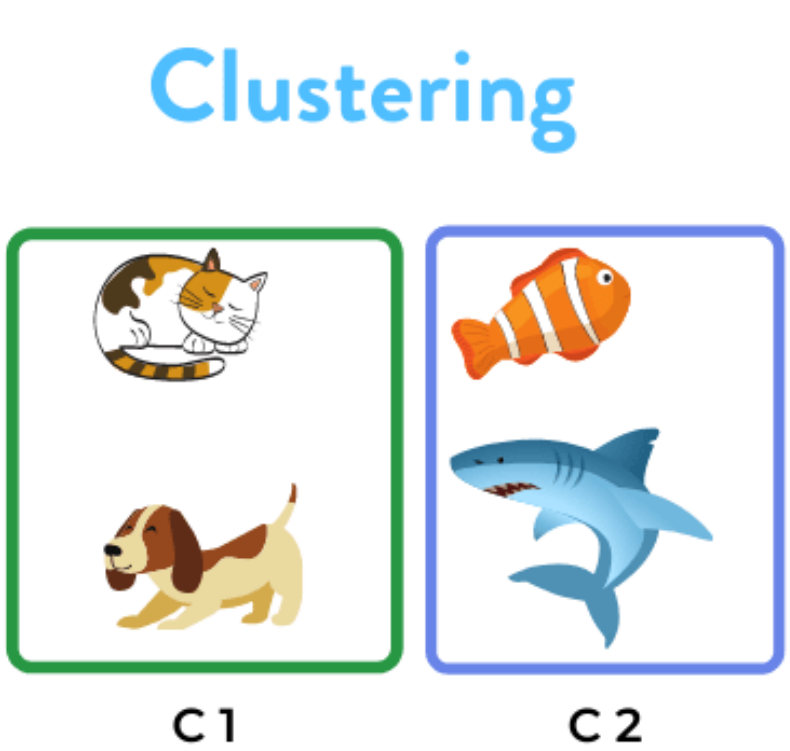
- ➕ Не требует размеченных данных;
- ➕ Много алгоритмов для разных ситуаций;
- ➕ Может работать с большими наборами данных.

- ➖ Сложно выбрать оптимальное число кластеров;
- ➖ Результаты могут отличаться в зависимости от выбранного алгоритма и его параметров;
- ➖ Нет универсального критерия качества кластерной модели;
- ➖ Некоторые алгоритмы чувствительны к шуму и выбросам;
- ➖ Результаты могут быть трудны для интерпретации.

Отличие кластеризации от классификации



Отличие кластеризации от классификации





Кластерный анализ в ПИ

Задача: выявление групп программных проектов с повышенным риском возникновения проблем.
Признаки: количество дефектов, частота исправлений, количество изменений требований, превышение сроков, перерасход ресурсов, технический долг, количество инцидентов после релиза.

Возможные кластеры:

«Высокий технический долг» – большое количество накопленных проблем в коде.

«Нестабильные» – высокая частота ошибок и исправлений.

«Перегруженные» – большое количество задач при ограниченных ресурсах.

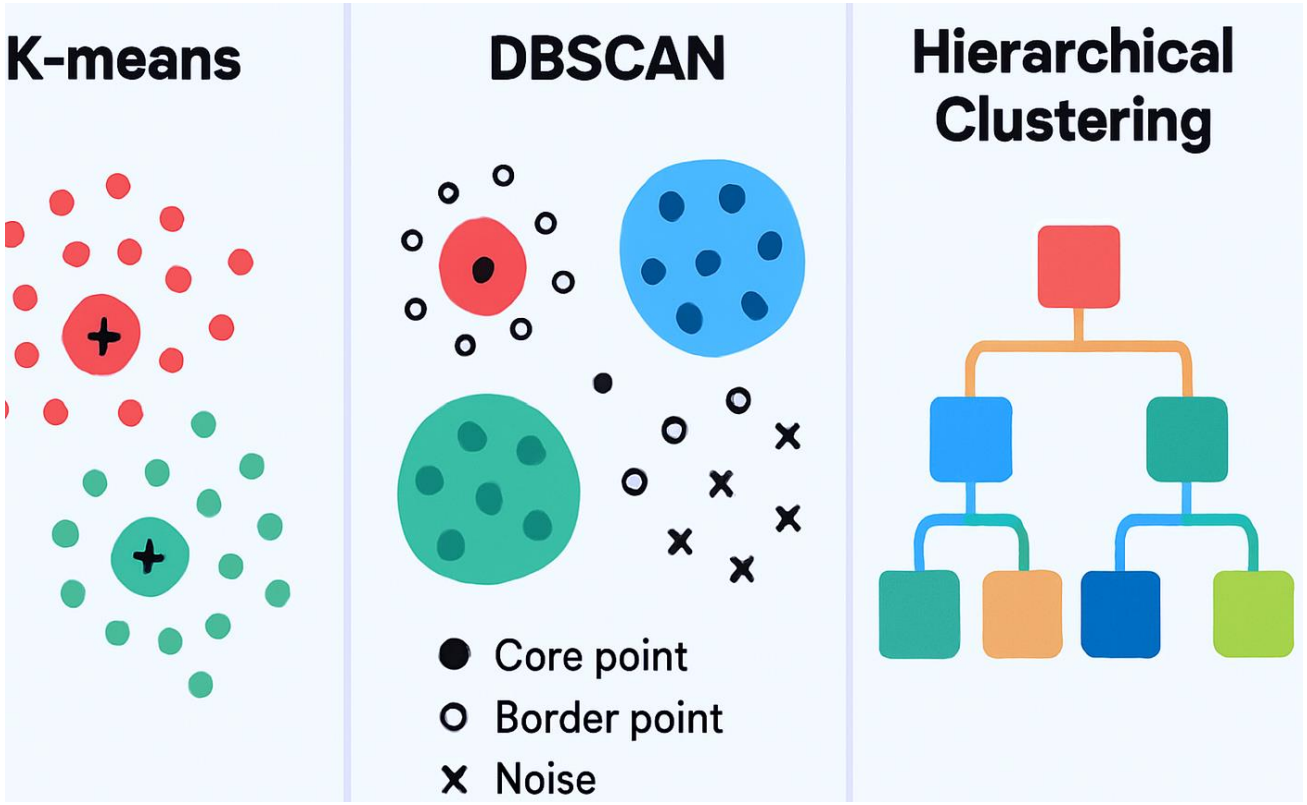
«Рискованные по срокам» – частое отставание от плановых сроков.

«Стабильные» – небольшое количество дефектов и предсказуемая динамика разработки.

Порядок проведения кластерного анализа

1. Определение цели кластеризации и, возможно, того, насколько детальную картину мы хотим получить.
2. Выбор объектов кластеризации.
3. Выбор признаков их подготовка (проверка мультиколлинеарности, перекодирование, стандартизация, снижение размерности).
4. Отпределение алгоритма кластеризации и метода измерения расстояния между кластерами.
5. Оценка качества (однородность внутри каждого кластера, различия между кластерами).
6. Определение числа кластеров.
7. Интерпретация кластеров.
8. Валидация результатов (проверка устойчивости результатов и значимости отличий).

Алгоритмы кластеризации



Иерархический кластерный анализ

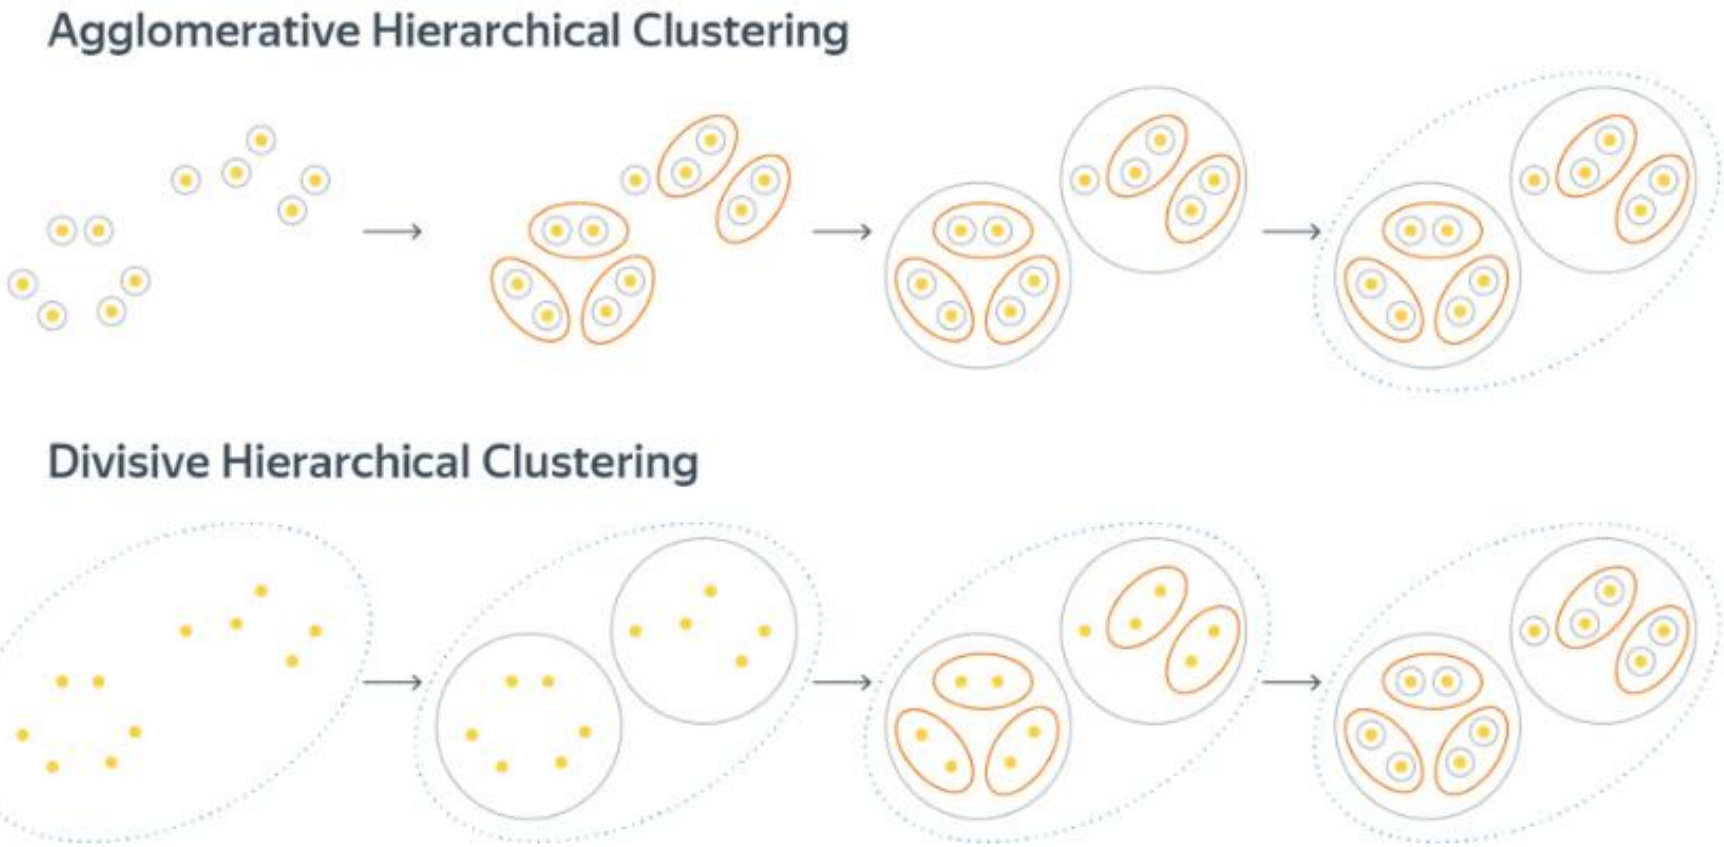
Иерархический кластерный анализ (агломеративный) последовательно объединяет объекты в группы, формируя древовидную структуру кластеров, которую можно визуализировать на **дендрограмме**.

Не требует заранее задавать число кластеров. Визуализация поэтапного процесса формирования кластеров обеспечивает наглядность результатов.

Алгоритм иерархической кластеризации

1. Каждый объект сначала рассматривается как отдельный кластер.
2. На каждом шаге объединяются два наиболее близких кластера на основе выбранной меры расстояния и правила объединения.
3. Процесс продолжается пока все объекты не окажутся в одном большом кластере.
4. Необходимо принять решение в какой момент прекратить объединение кластеров, чтобы они были достаточно однородными и содержательно интерпретируемыми.

Иерархический кластерный анализ (агломеративный или дивизионный)



Определение оптимального числа кластеров

Оптимальным считается такое число кластеров, при котором достигается баланс между размером кластеров и их однородностью:

- с одной стороны, каждый кластер включает максимально возможное количество объектов исследования,
- с другой стороны, объекты внутри кластера характеризуются минимальной вариативностью.

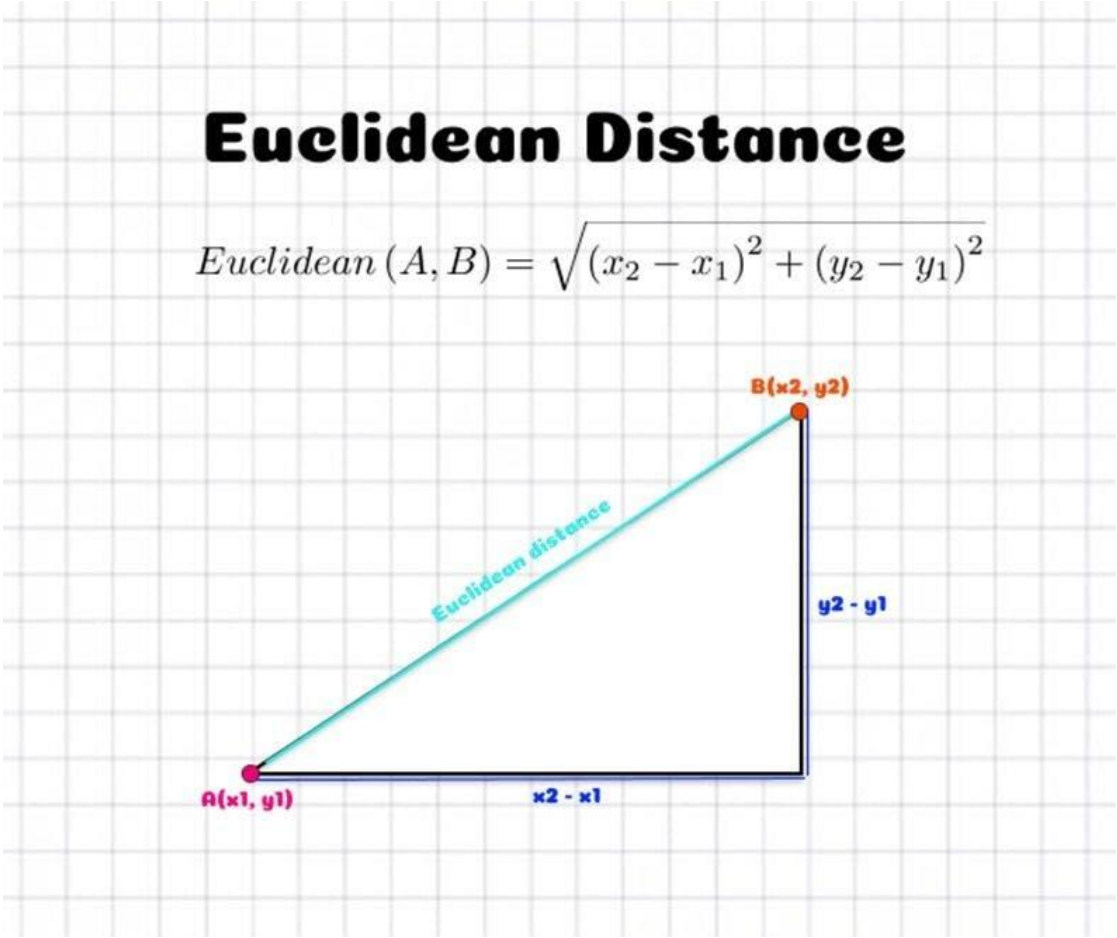
При этом различия между кластерами должны быть довольно четко выраженными для интерпретируемости.

Евклидово расстояние между объектами

Евклидово расстояние чаще всего используется для измерения расстояния при проведении кластеризации на основе числовых признаков. Иногда используется квадрат Евклидова расстояния для усиления эффекта больших расстояний. Рекомендуется предварительно стандартизировать шкалы переменных кластеризации, если они различаются. Метрика чувствительна к выбросам.

$$D_{ij} = \sqrt{\sum_{k=1}^{n} \left(x_{ki} - x_{kj} \right)^2}$$

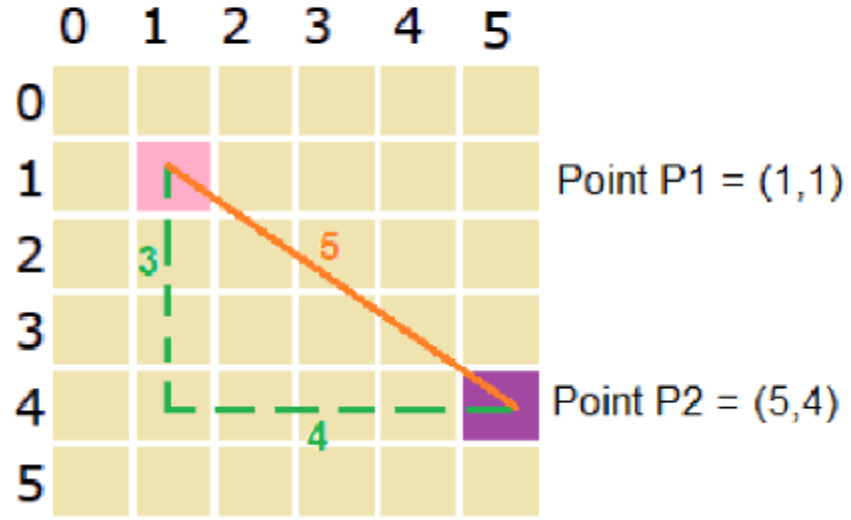
Евклидово расстояние



Манхэттенское расстояние между объектами

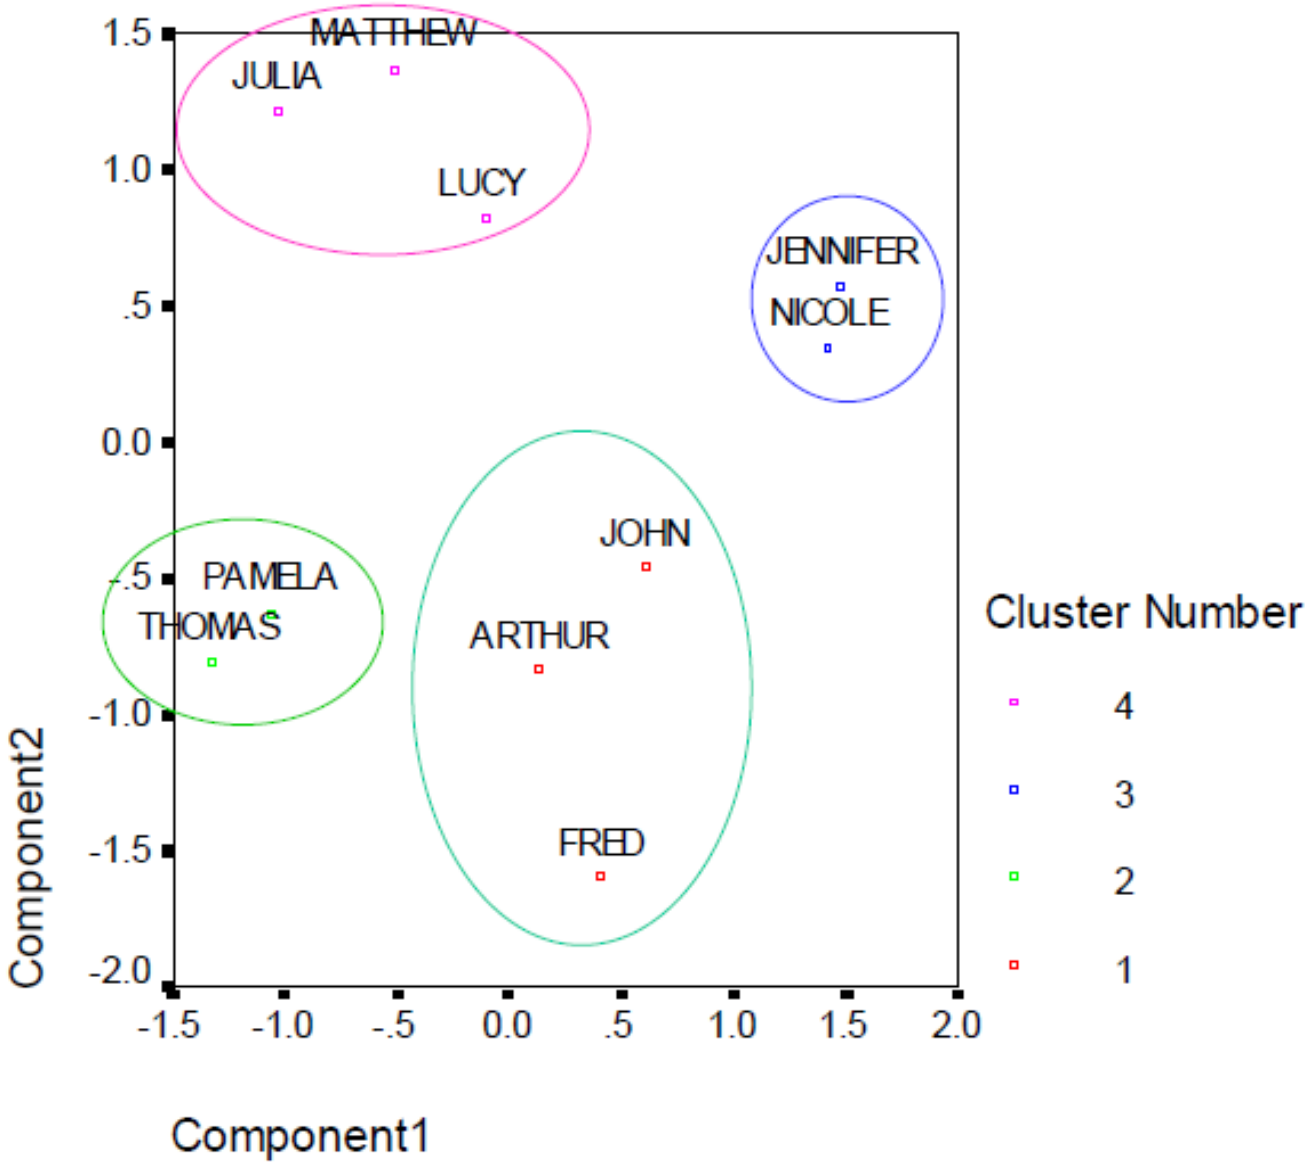
Расстояние городских кварталов (Манхэттенское расстояние) - расстояние между двумя точками равно сумме модулей разностей их координат. Менее чувствительно к выбросам, чем евклидово расстояние.

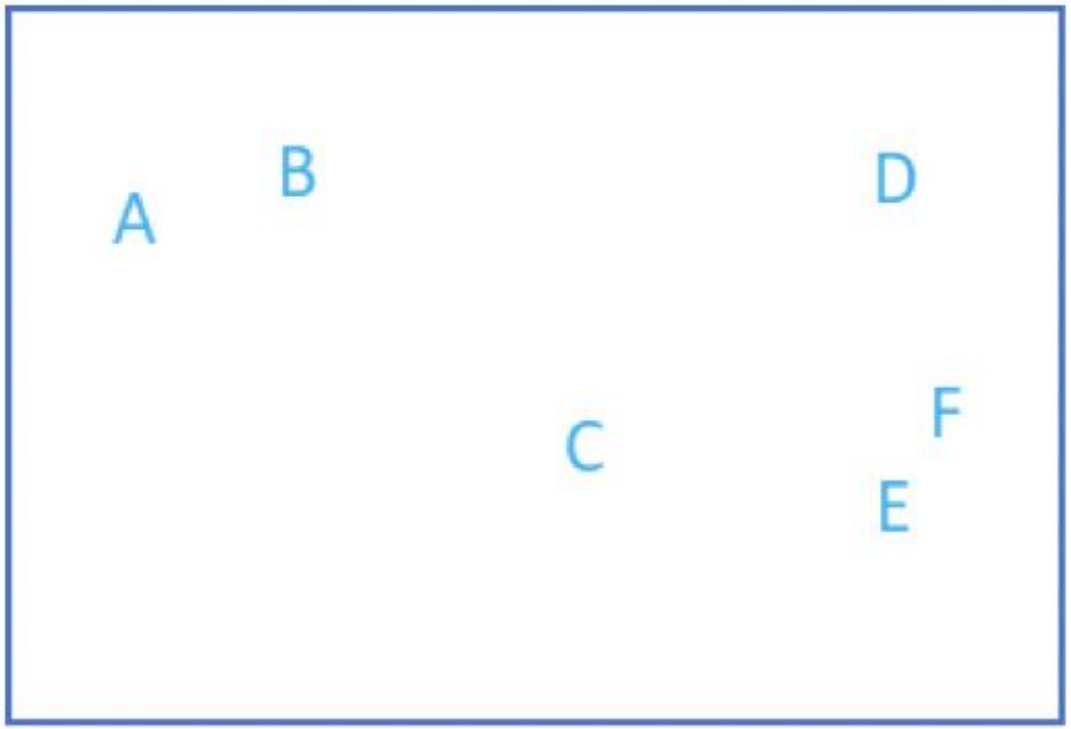
$$\rho(a,b) = |x_1 - x_2| + |y_1 - y_2|$$



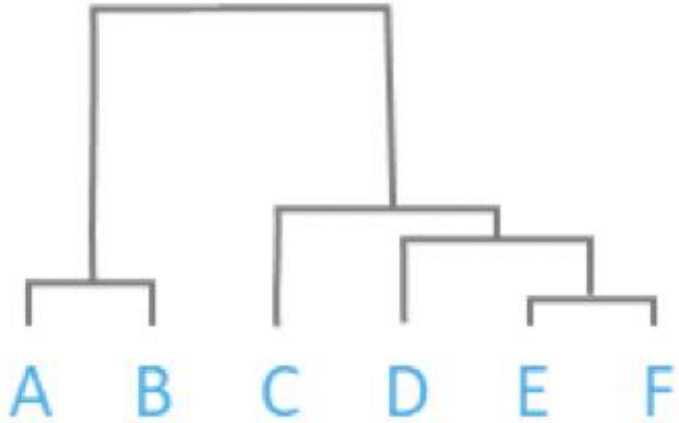
Euclidean distance = $\sqrt{(5-1)^2 + (4-1)^2} = 5$

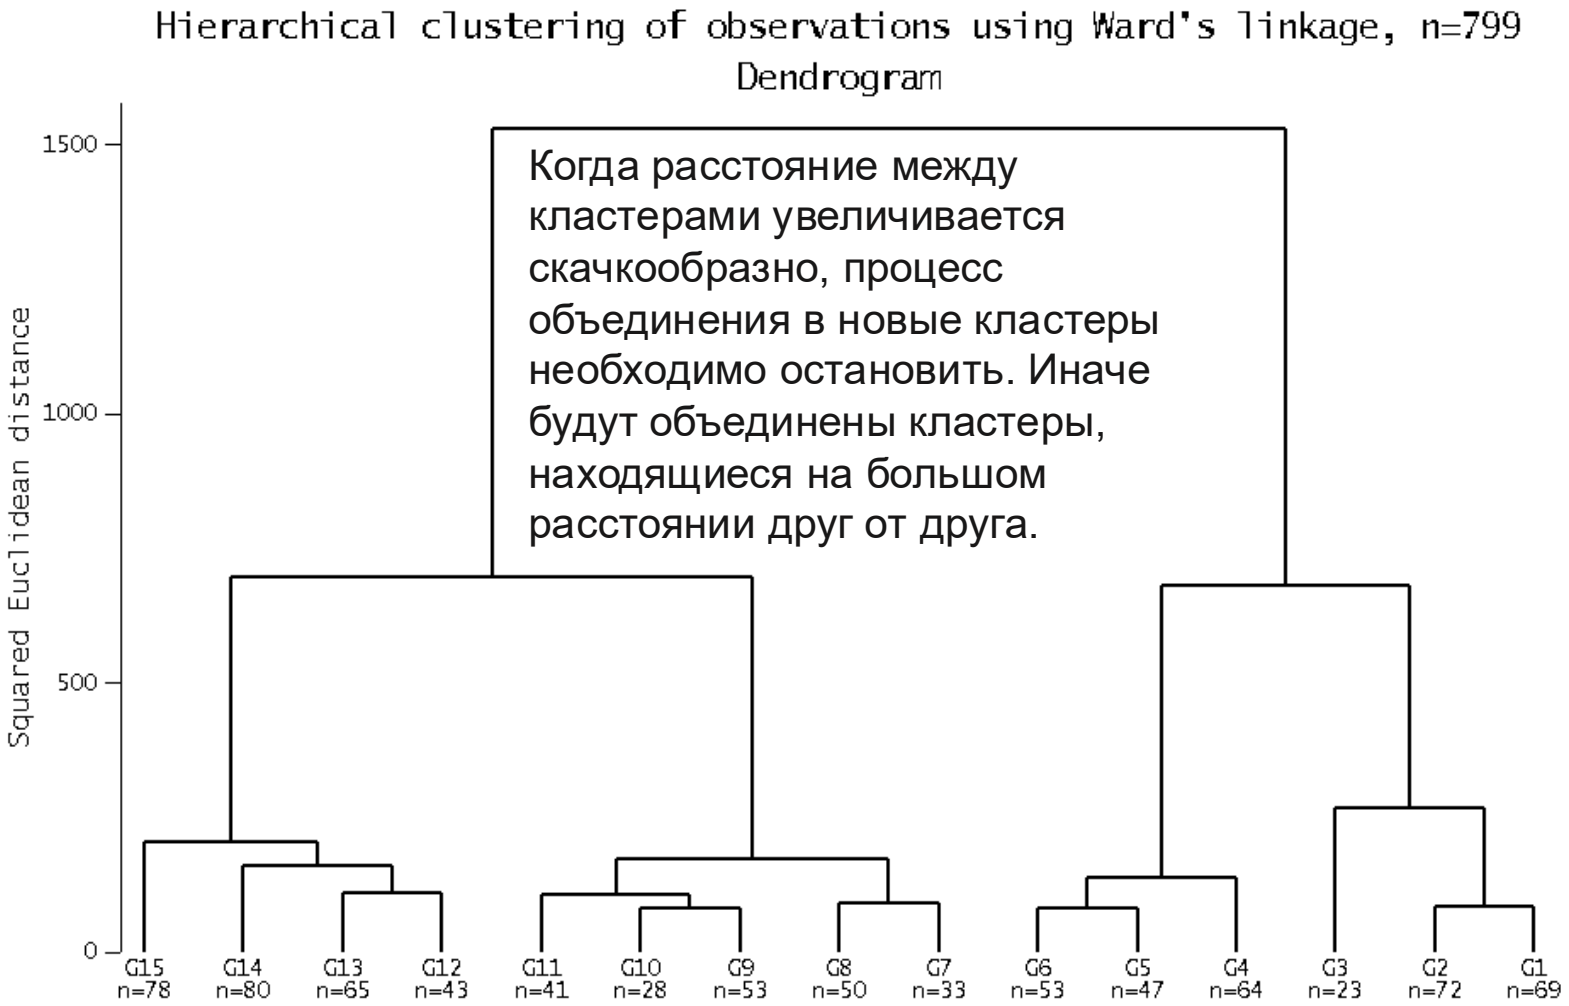
Manhattan distance = $|5-1| + |4-1| = 7$


MATTHEW
JULIA
LUCY
JENNIFER
NICOLE
JOHN
PAMELA
THOMAS
ARTHUR
FRED
1.5
1.0
.5
0.0
-.5
-1.0
-1.5
-2.0
-1.5
-1.0
-.5
0.0
.5
1.0
1.5
2.0
Component2
Component1
Cluster Number
4
3
2
1

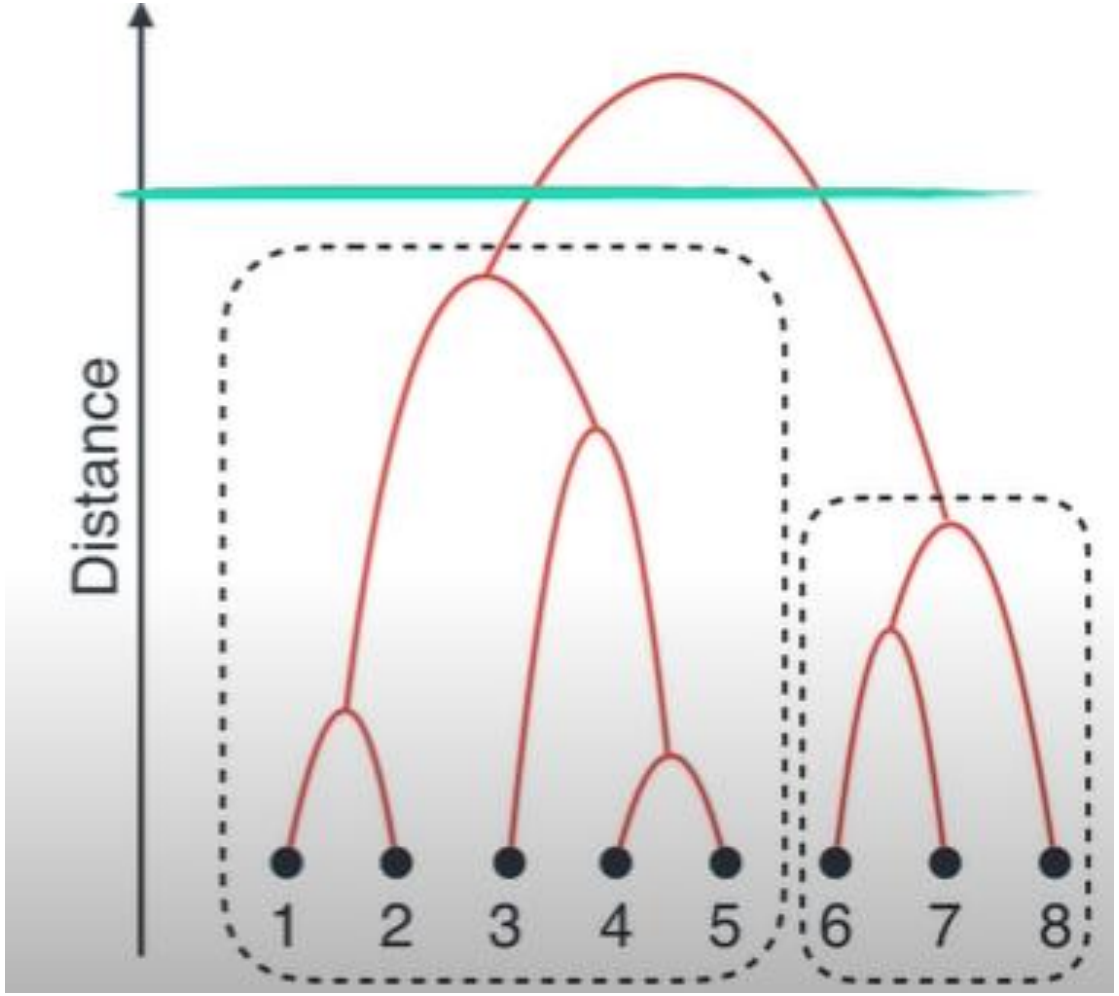


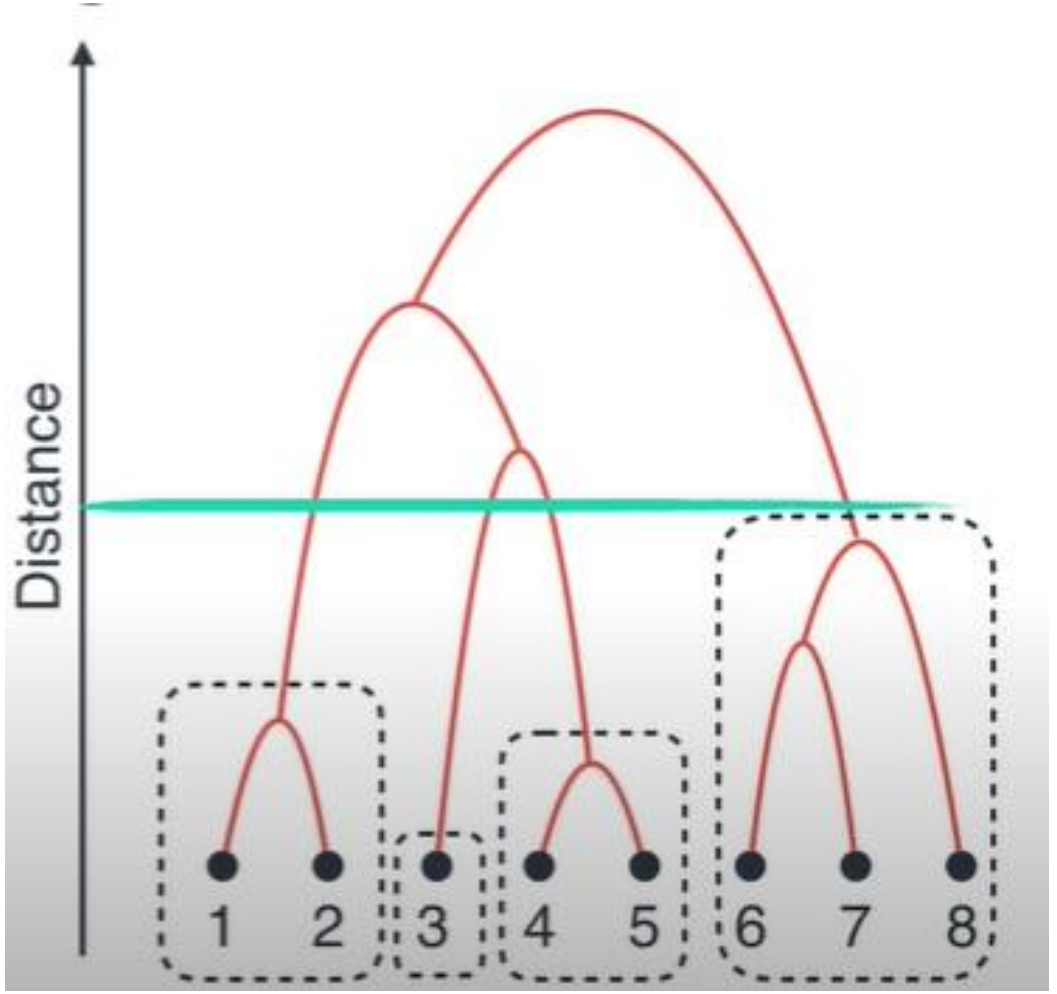
Dendrogram





Когда расстояние между кластерами увеличивается скачкообразно, процесс объединения в новые кластеры необходимо остановить. Иначе будут объединены кластеры, находящиеся на большом расстоянии друг от друга.


Distance
1
2
3
4
5
6
7
8


Distance
1
2
3
4
5
6
7
8

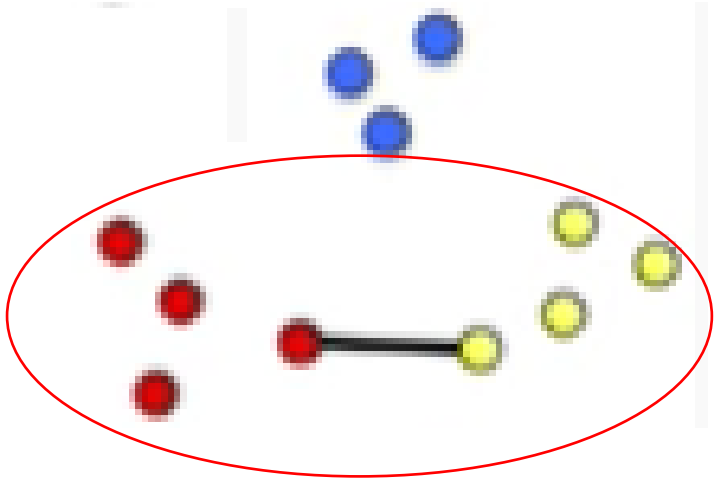
Правила объединения кластеров

Правила объединения кластеров (Linkage Rules) – это критерии, по которым в определяется, какие два кластера следует объединить на каждом шаге.

- Ближайший сосед (Nearest Neighbor)
- Дальний сосед (Furthest Neighbor)
- Межгрупповые связи (Between-Groups Linkage)
- Центроидная кластеризация (Centroid Clustering)
- Метод Варда/Уорда (Ward’s Method)

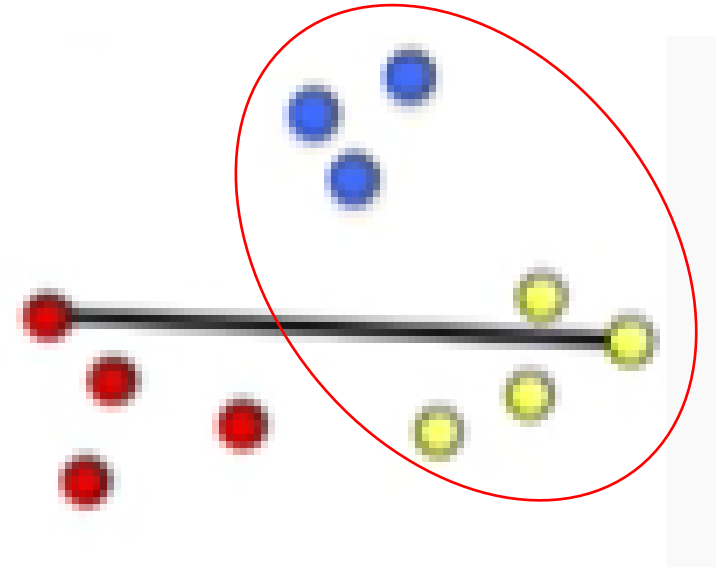
Близлежащий сосед (Nearest Neighbor / Single-Linkage)

Расстояние между двумя кластерами определяется расстоянием между двумя наиболее близкими объектами (ближайшими соседями) в разных кластерах. Может привести к цепочкам последовательностей, когда кластеры объединяются через одиночные близкие точки.



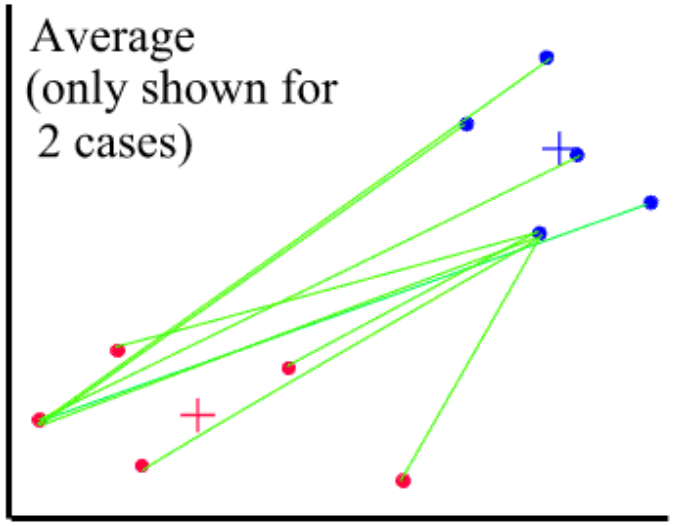
Дальний сосед (Furthest Neighbor / Complete-Linkage)

Расстояние между кластерами определяется максимальным расстоянием между любыми двумя объектами в различных кластерах (т.е. наиболее удаленными соседями). Старается минимизировать диаметр нового кластера. Больше шансов получить кластер, похожий на сферу. Чувствителен к выбросам.



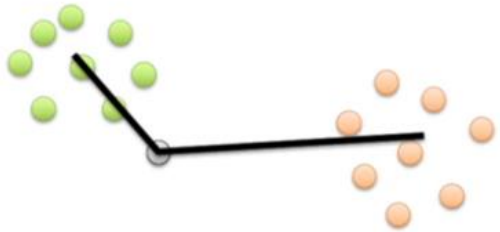
Межгрупповые связи (Average Linkage / Between Groups Linkage)

Дистанция между кластерами равна среднему значению дистанций между всеми возможными парами наблюдений, причём одно наблюдение берётся из одного кластера, а другое из другого. Информация, необходимая для расчёта дистанции, находится на основании всех теоретически возможных пар наблюдений. Снижается влияние выбросов на результат.



Центроидная кластеризация (Centroid Clustering)

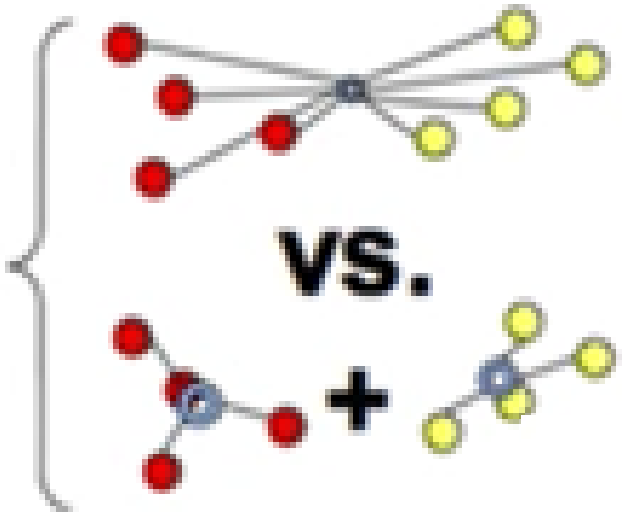
Наблюдение будет отнесено к тому кластеру, центр которого ближе всего к нему расположен.



Расстояние между двумя кластерами определяется как расстояние между их центрами.

Метод Варда/Уорда (Ward’s Method)

Основан на принципе минимального увеличения внутрикластерной вариации. Объединяются те два кластера, слияние которых приводит к наименьшему росту суммы квадратов отклонений объектов от центров кластеров (Within-Cluster Sum of Squares). Алгоритм стремится сохранить кластеры максимально однородными. При этом формирует кластеры примерно одинакового размера.



Иерархический кластерный анализ: преимущества и ограничения

- ➕ Не требует заранее задавать число кластеров;
- ➕ Работает с признаками разного типа;
- ➕ Наглядно визуализирует процесс формирования кластеров на дендрограмме;
- ➕ Можно использовать разные меры расстояния и правила объединения;
- ➕ При идентичных параметрах всегда выдает один и тот же результат.

- ⛔ Рассчитан на небольшие выборки (до 500 объектов);
- ⛔ Чувствителен к выбросам.

Кластерный анализ по методу k-means

Распространённый итеративный алгоритм для разбиения множества объектов на заранее заданное число кластеров **k**. Стремится минимизировать суммарное квадратичное отклонение точек кластеров от центров этих кластеров.

Каждый кластер в результате описывается центроидом – вектором средних значений признаков объектов, входящих в него.

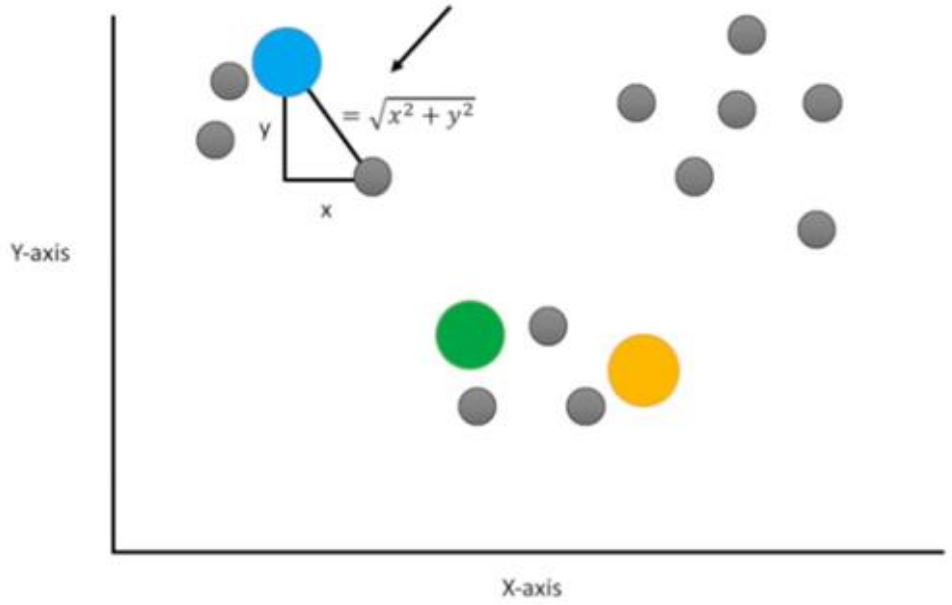
k-means: шаг 1

Нужно **задать значение гиперпараметра k,** определяющего число кластеров. Выбор значения может базироваться на теоретических основах исследования, ранее проведенных исследованиях, результатах иерархической кластеризации на случайно отобранной подвыборке наблюдений, методе «локтя», значениях коэффициента силуэта.

Если не возможно определить одно значение, то можно построить модели для диапазона значений k. После сравнения полученных моделей окончательно определиться с финальным числом кластеров.

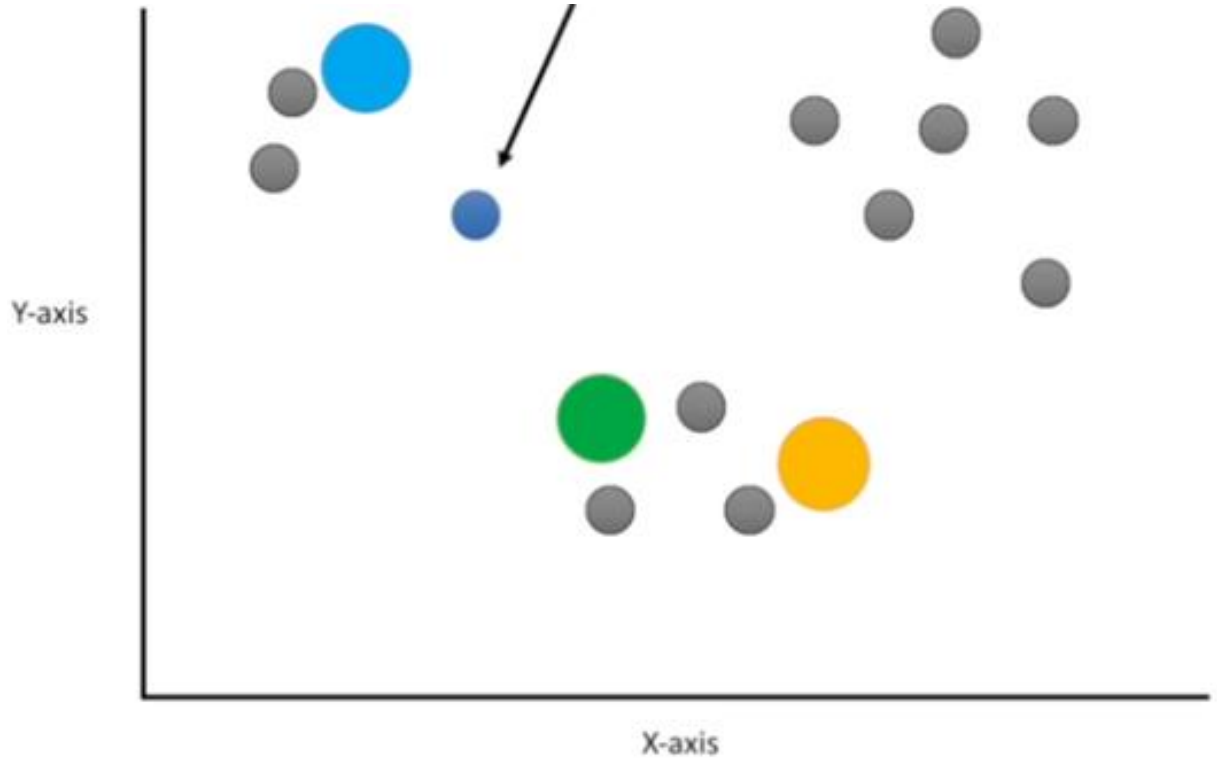
k-means: шаг 2

Инициализировать центры кластеров. Чаще всего это случайные точки в соответствии с числом кластеров, заданных на предыдущем этапе. Но можно задать конкретные центры (на основе мнений экспертов или ранее проведенных исследований) или использовать алгоритм k-means++, который обеспечивает улучшенную инициализацию центров, ускоряя сходимость. Важно: инициализация может влиять на итоговый результат.



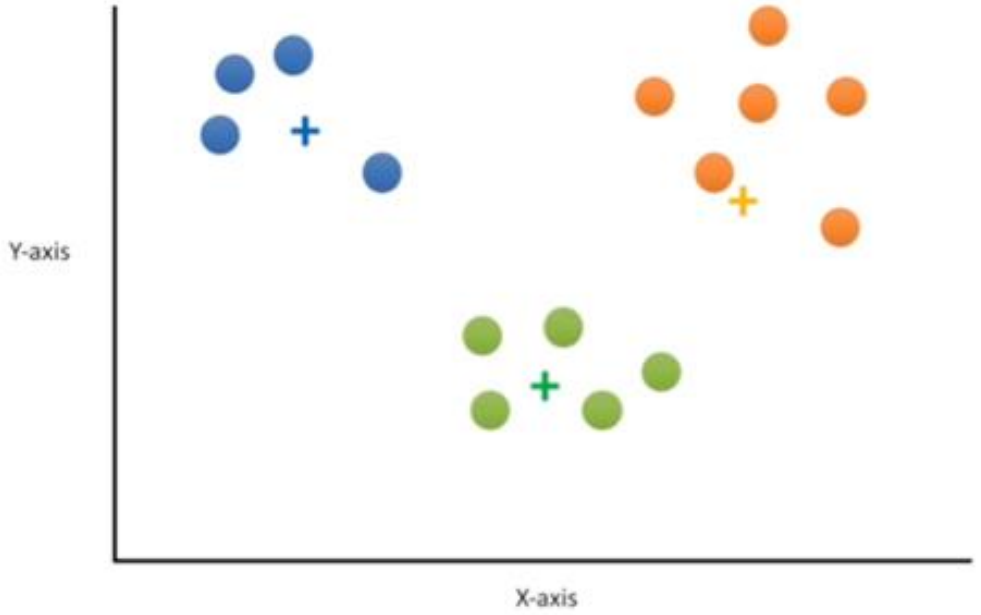
k-means: шаг 3

Присоединить наблюдения к ближайшим кластерам.



k-means: шаг 4

Для каждого кластера **вычисляется новый центр** как среднее значение всех объектов, входящих в данный кластер. Дальше процесс кластеризации повторяется пока возможны улучшение результатов.

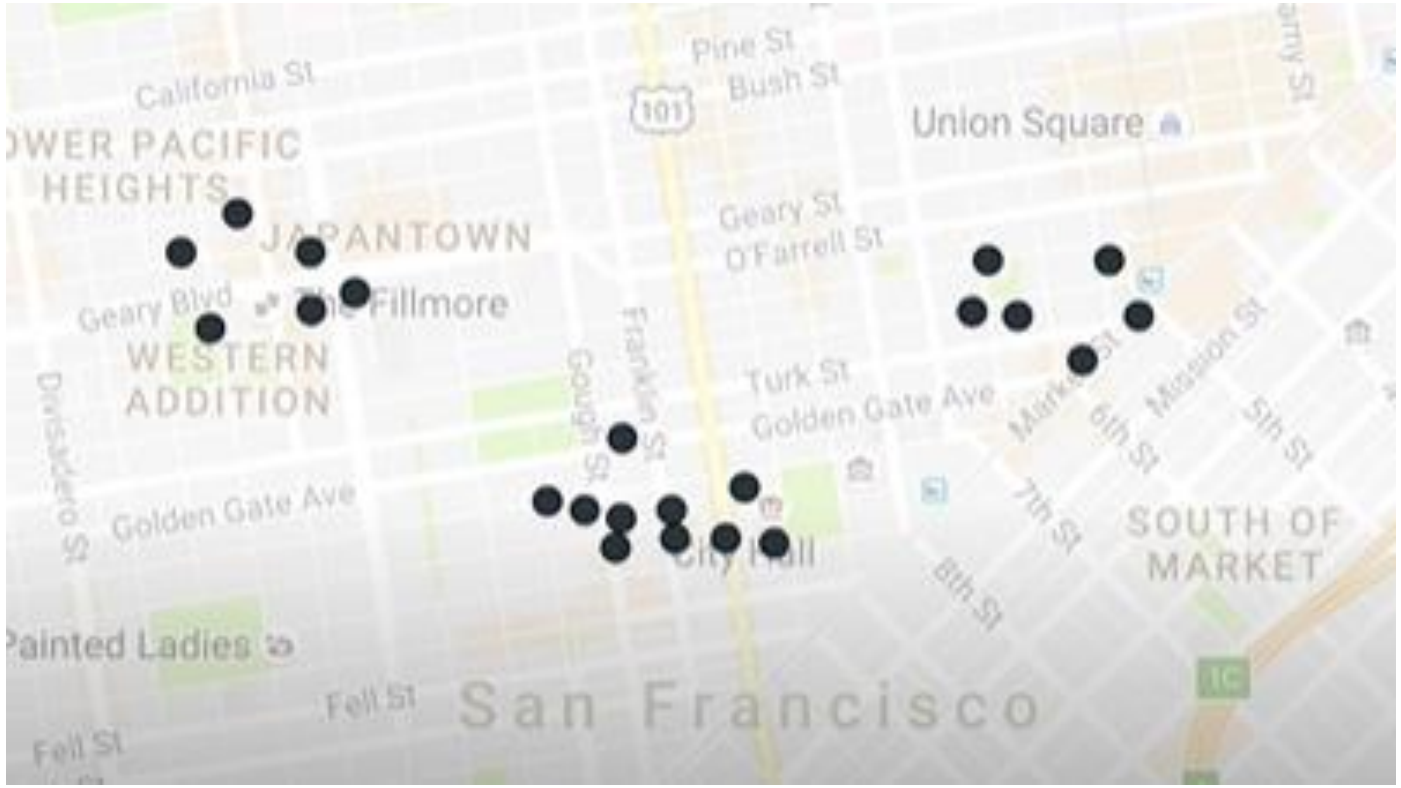


k-means: завершение

Шаги 3 и 4 повторяются пока центры кластеров перестают изменяться, или перераспределение объектов прекращается, или достигнуто максимальное число итераций.

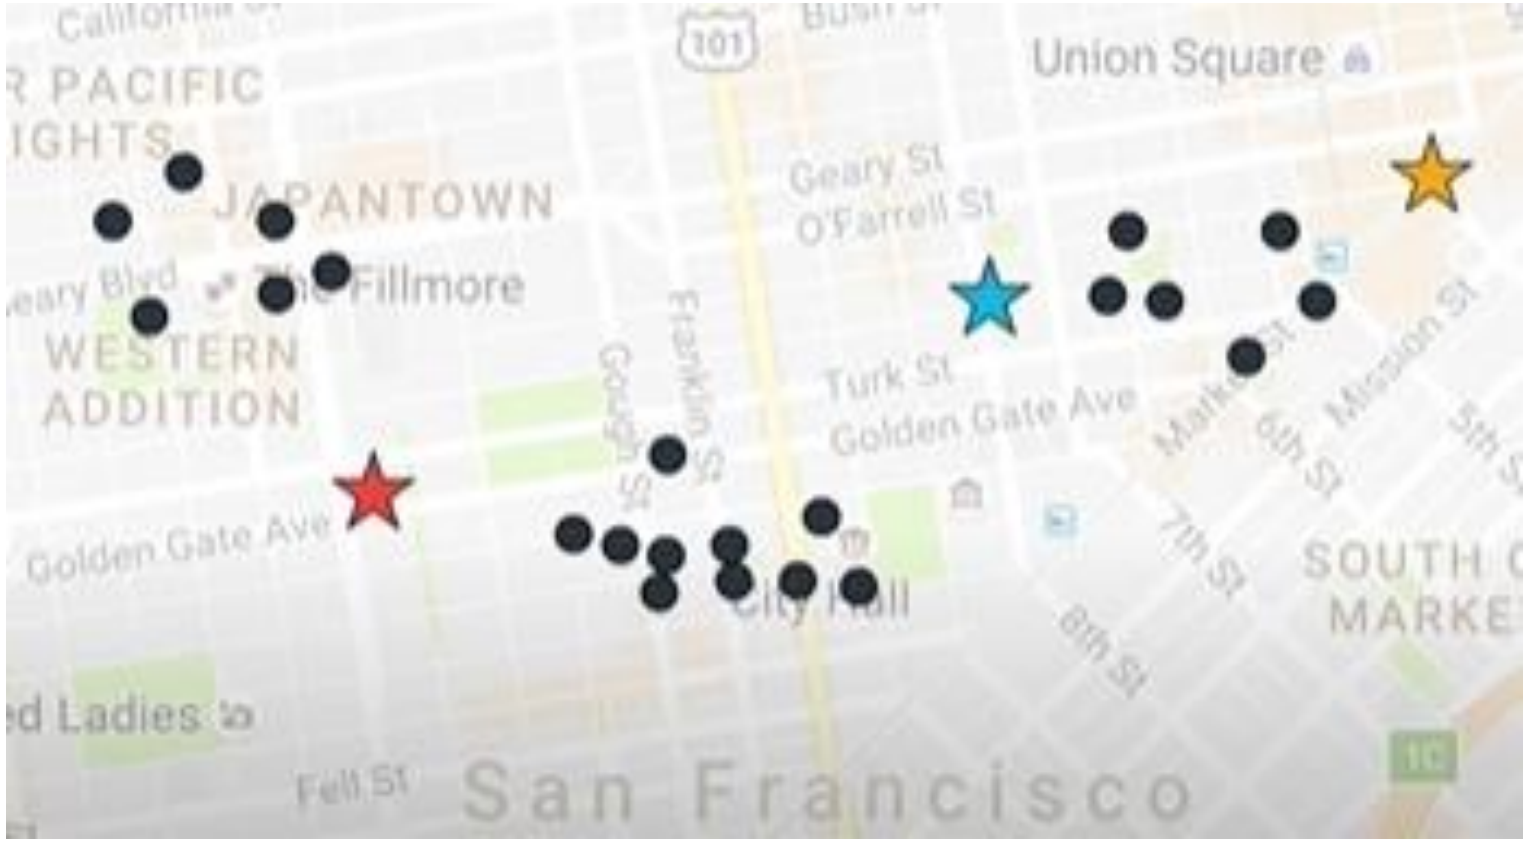
Пример: k-means

Ищем лучшее расположение для 3-х кафе. На карте отмечены дома, жители которых будут посещать эти кафе.



Пример: k-means

Помечаем 3 случайные точки (начальные центры).



Пример: k-means

Распределяем точки (дома) по принципу близости к центру.



Пример: k-means

Ставим центральные точки в центр домов, которые они обслуживают.



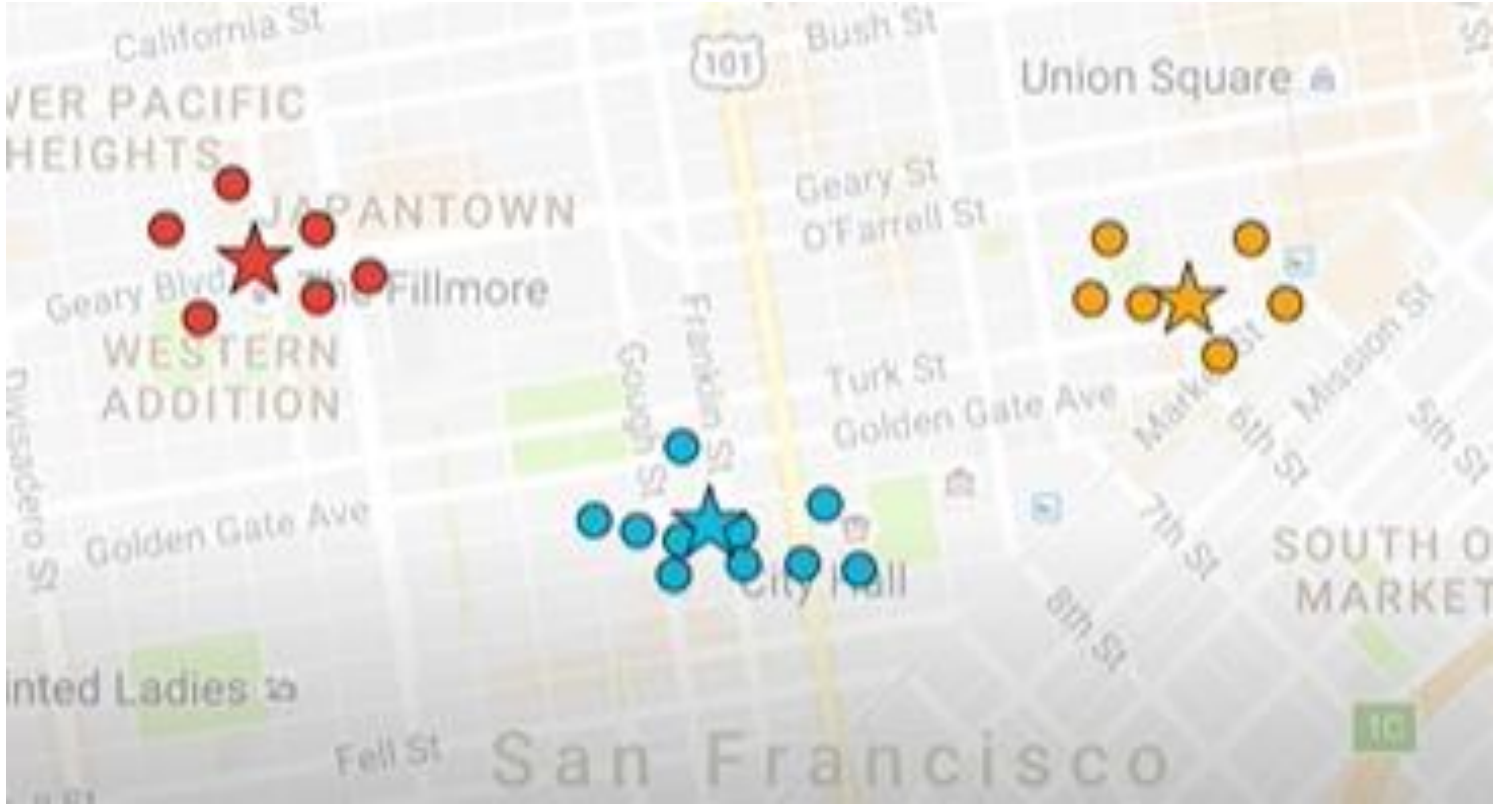
Пример: k-means

Снова пересчитываем центры, чтобы минимизировать расстояние между каждым зданием и кафе. Алгоритм повторяется пока возможны дальнейшие улучшения (сокращение расстояния между точками и центром).



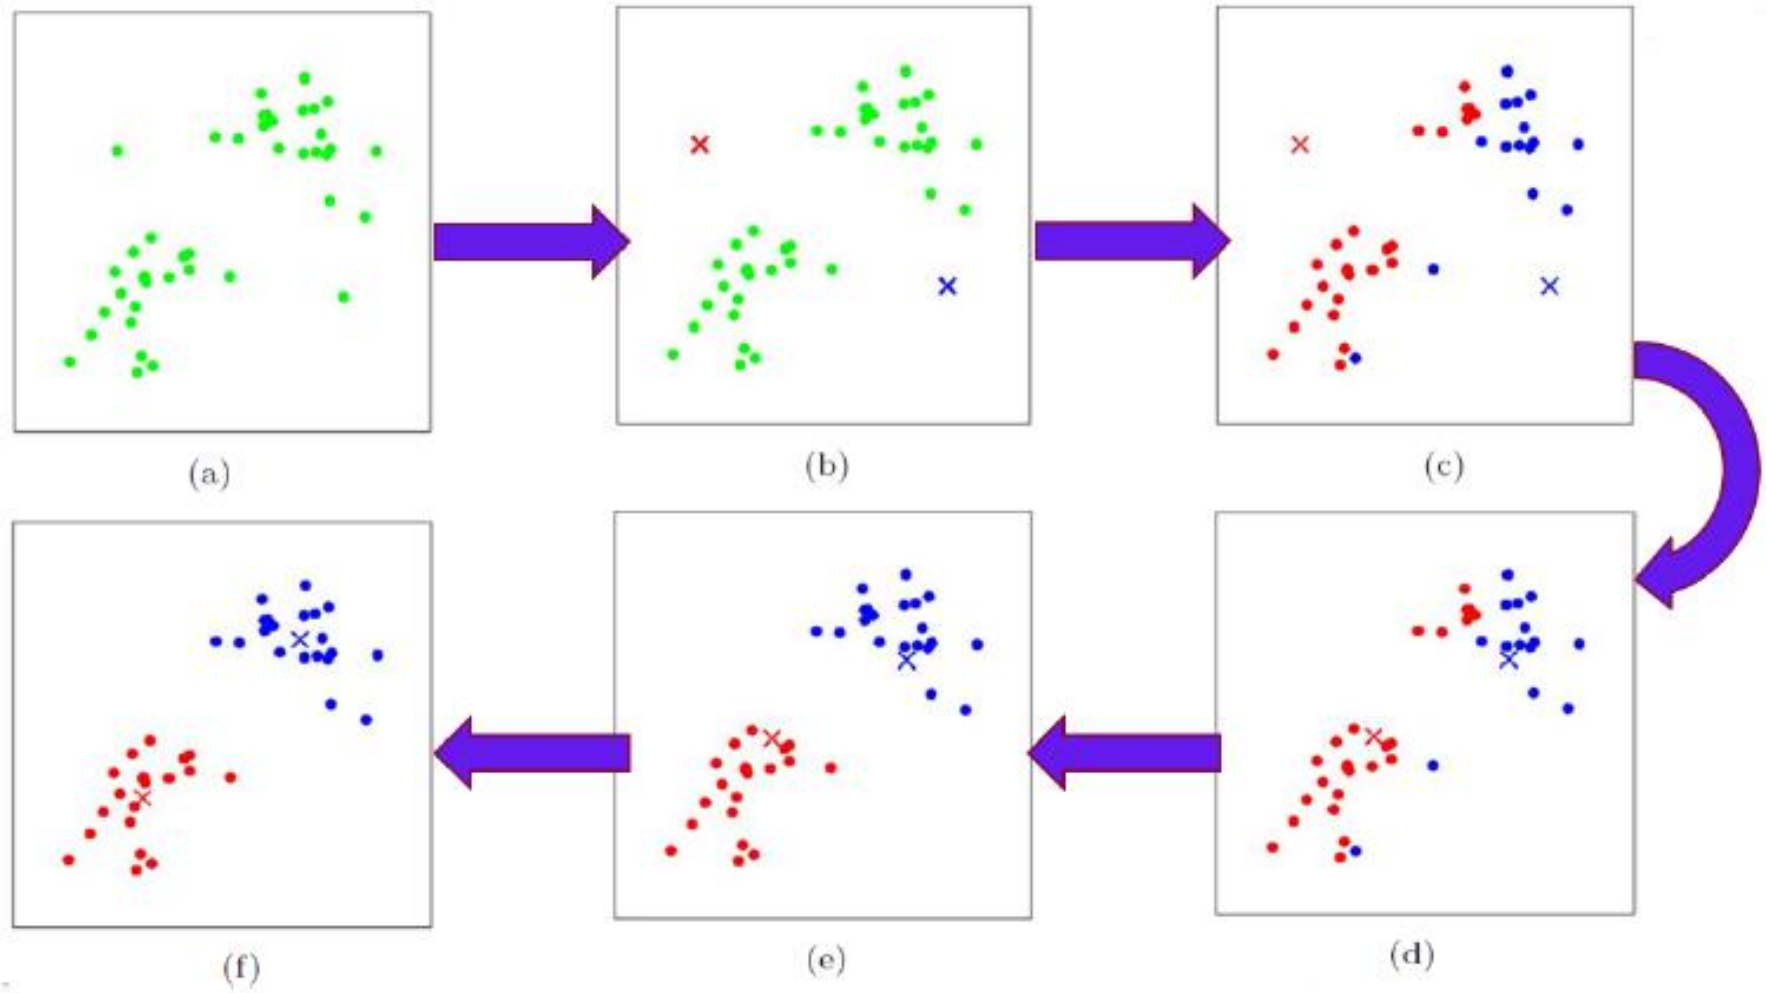
Пример: k-means

Финальный результат.

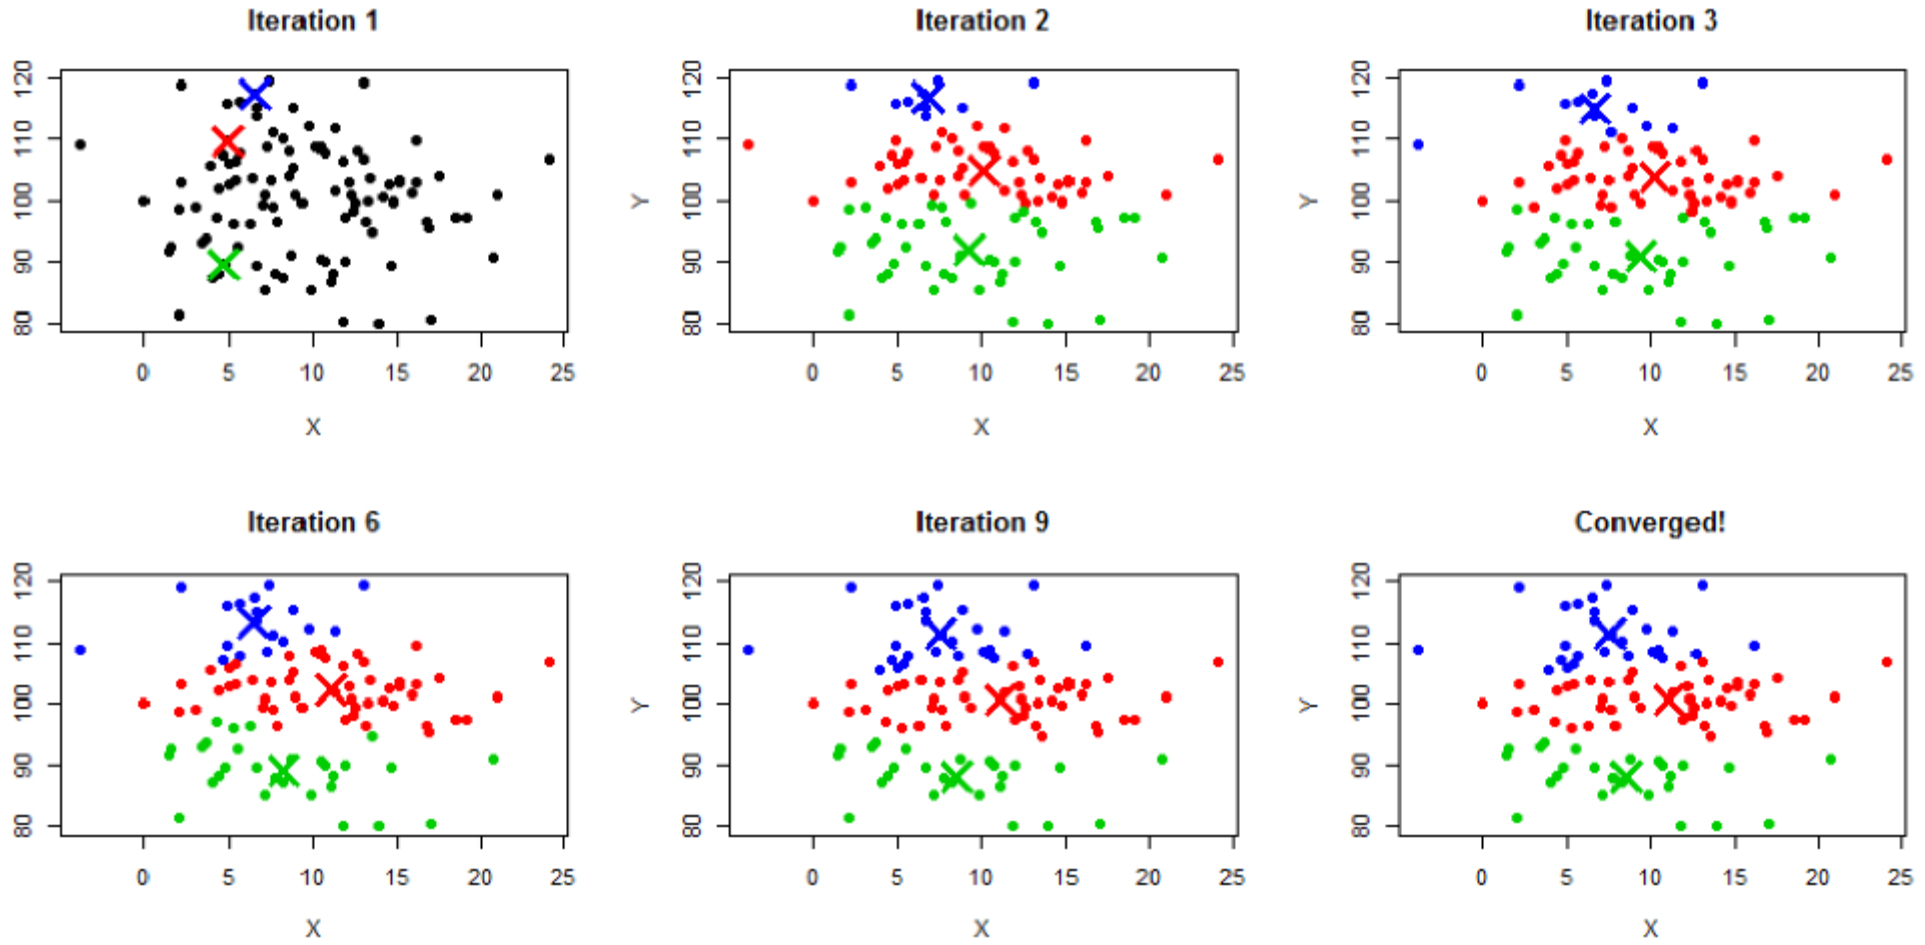


Источник: https://www.youtube.com/watch?v=QXOkPvFM6NU

k-means (2 кластера)



k-means (3 кластера)



k-means: преимущества и ограничения

- ➕ Простота реализации и интерпретации;
- ➕ Высокая скорость работы;
- ➕ Подходит для больших выборок.

- ⛔ Требует заранее задавать число кластеров;
- ⛔ Чувствителен к выбросам;
- ⛔ Работает только с числовыми признаками;
- ⛔ Результат может зависеть от начальной инициализации.

k-medians

k-medians идентичен k-means, но отличается тем, что в качестве центра кластера использует медиану, а не среднее арифметическое. Благодаря этому он более устойчив к выбросам. Для вычисления медианы достаточно знать порядок значений. Это делает алгоритм подходящим для работы с порядковыми данными. Для измерения расстояния между кластерами используется Манхэттенское расстояние.

k-modes

k-modes разработан для категориальных (номинальных) данных, где нельзя использовать среднее значение или медиану, как меру центральной тенденции. В качестве центра кластера используется мода – наиболее часто встречающаяся категория в каждом признаке.

Для вычисления расстояния между объектами применяется мера несходства (Matching Dissimilarity), которая представляет собой количество несовпадающих категорий по всем признакам кластеризации.

Не требует числового кодирования категорий, но требует заранее задать число кластеров k.

k-prototypes

k-prototypes – алгоритм кластеризации, предназначенный для наборов данных, содержащих как числовые, так и категориальные признаки. Объединяет идеи двух алгоритмов: k-means (использует средние значения и евклидово расстояние для числовых данных) и k-modes (использует моду и подсчёт несовпадений для категориальных признаков).

Расстояние вычисляется как взвешенная комбинация:

- числовой дистанции (обычно евклидовой);
- категориальной меры несходства (количество несовпадающих категорий).

Подходит для реальных прикладных задач, где данные нередко бывают смешанными.

k-семейство алгоритмов кластеризации

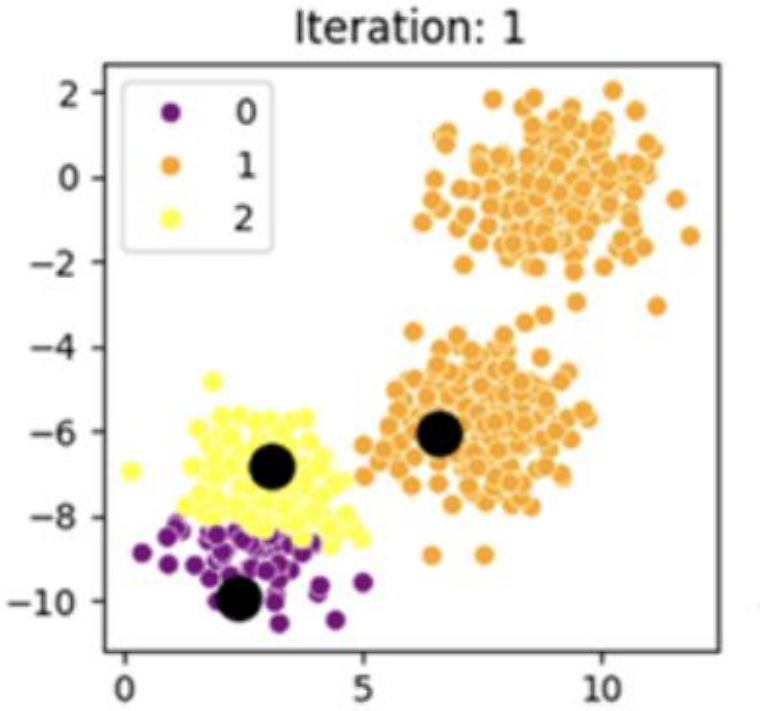
Алгоритм	Тип данных	Центр кластера	Метрика расстояния (по умолчанию)	Устойчивость к выбросам	Пример использования
k-means	Числовые	Среднее значение	Евклидово расстояние (L2)	Нет	Доход, возраст
k-medians	Числовые / порядковые	Медиана	Манхэттенское расстояние (L1)	Да	Удовлетворённость, уровень образования
k-modes	Категориальные	Мода	Подсчёт несовпадений	-	Должность, пол
k-prototypes	Смешанные (числ. + кат.)	Среднее + мода	Комбинация L2 + несовпадений	Частично	Возраст + должность + отдел + з/п

k-means++

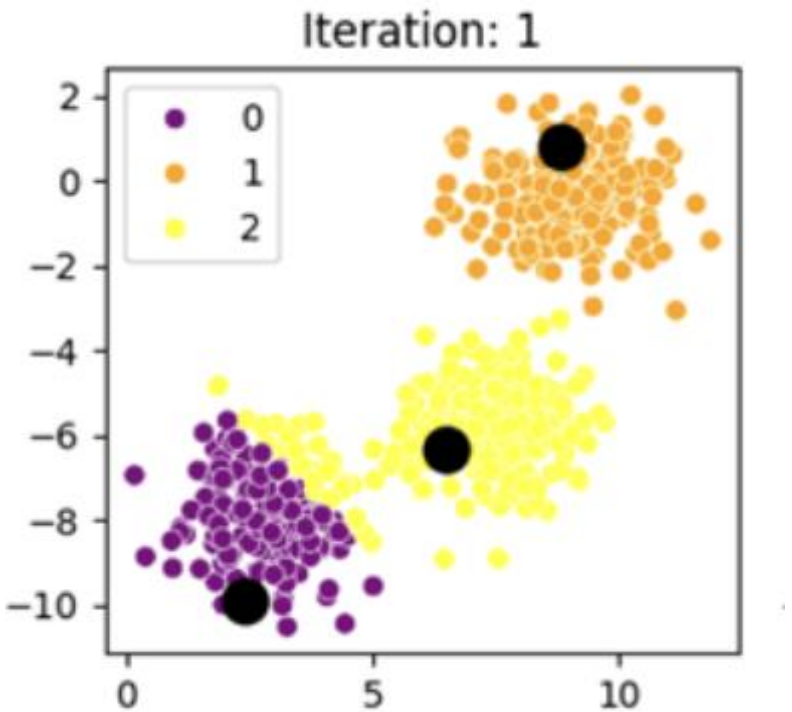
В k-means начальные центры кластеров выбираются случайным образом. Это делает его чувствительным к инициализации: при неудачном выборе начальных центров он может сойтись к неоптимальному локальному минимуму, сформировать несбалансированные кластеры, а результаты кластеризации могут отличаться при разных запусках.

Алгоритм k-means++ решает эту проблему за счёт более продуманной инициализации. Он выбирает начальные центроиды так, чтобы они были максимально удалены друг от друга. Первый центр выбирается случайно, а второй тоже случайно, но с вероятностью, пропорциональной квадрату расстояния точки до уже выбранного первого центра (то есть чем дальше точка, тем выше шанс быть выбранной). Благодаря этому уменьшается зависимость результата от случайности, сокращается число итераций и ускоряется сходимость алгоритма.

k-means vs k-means++



k-means



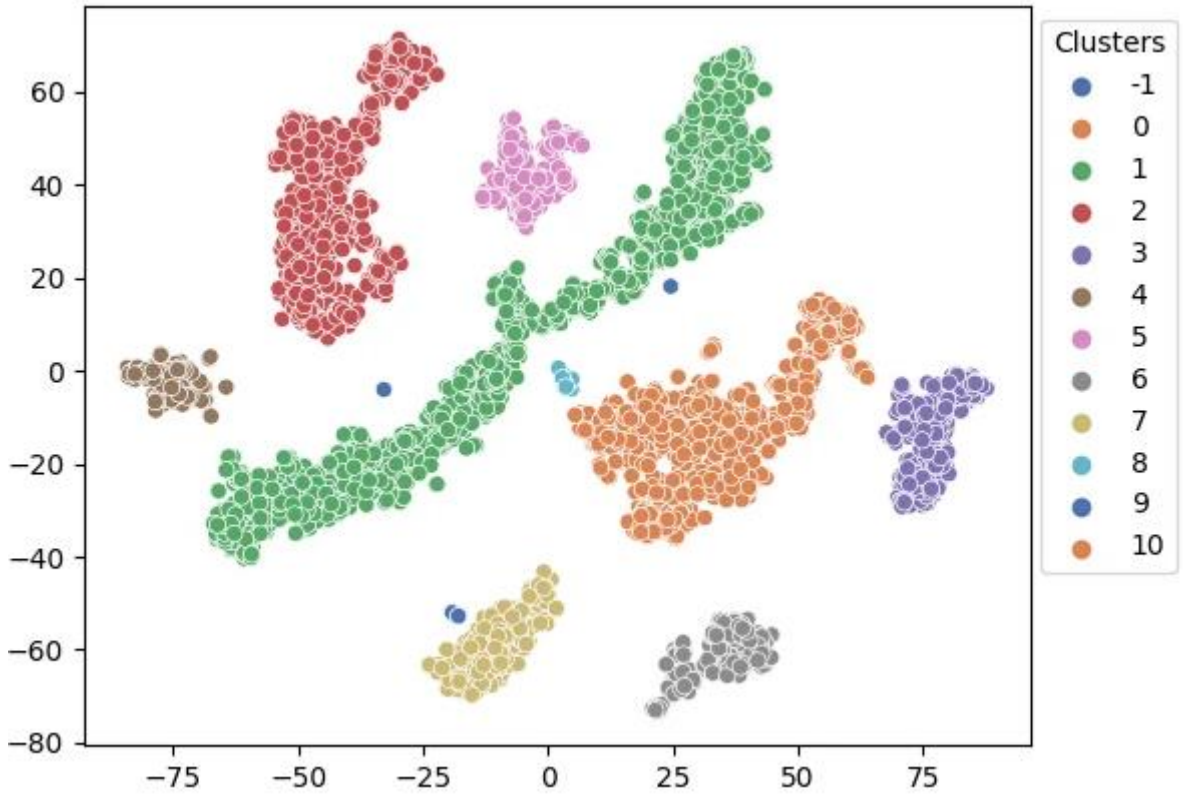
k-means++

Плотностные алгоритмы кластеризации

Основной принцип работы плотностных алгоритмов – это выделение областей с высокой концентрацией точек. Точки, которые попали в области с низкой плотностью, считаются выбросами. Такие алгоритмы подходят для анализа пространственных данных. Например, для того, чтобы выявить области с наибольшим количеством ДТП. Плотностные алгоритмы учитывают выбросы. Если одно-два ДТП произошли вдали от города, эти объекты не будут отнесены к кластерам.

DBSCAN

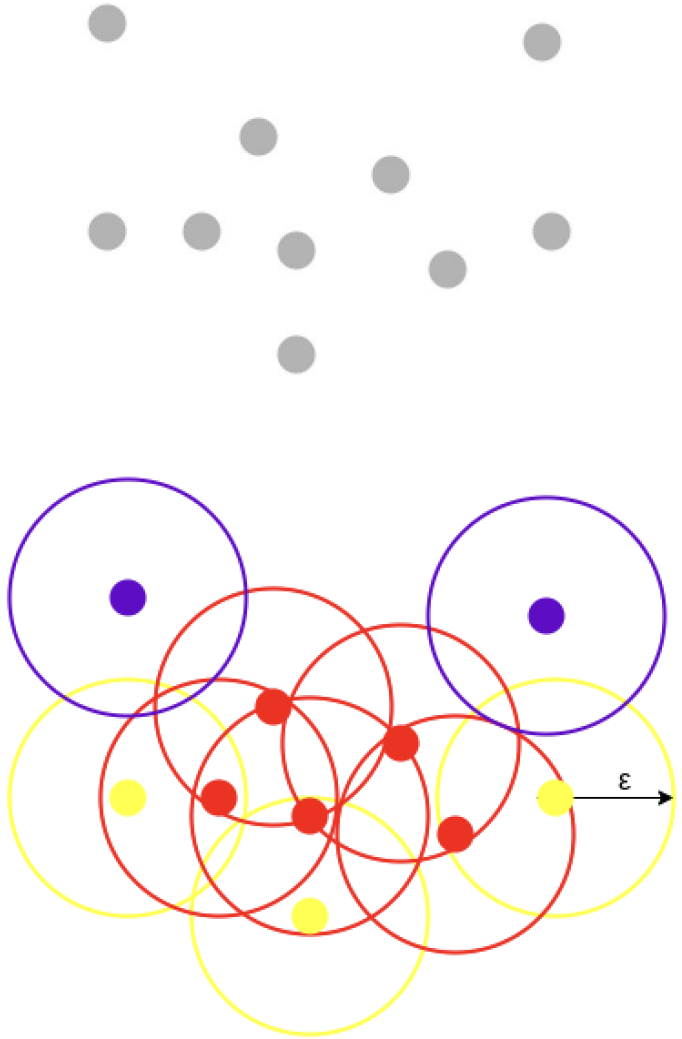
Алгоритм DBSCAN (Density Based Spatial Clustering of Applications with Noise) – плотностный алгоритм для кластеризации пространственных данных с присутствием шума. Способен распознать кластеры различной формы. При реализации алгоритма на вход подаются два параметра: радиус окрестности точек данных и минимальное число соседей.



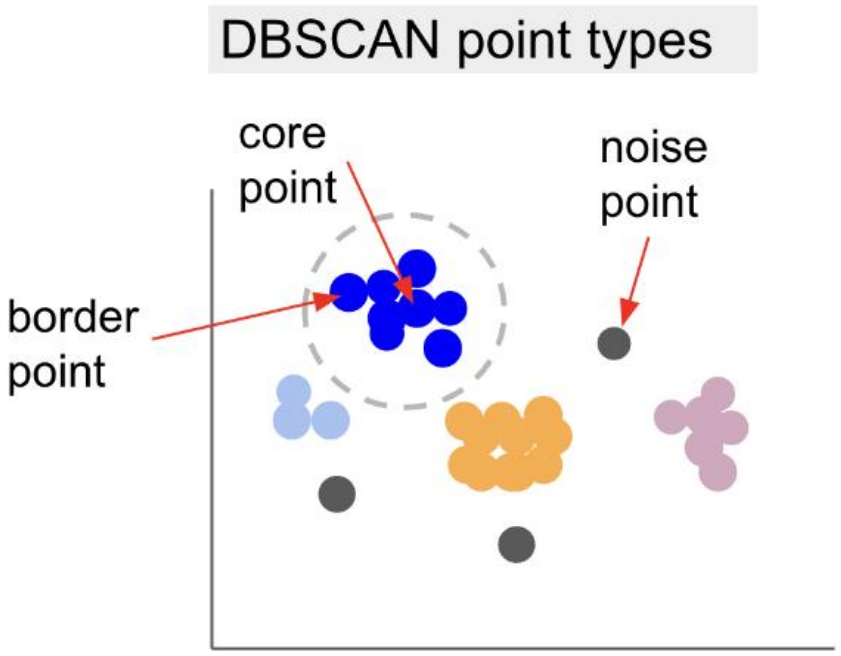
DBSCAN

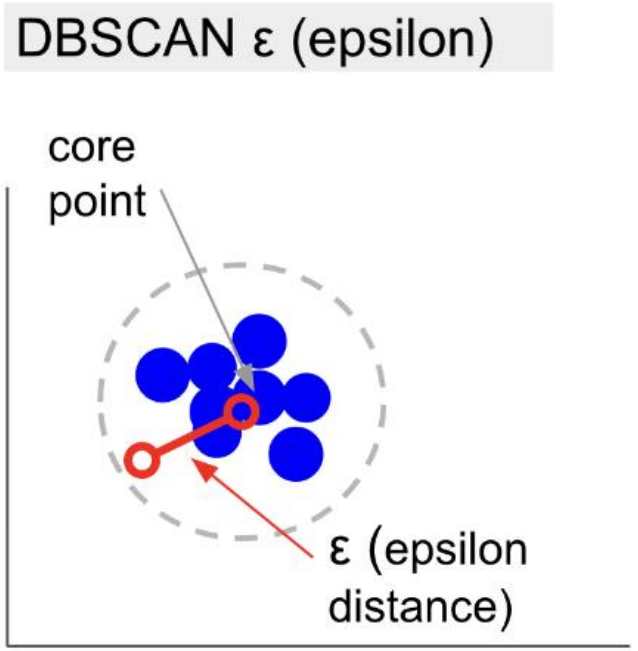
DBSCAN требует два параметра: epsilon (радиус круга, который должен быть создан вокруг каждой точки данных для проверки плотности) и minPoints (минимальное количество точек данных, необходимых внутри этого круга для того, чтобы точка данных была классифицирована как базовая).

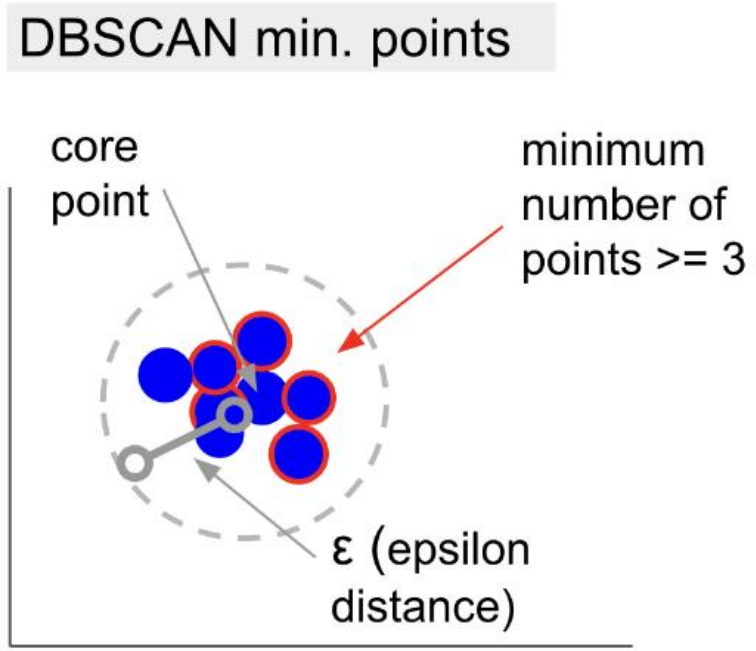
Точка данных является ***базовой/ядровой***, если круг вокруг нее содержит не менее minPoints точек (включая саму точку). Если точка не является ядровой, но находится в ε-окрестности ядровой точки, то она классифицируется как ***граничная точка***, в остальных случаях точка классифицируется как ***шум***.



DBSCAN

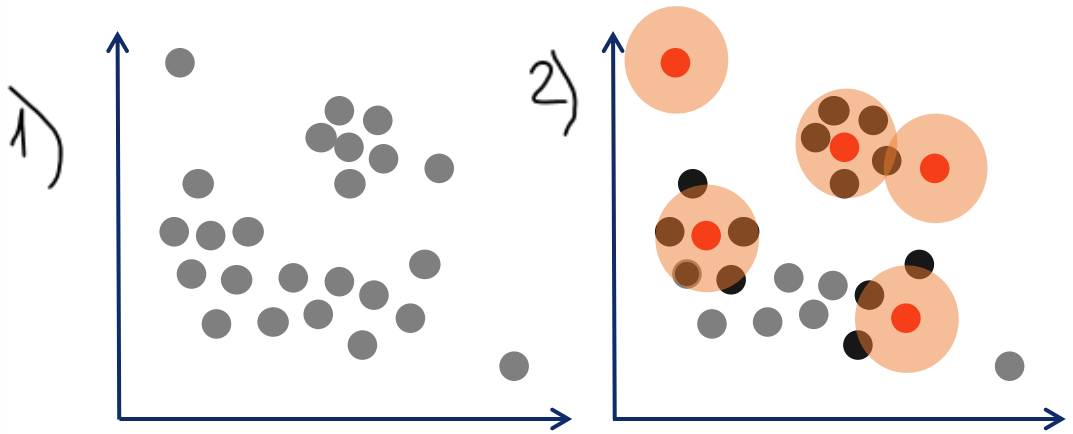

DBSCAN point types
core point
noise point
border point

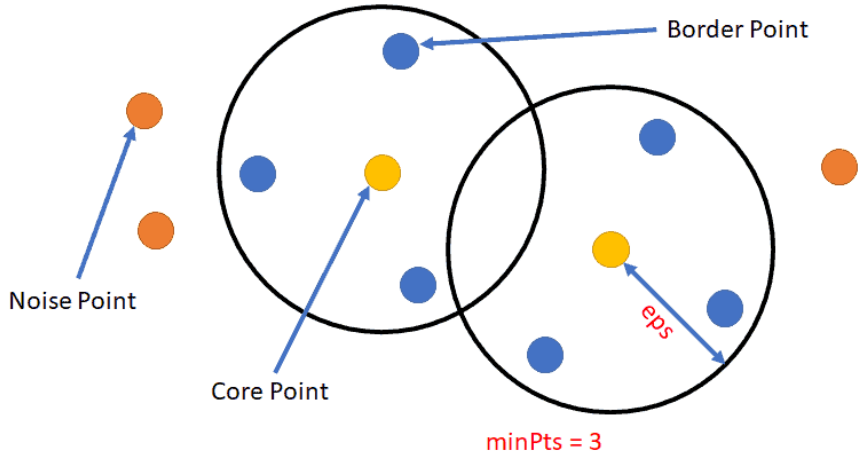

DBSCAN ε (epsilon)
core point
ε (epsilon distance)


DBSCAN min. points
core point
minimum number of points >= 3
ε (epsilon distance)

DBSCAN

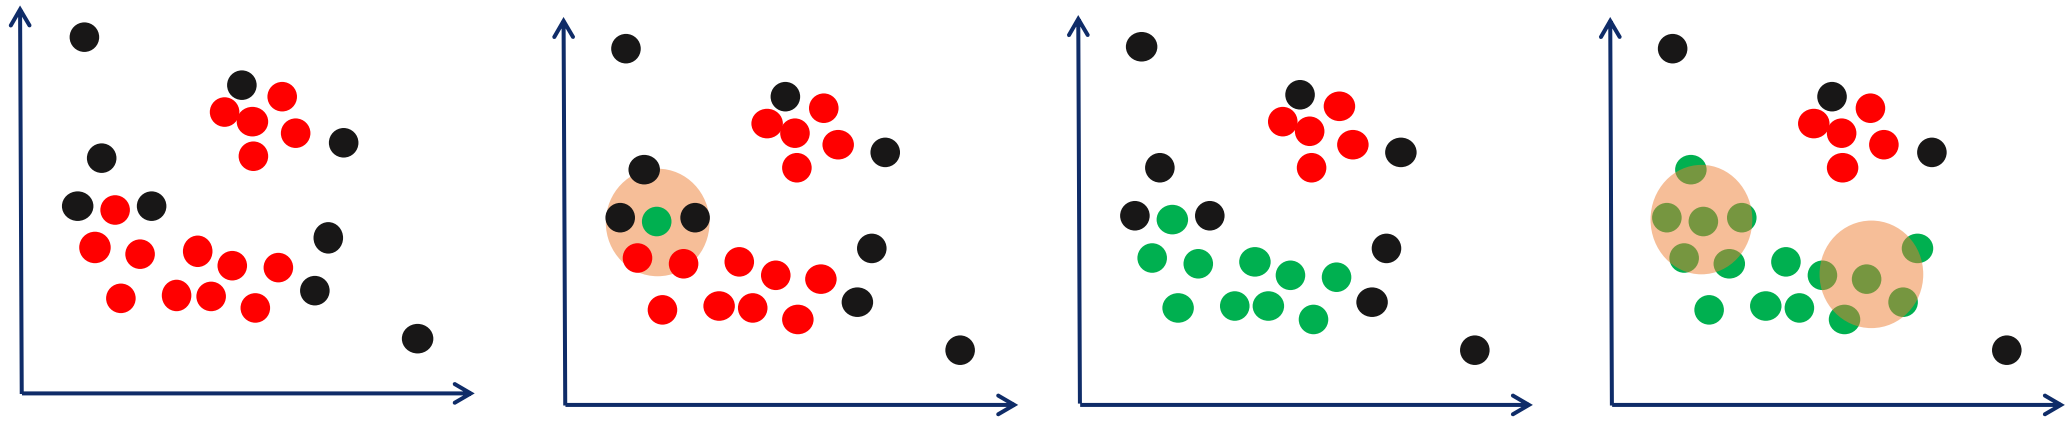
1) Сформировать пространство точек.
2) Подсчитать количество точек, находящихся рядом с каждой точкой в радиусе ε. Пометить ядровые, граничные и шумовые точки.





DBSCAN

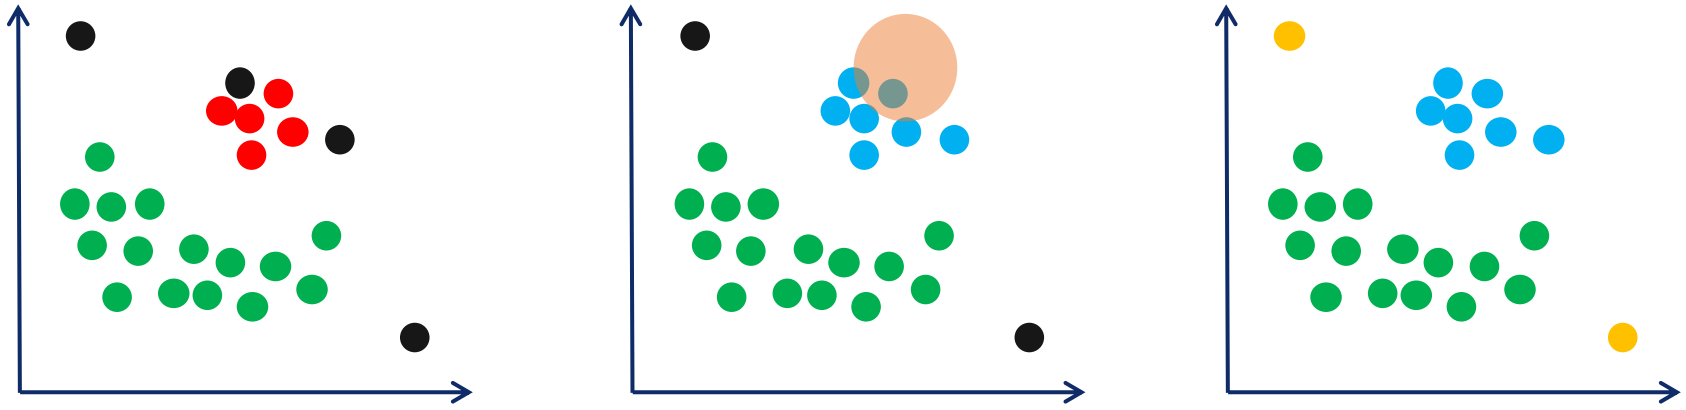
3) Случайным образом выбирается ядровая точка и она назначается **первому кластеру**. Все ядровые точки, находящиеся рядом с ней, также добавляются в этот кластер. Процесс повторяется, пока кластер больше нельзя расширить. После этого к кластеру добавляются неядровые точки, расположенные вблизи его ядровых точек.



DBSCAN

4) Оставшиеся точки, которые находятся близко друг к другу, но отделены от первого кластера, используются для формирования **второго кластера** аналогичным образом.

5) Когда все ядровые точки распределены по кластерам, кластеризация считается завершённой. Точки, не вошедшие ни в один кластер, называются **выбросами** и помещаются в отдельный кластер.

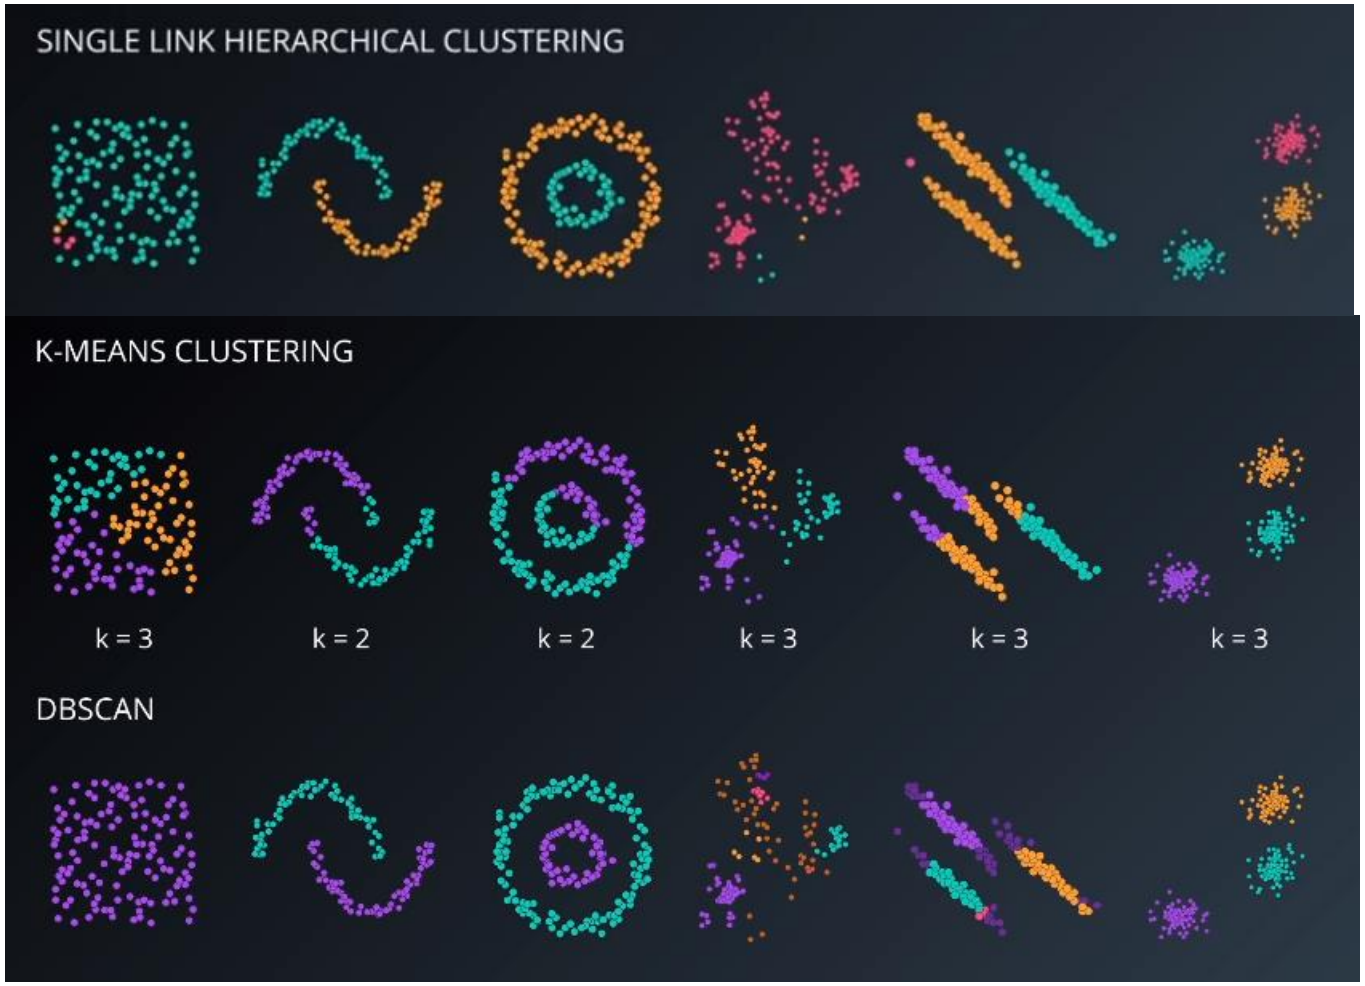


DBSCAN: преимущества и ограничения

- ➕ Находит кластеры разных форм и размеров;
- ➕ Различает шумы и выбросы в данных;
- ➕ Не требует предварительного указания количества кластеров;
- ➕ Легко и быстро реализуется.

- ➖ Требует указания двух гиперпараметров (радиус и число соседей), оптимальные значения которых не всегда легко найти;
- ➖ Может быть чувствителен к выбору параметров и используемой метрике расстояния.

Сравнение трех алгоритмов



Выбор оптимального числа кластеров

Для принятия решения об оптимальном числе кластеров необходимо учитывать цель исследования, специфику данных, результаты ранее проведённых исследований подобной тематики и интерпретируемость результатов. Возможно, стоит сохранить несколько кластерных решений и выбрать из них наилучшее с точки зрения однородности кластеров и содержательной интерпретации полученного решения. Выбор количества кластеров может быть осуществлен на основе значений различных метрик.

Индекс Калински-Харабаша

Индекс Калински-Харабаша (CH Index) часто используется для выбора оптимального числа кластеров, особенно для иерархической кластеризации. В нем используются внутрикластерная и межкластерная вариации для оценки качества кластеризации.

$$CH(K) = \frac{B/(K-1)}{W/(n-K)}$$

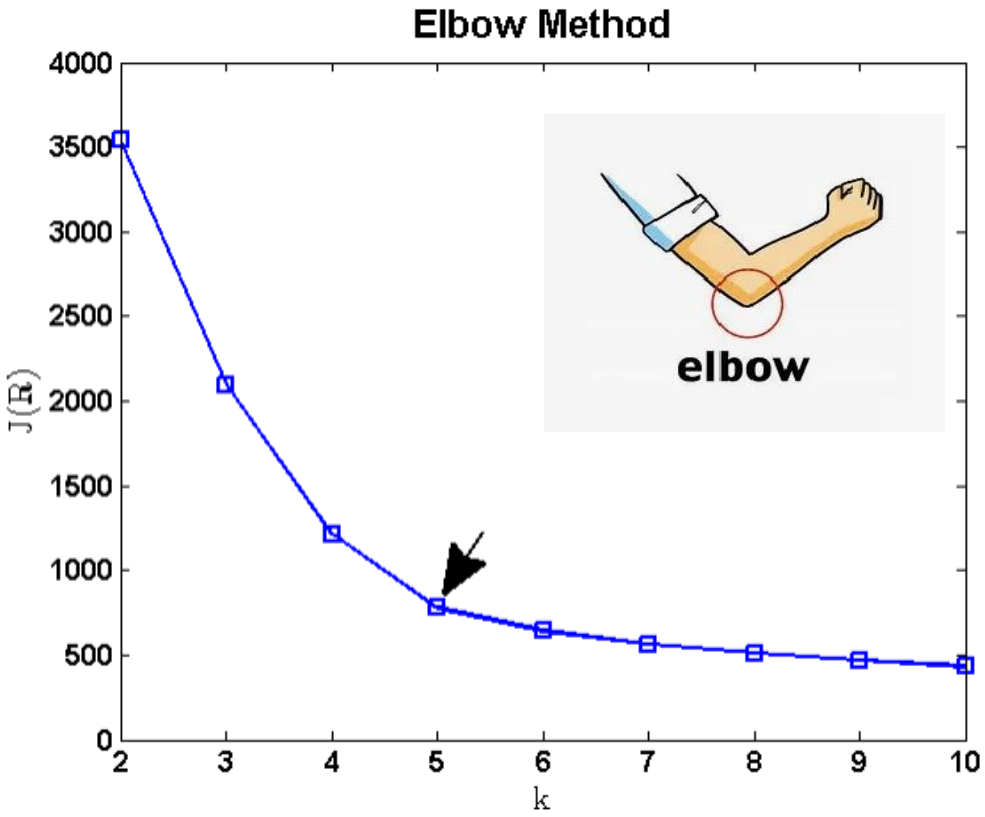
- W - внутрикластерная вариация,
- B - межкластерная вариация,
- K - число кластеров,
- n - количество объектов.

Мы стремимся добиться малой вариации внутри кластеров и большой вариации между кластерами. Поэтому оптимальным выбирается значение K, при котором значение индекса CH максимально.

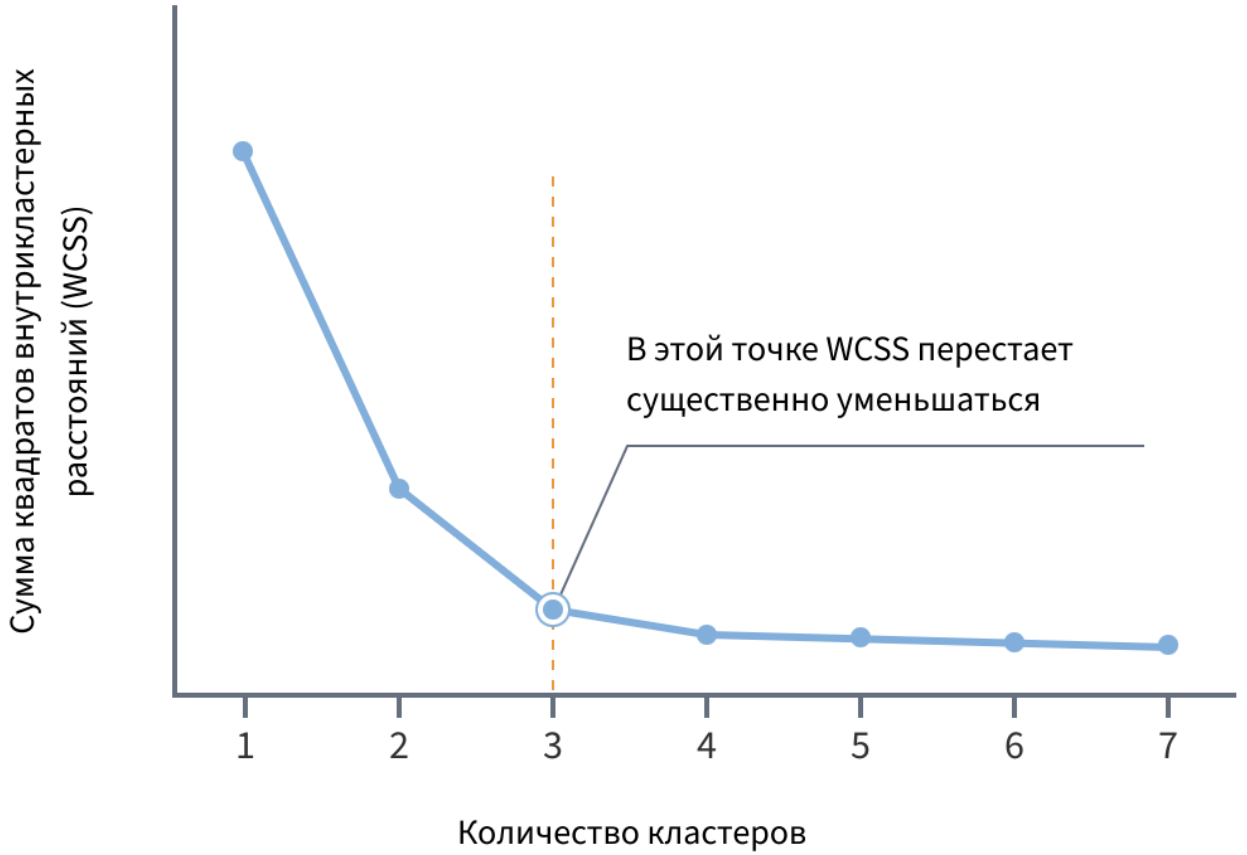
Метод локтя с использованием инерции

На графике показано значение **инерции** для разного количества кластеров. **Инерция** вычисляется как сумма квадратов расстояний от каждой точки данных до центра её кластера.

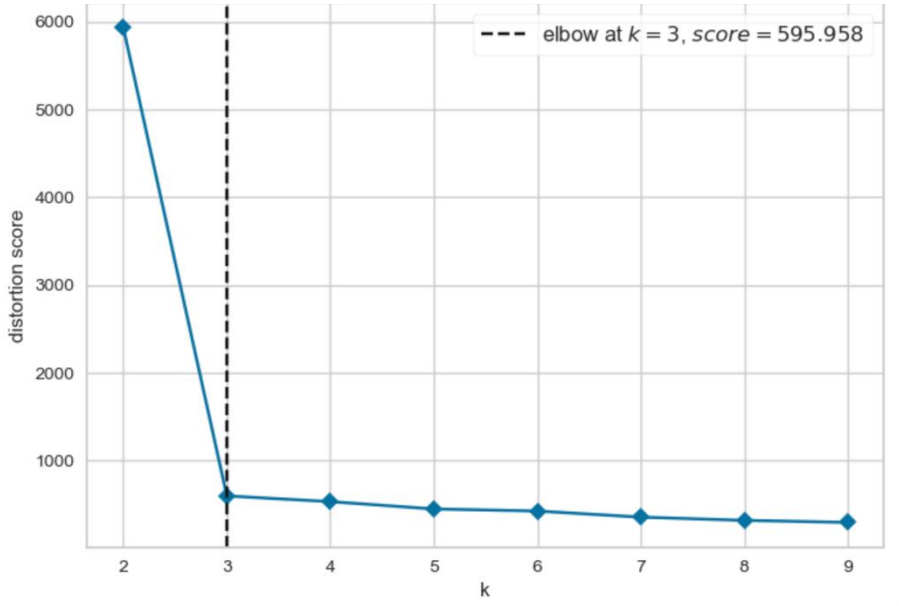
Метод локтя предполагает выбор такого числа кластеров, при котором уменьшение инерции начинает замедляться – на графике это выглядит как «локоть». Это значение **k** считается оптимальным, так как дальше увеличение числа кластеров даёт лишь незначительное улучшение качества.



Метод локтя


Сумма квадратов внутрикластерных расстояний (WCSS)
В этой точке WCSS перестает существенно уменьшаться
1
2
3
4
5
6
7
Количество кластеров

Метод локтя с использованием меры искажений



Мера искажений (Distortion Score) - это среднее значение квадратов евклидовых расстояний от каждой точки до центроида её кластера. Inertia – это суммарная мера, а Distortion Score – нормализованная (усреднённая), что делает её удобнее для сравнения наборов данных разного размера.

Коэффициент силуэта

Коэффициент силуэта (Silhouette Score) – это метрика качества кластеризации, оценивающая баланс между компактностью кластеров и их разделённостью.

Для каждого объекта рассчитываются два значения:

- Связность (Cohesion, a) – среднее расстояние от точки до остальных точек внутри того же кластера. Чем меньше, тем более компактным является кластер.
- Разделённость (Separation, b) – минимальное среднее расстояние от точки до точек ближайшего другого кластера. Чем больше, тем лучше кластеры отделены друг от друга.

Коэффициент силуэта для точки вычисляется по формуле:

$$s = \frac{b - a}{\max(a, b)}$$

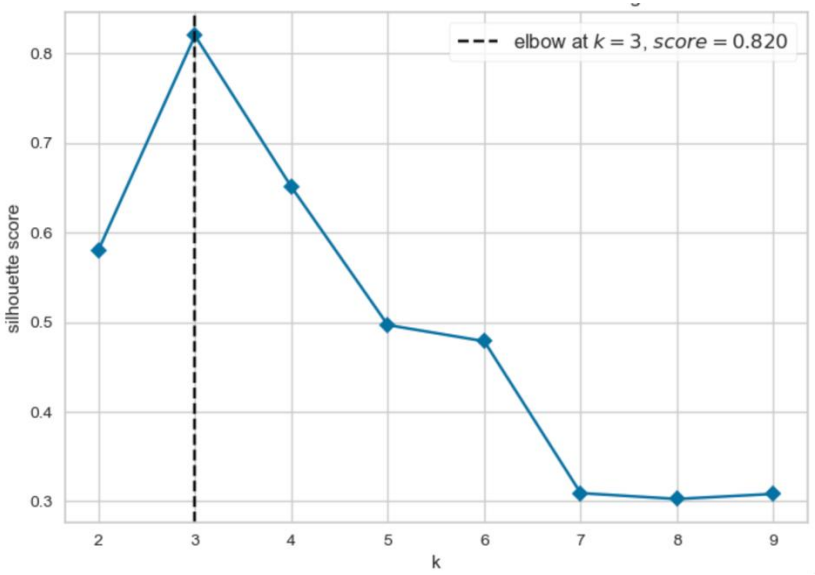
Коэффициент силуэта для модели – это среднее значение коэффициентов по всем точкам.

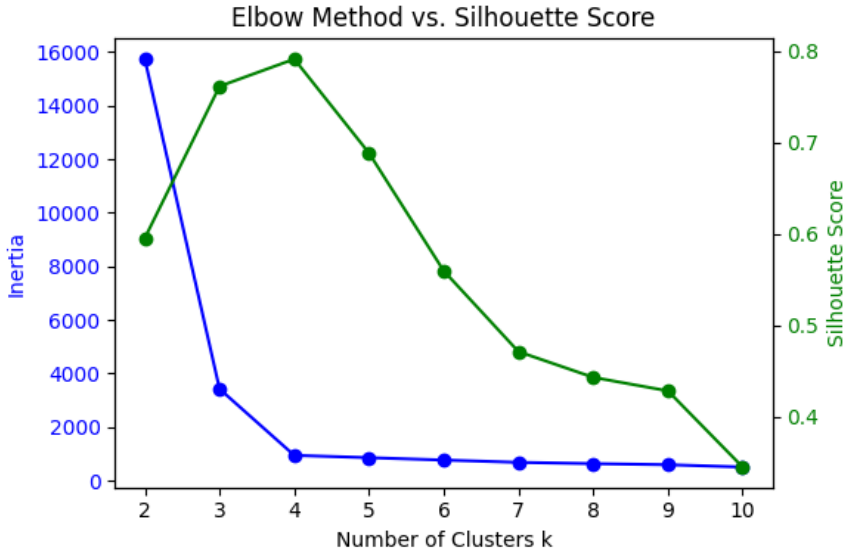
Коэффициент силуэта

Значения коэффициента силуэта лежат в интервале [-1; 1]:

- Отрицательное значение сигнализирует о том, что точку неправильно отнесли к кластеру (она ближе к другому кластеру, чем к своему).
- Значения, близкие к 0, означают, что кластеры перекрываются, нет четкого разделения (много точек на границе кластеров).
- Чем ближе к 1, тем лучше кластерная модель.

≥ 0.7 – отличная кластеризация;
0.5-0.7 – хорошая;
0.25-0.5 – слабая, возможны пересечения;
< 0.25 – структура кластеров выражена плохо.





Описание результатов и проверка их значимости

Для описания результатов кластеризации можно рассчитать описательную статистику по кластерам.

Для проверки статистической значимости выявленных отличий между кластерами можно провести тест ANOVA или его непараметрический аналог, чтобы убедиться, что средние значения анализируемых переменных значимо различаются по кластерам.

Для оценки качества кластеризации можно оценить дисперсию значений переменных по кластерам.

Описательная статистика по кластерам

Табл. 7. **Профили кластеров и распределение объектов**

Номер кластера	«ЕГЭ»	«Молодежь»	«УБФ»	«Размер»	«ИиР»	Количество объектов
1	59.81	0.24	82.75	5905.31	89.82	36
2	66.32	0.15	90.05	13495.43	86.92	37
3	57.42	0.06	95.82	5825.06	71.61	32
4	70.77	0.16	205.40	7947.39	70.72	18
5	59.53	0.21	85.15	7177.98	50.80	42
6	65.00	0.15	101.54	9005.85	13.41	54

Источник: расчеты авторов.

Диагностика кластерной модели

Для подтверждения надёжности результатов кластеризации применяются различные приёмы:

- Используются разные алгоритмы кластеризации и полученные результаты сопоставляются;
- Объекты случайно разбиваются на две группы, анализ выполняется отдельно для каждой группы, результаты сопоставляются;
- Анализ проводится по сокращённому набору признаков и результаты сравниваются с полноценным анализом.

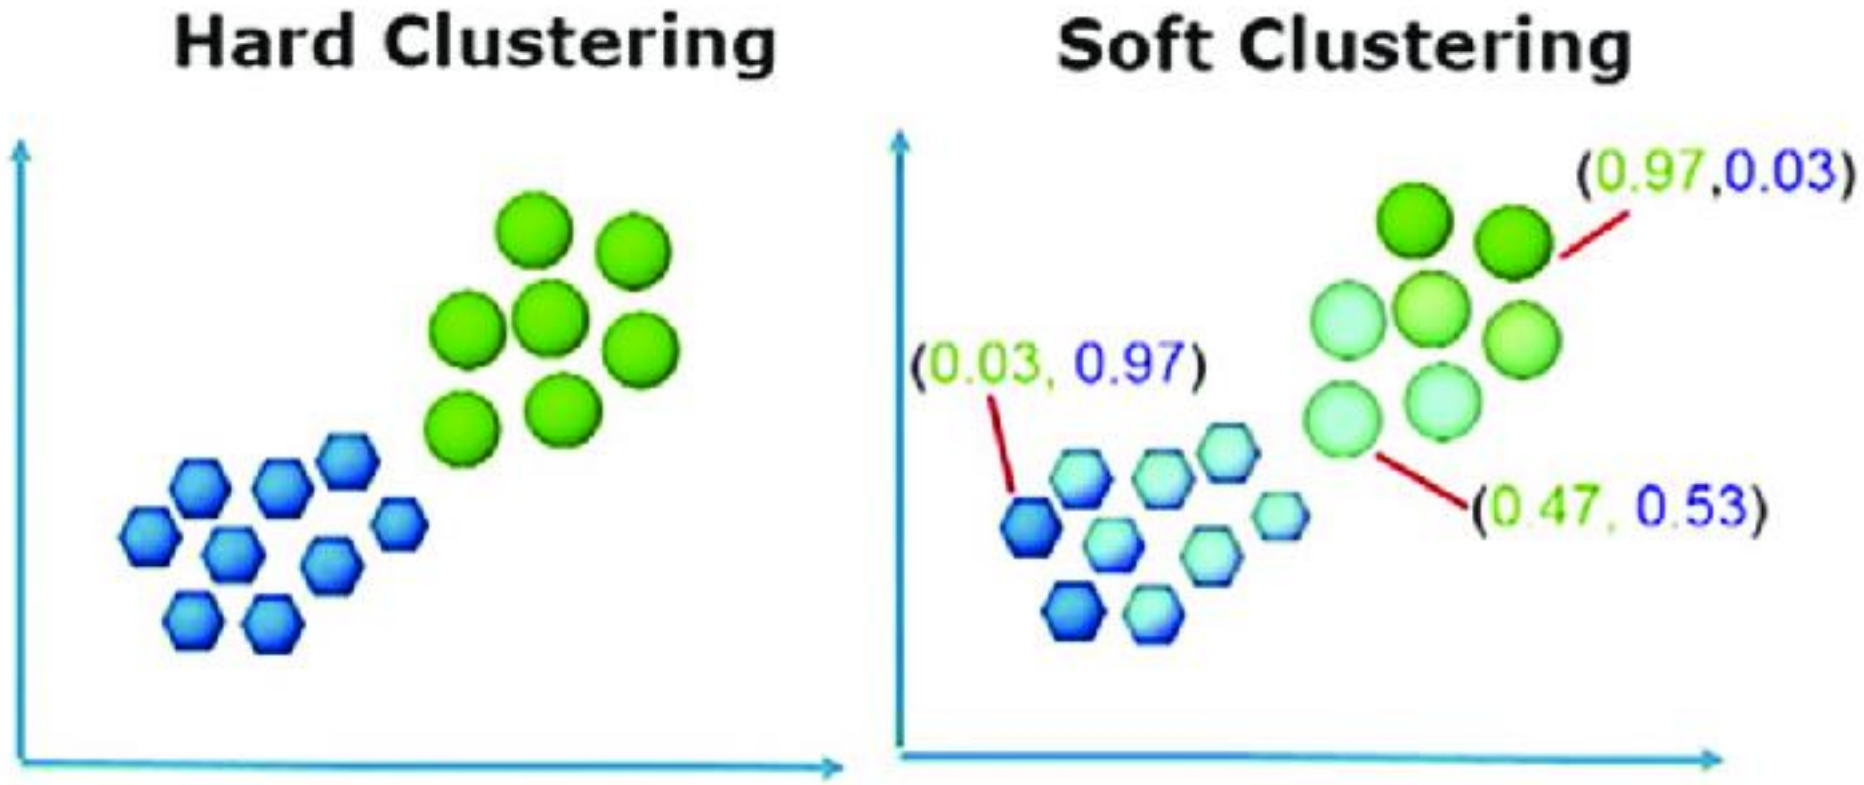
Жёсткая и мягкая кластеризация

Жёсткая и мягкая кластеризация – два подхода к разбиению данных на кластеры.

В **жёсткой кластеризации** (hard clustering) каждый объект принадлежит только одному кластеру. Применяется когда кластеры довольно хорошо разделяются и требуется однозначное решение о принадлежности объекта тому или иному кластеру. Примеры алгоритмов: k-means, иерархическая кластеризация, DBSCAN.

В **мягкой/нечеткой кластеризации** (soft / fuzzy clustering) каждый объект может принадлежать нескольким кластерам с разной степенью принадлежности. В таком подходе используются вероятности или веса. Он больше подходит для перекрывающихся кластеров. Примеры алгоритмов: Gaussian Mixture Models (GMM), Fuzzy C-means (FCM), Expectation–Maximization (EM), Probabilistic Clustering (PC), Soft K-Means

Жёсткая и мягкая кластеризация



Возможные ошибки в кластерном анализе

- Не масштабировать признаки.
- Использовать неподходящие алгоритм кластеризации или метрику расстояния.
- Случайным образом выбирать гиперпараметры.
- Полагаться только на метрики качества.
- Механически описывать кластеры не вникая в смысл полученных результатов.
- Рассматривать полученную группировку объектов как истину.

Особенности кластерного анализа

Результат кластеризации может зависеть от того, какие признаки выбраны для построения модели и какой алгоритм кластеризации применяется. Если в выборке явно наблюдаются тенденции, то они будут выявлены независимо от выбранного алгоритма, но состав кластеров и их характеристики могут несколько отличаться. Для того, чтобы группу объектов считать полноценным кластером, в ней должно быть достаточно наблюдений. Не должно быть “влияющих наблюдений” и изменение алгоритма кластеризации не должно кардинально менять результат.

Визуализация работы алгоритмов

- Visualizing K-Means Clustering (naftaliharris.com)
- Visualizing DBSCAN Clustering (naftaliharris.com)

Спасибо за внимание!