

Факультет компьютерных наук | Машинное обучение | Москва 2026

Лекция 6
Линейная регрессия

Преподаватель: Меликян Алиса Валерьевна, amelikyan@hse.ru
кандидат наук, доцент Департамента программной инженерии ФКН НИУ ВШЭ

Регрессионный анализ

Регрессионный анализ используется для предсказания числовых значений на основе входных данных. Позволяет проанализировать зависимости между признаками и целевой переменной.

Ограничения использования:

- выявляются статистические, а не обязательно причинно-следственные связи;
- возможно влияние внешних и скрытых факторов, не учтённых в данных;
- необходимость валидации на независимой выборке для предотвращения переобучения;
- модель корректно работает при условии, что характеристики и структура новых данных существенно не отличаются от обучающей выборки (отсутствие значимого смещения распределений – data drift).

Виды регрессии

- **Линейная регрессия**: предполагает линейную зависимость между признаками и целевой переменной.
- **Полиномиальная регрессия**: расширение линейной регрессии – добавляет степени признаков и позволяет моделировать нелинейные зависимости.
- **Регуляризованные модели** (помогают бороться с переобучением):
  - Ridge-регрессия (L2)
  - Lasso-регрессия (L1)
  - Elastic Net (комбинация L1 и L2)

Линейная регрессия

Линейную регрессию используют, когда нужно:

- построить модель для предсказания целевой переменной по набору признаков;
- понять, какие признаки значимы;
- оценить, как именно каждый из них влияет на результат.

Например, можно предсказывать зарплату программного инженера по его характеристикам: возрасту, полу, опыту работы, уровню образования, должности, количеству лет работы в отрасли и др. характеристикам.

Ключевое допущение модели – **линейная зависимость** целевой переменной от признаков: изменение признака на одну единицу приводит к изменению результата на фиксированную величину при прочих равных условиях. Это упрощение реальности, но оно позволяет получить понятную и обобщающую модель.

Линейная регрессия

Алгоритм линейной регрессии подбирает коэффициенты модели таким образом, чтобы минимизировать суммарную ошибку предсказания на обучающей выборке. После обучения модель принимает вид формулы с коэффициентами. Подставив значения признаков конкретного человека, мы можем получить прогноз его зарплаты.

Кроме того, анализ коэффициентов позволяет интерпретировать модель:

- знак коэффициента показывает направление влияния признака на результат;
- величина коэффициента отражает силу этого влияния;
- статистическая значимость помогает понять, какие факторы действительно связаны с целевой переменной.

Таким образом, линейная регрессия сочетает в себе предсказательную способность и интерпретируемость.

Линейная регрессия в ПИ

Пример: прогнозирование производительности программиста

- Целевая переменная (Y): скорость выполнения задач.
- Факторы (X): опыт работы, количество завершённых проектов, количество написанных и проверенных задач, сложность выполняемых задач, участие в командных проектах.

С помощью коэффициентов модели можно понять, какие факторы и как именно влияют на скорость. Коэффициенты легко объяснить не экспертам: «Участие в командных проектах повышает скорость работы на X единиц».

Подходит для начального анализа данных перед использованием сложных алгоритмов (baseline модель). Можно протестировать гипотезы, проверить эффекты взаимодействия и мультиколлинеарность, прежде чем переходить к сложным ML-моделям.

Этапы построения модели линейной регрессии

1. Собрали и подготовили датасет: выделили предикторы и целевую переменную.
2. Проверили, что целевая переменная – непрерывная числовая, а предикторы – числовые или корректно закодированные категориальные (бинарные). При необходимости преобразовали признаки.
3. Разделили данные на обучающую и тестовую выборки для оценки обобщающей способности модели.
4. Стандартизировали признаки, если планируется сравнение силы влияния предикторов на целевую переменную.
5. Обучили модель линейной регрессии.
6. Провели диагностику модели (качество предсказания, проверка допущений).
7. Интерпретировали результаты, проанализировав значения и статистическую значимость коэффициентов регрессии.

Простая линейная регрессия

Простая линейная регрессия – это метод моделирования линейной зависимости между признаком (feature) и одной целевой переменной (target) с помощью уравнения:

$$\hat{Y} = \mathrm{w} \cdot X + b$$

X – входной признак (feature);

$\hat{Y}$ – целевая переменная (target);

w – коэффициент признака (weight), определяет наклон линии;

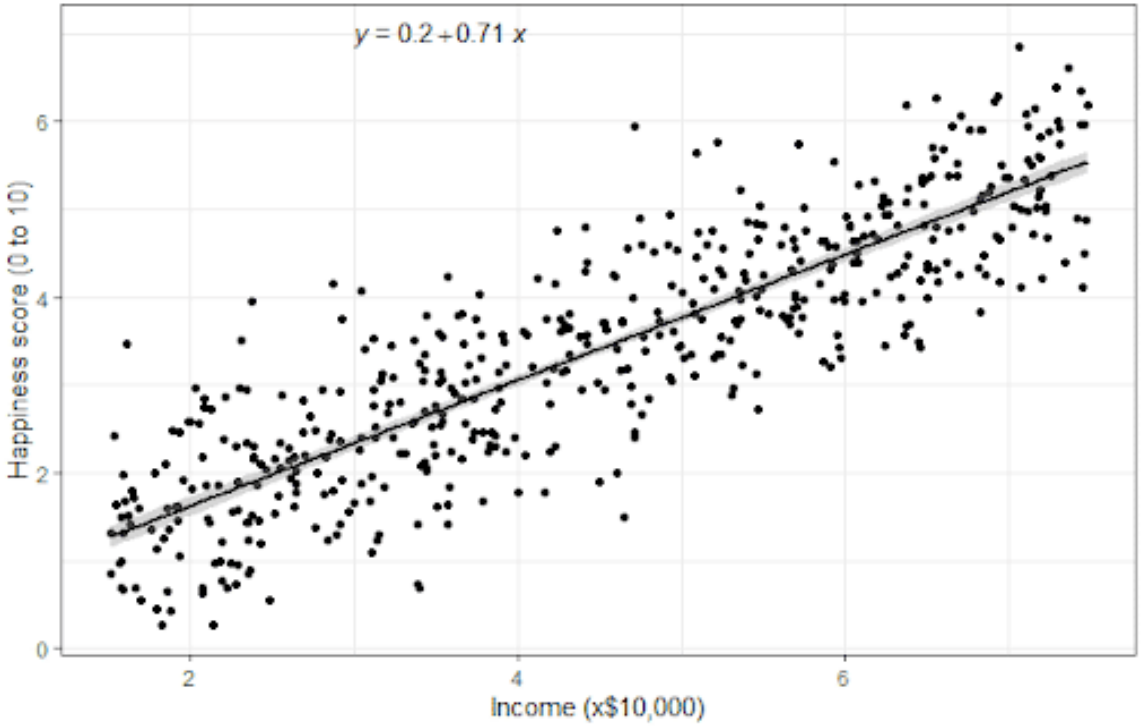
b – смещение (bias), сдвигает линию вертикально.

Параметры модели (w и b) оцениваются методом наименьших квадратов, минимизируя отклонения между предсказанными и фактическими значениями целевой переменной.

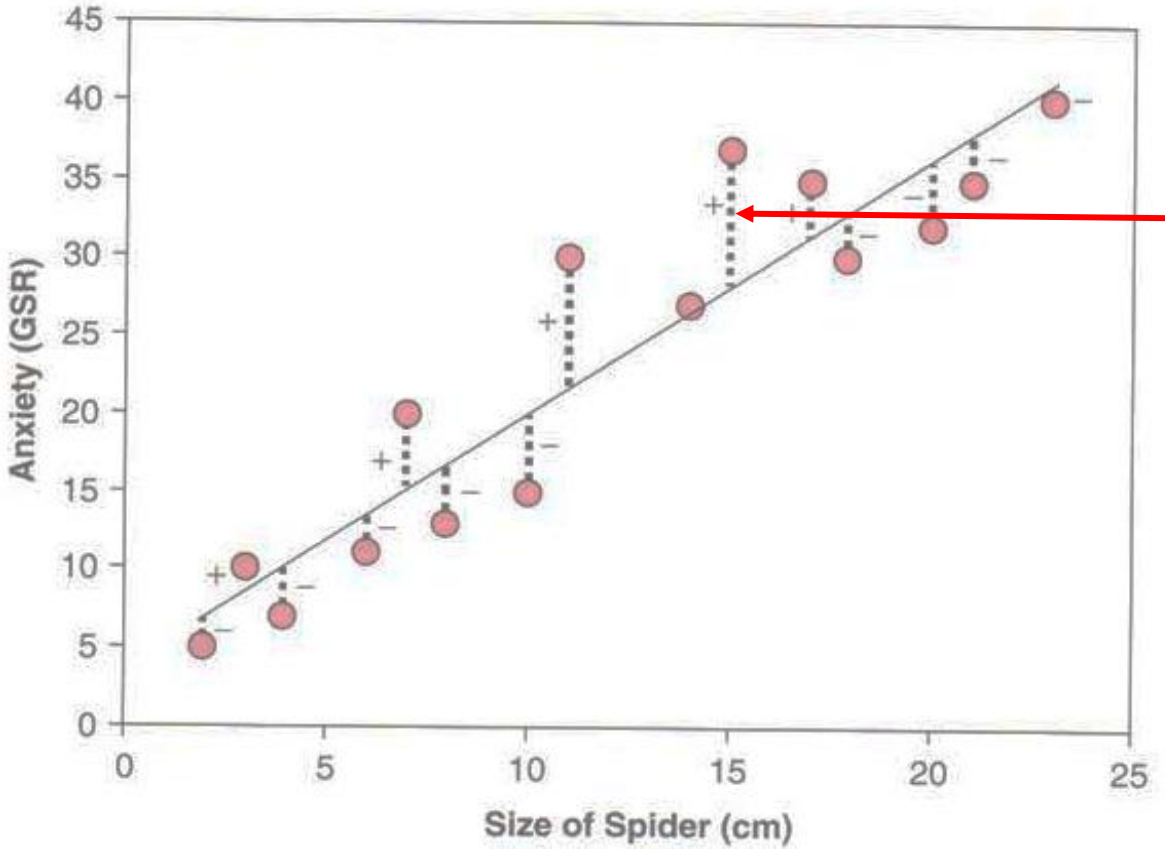
Диаграмма рассеяния

Перед обучением модели полезно построить диаграмму рассеяния (scatter plot), чтобы:

- Проверить наличие линейной зависимости между признаком и целевой переменной.
- Выявить выбросы (outliers), которые могут сильно влиять на обучение модели.



Остатки



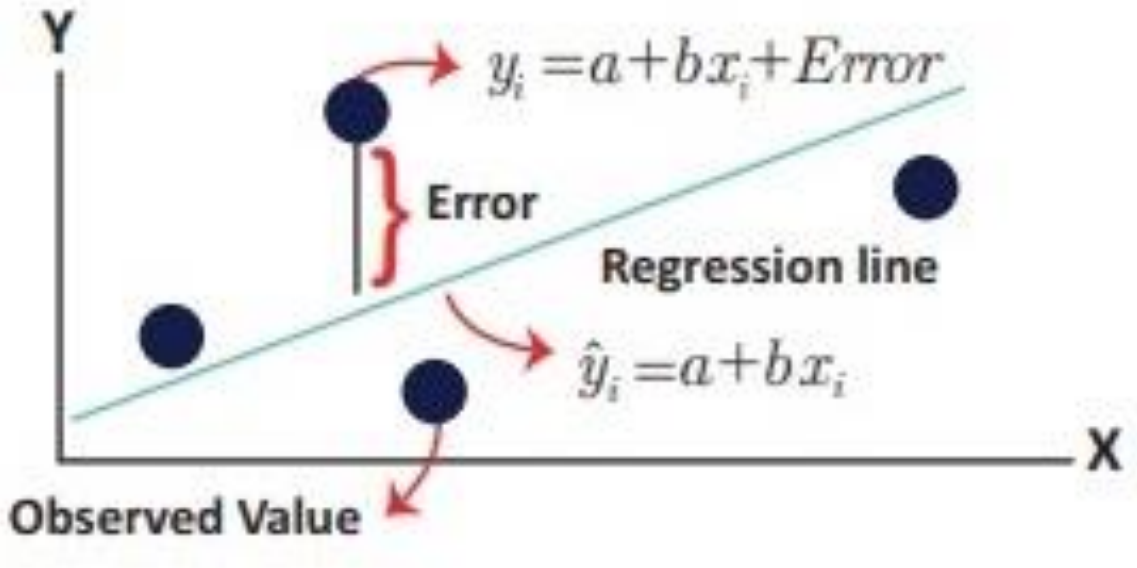
Остатки – отклонения между реальными и предсказанными моделью значениями целевой переменной. Могут принимать нулевые, отрицательные и положительные значения.

Метод наименьших квадратов

Цель – подобрать такие параметры модели a и b, чтобы минимизировать квадраты отклонений реальных и предсказанных значений целевой переменной (Sum of Squared Errors, SSE).

Возводим в квадрат, чтобы плюс и минус не сокращались, а большие ошибки штрафовались сильнее.

$$\mathrm{SSE} = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$



Три вида сумм квадратов

SSE – Sum of Squared Errors (ошибка модели)

TSS – Total Sum of Squares (ошибка константой модели)

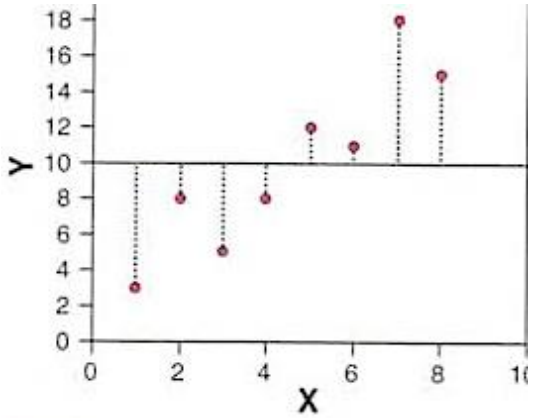
ESS – Explained Sum of Squares (объяснённая вариация)

$$\boxed{TSS = ESS + SSE}$$

Виды сумм квадратов

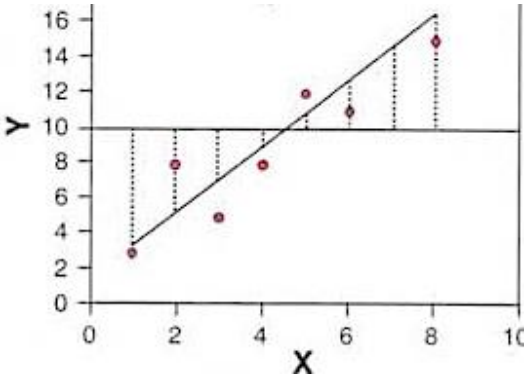
Общая сумма квадратов (Total Sum of Squares) – TSS. Это ошибка константной модели (baseline), которая всегда предсказывает среднее.

$$\mathrm{TSS} = \sum (y_i - \bar{y})^2$$



Объяснённая сумма квадратов (Explained Sum of Squares) – ESS. Это объясненная моделью вариация, показывающая насколько предсказания отличаются от модели среднего (baseline).

$$ESS = \sum_{i=1}^{n} (\hat{y}_i - \bar{y})^2$$



Множественная линейная регрессия

Позволяет предсказать значения целевой переменной на основе нескольких признаков. Уравнение регрессии принимает вид:

$$\hat{Y} = \mathrm{b} + w_1 x_1 + w_2 x_2 + \cdots + w_k x_k$$

$\hat{Y}$ – предсказанное значение целевой переменной;

$x_1, x_2, \ldots, x_k$ – признаки;

b – смещение;

$w_1, w_2, \ldots, w_k$ – веса модели.

Предсказания зарплаты

$$\widehat{\text{зарплата}} = \text{b} + w_1 * \text{опыт} + w_2 * \text{образование} + w_3 * \text{кол} - \text{во навыков} + w_4 * \text{уровень компании}$$

Каждый коэффициент показывает, как признак влияет на зарплату:

w_1 – насколько меняется зарплата при увеличении опыта на 1 год

w_2 – вклад образования

w_3 – влияние количества навыков

w_4 – влияние уровня компании (например, стартап / корпорация)

b – базовая зарплата при нулевых значениях признаков.

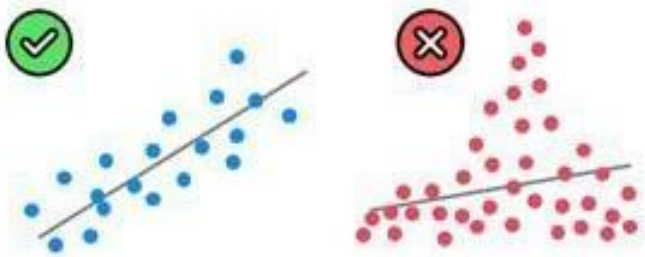
Предположения линейной регрессии

Предположения линейной регрессии нужны, чтобы оценки коэффициентов были корректными и чтобы можно было делать надёжные выводы на основе модели.

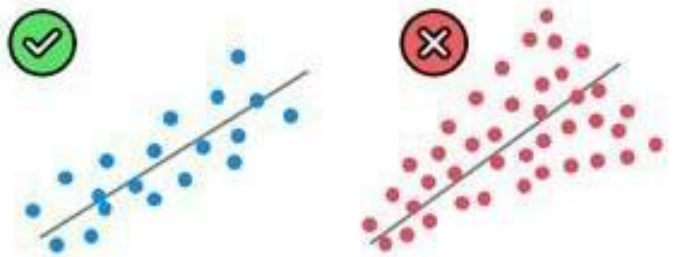
- Линейная зависимость;
- Отсутствие сильной мультиколлинеарности;
- Гомоскедастичность (постоянная дисперсия ошибок);
- Независимость наблюдений;
- Нормальность ошибок (для корректных статистических выводов о значимости, для предсказания не так важно).

Предположения линейной регрессии

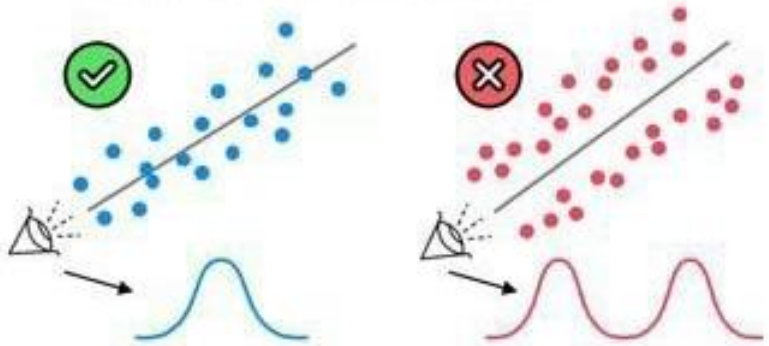
1. Linearity
(Linear relationship between Y and each X)



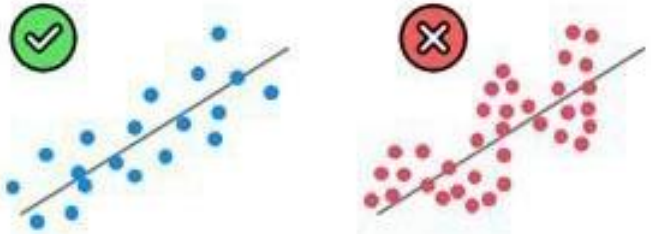
2. Homoscedasticity
(Equal variance)



3. Multivariate Normality
(Normality of error distribution)



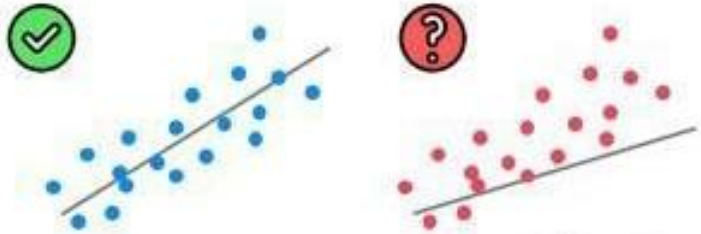
4. Independence
(of observations. Includes "no autocorrelation")



5. Lack of Multicollinearity
(Predictors are not correlated with each other)

$X_1 \not\sim X_2$ $X_1 \sim X_2$

6. The Outlier Check
(This is not an assumption, but an "extra")



Мультиколлинеарность

Мультиколлинеарность – ситуация, когда два или более признака в модели сильно коррелируют между собой ($r > 0,7$). Это проблема, которая может существенно повлиять на результаты регрессионного анализа, снижая точность оценок коэффициентов и усложняя интерпретацию модели.

Частые причины:

- избыточные признаки, которые измеряют один и тот же аспект явления;
- взаимосвязь между признаками (часто наблюдается в социально-экономических данных);
- искусственно созданные признаки, представляющие те же данные, но в преобразованном виде.

Мультиколлинеарность

Мультиколлинеарность приводит к тому, что частная корреляция между признаком и целевой переменной стремится к нулю, даже если парная корреляция высока.

В линейной регрессии оценивается уникальный вклад каждого предиктора, «очистив» его от влияния других. Если два признака почти полностью дублируют друг друга, то после учета одного из них, второму практически не остается независимой информации для объяснения целевой переменной.

Из-за этого коэффициенты могут сильно искажаться, вплоть до смены знака, и терять значимость.

Диагностика мультиколлинеарности

- Корреляционная матрица: выявление высоких корреляций между признаками.
- Фактор инфляции дисперсии (Variance Inflation Factor, VIF): для каждого признака вычисляется VIF, который показывает, насколько сильно варьируется его регрессионный коэффициент из-за корреляции с другими признаками. Для каждого предиктора строится регрессия, в которой он является целевой переменной, а остальные признаки предикторами. Таким образом оценивается доля вариации признака, объясняемой другими признаками.

$$VIF_j = \frac{1}{1 - R_j^2}$$

Если VIF > 10, то наблюдается сильная мультиколлинеарность.

Устранение мультиколлинеарности

- Удаление признаков: если два признака сильно коррелируют и по смыслу дублируют друг друга, то один из них можно удалить.
- Объединение признаков: можно объединить несколько признаков в один, рассчитав на их основе комплексный индекс, например, усреднив их значения.
- Расчет главных компонент (PCA).
- Применение полиномиальной регрессии: если мультиколлинеарность возникает из-за взаимодействия признаков, можно рассмотреть использование полиномиальных признаков или взаимодействий, чтобы улучшить модель.
- Применение методов регуляризации:
    - Ridge-регрессия: добавляется штраф за большие коэффициенты,
    - Lasso-регрессия: не только может уменьшить коэффициенты, но и полностью исключить некоторые признаки из модели.

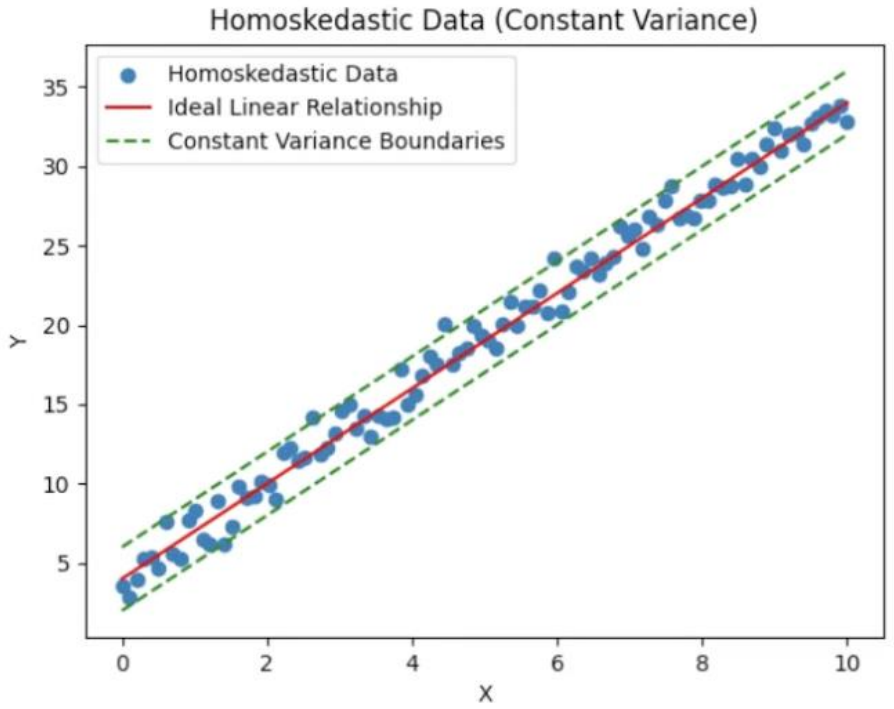
Гетероскедастичность

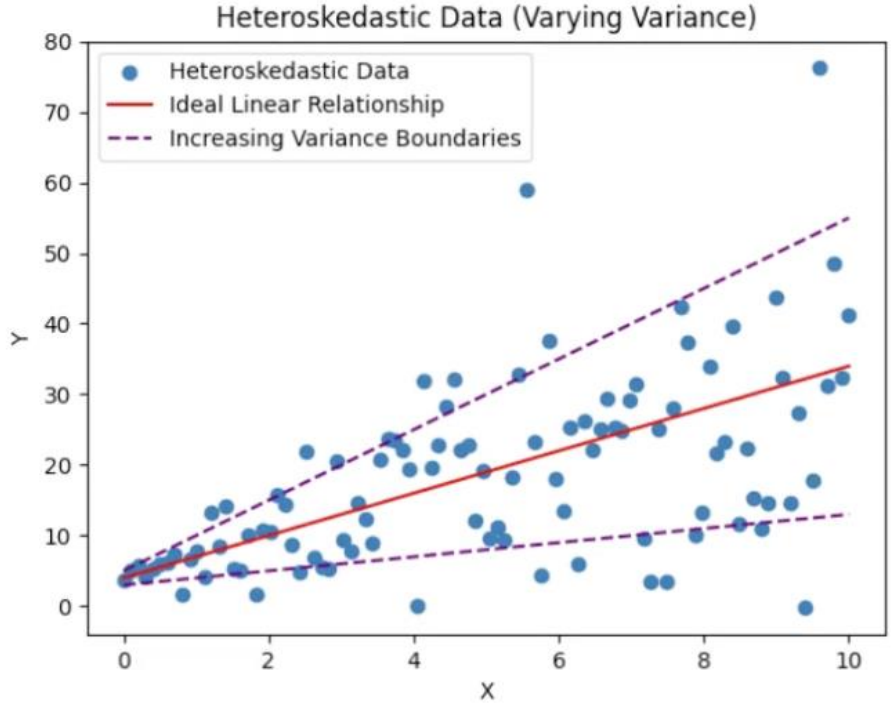
Гетероскедастичность – непостоянство дисперсии остатков. Это означает, что разброс ошибок модели меняется в разных частях данных: где-то прогнозы очень точные, а где-то наоборот. Этот шум не случайный, зависит от значений признаков или уровня целевой переменной.

Пример: цена дорогих объектов предсказывается с большим разбросом, чем дешёвых.

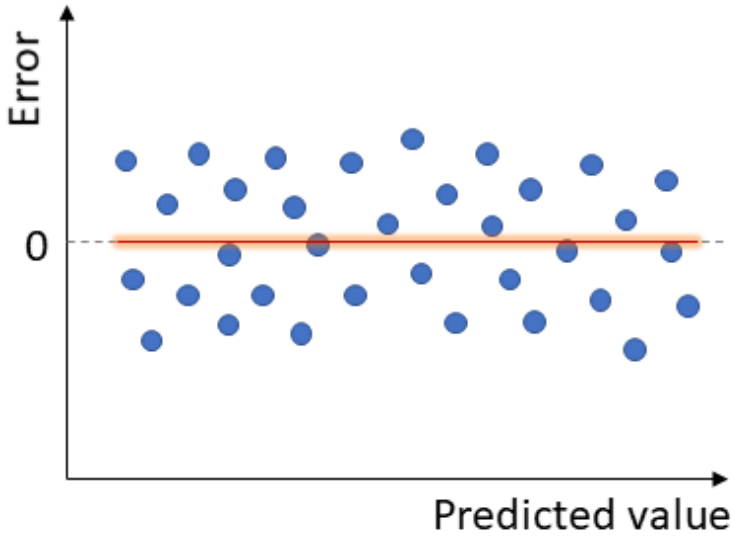
Модель может переобучаться на «шумные» области. Из-за этого она может хуже обобщаться, а коэффициенты становятся менее стабильными.

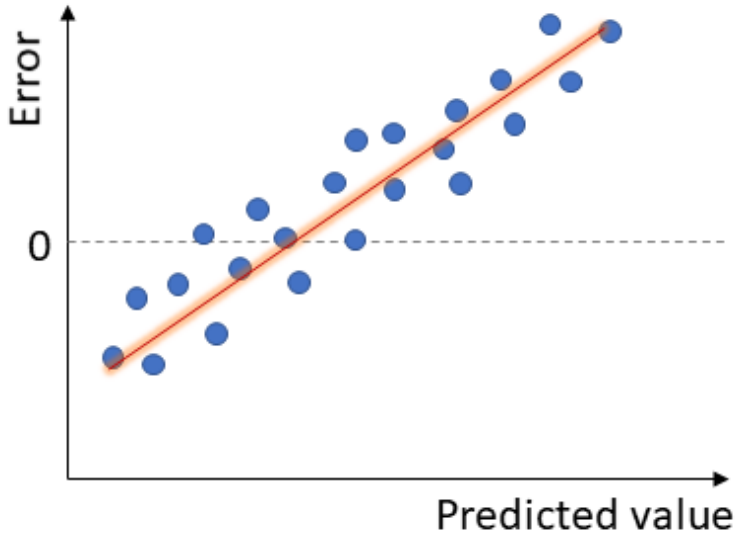
Гетероскедастичность

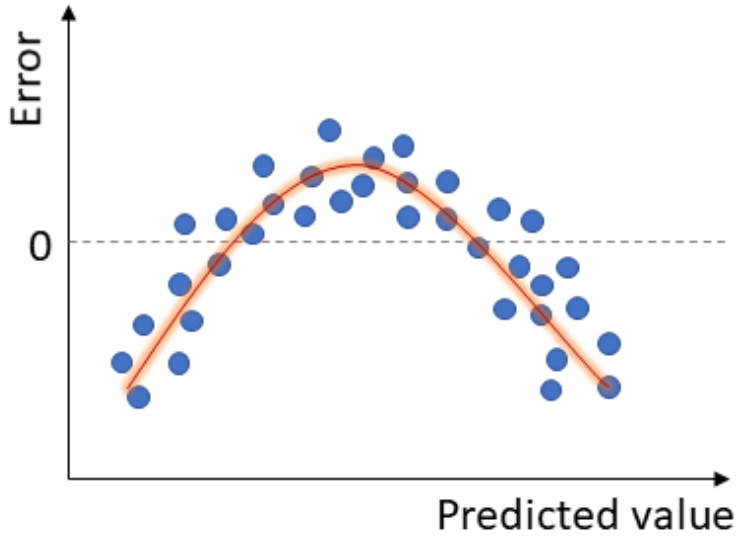




Гомоскедастичность

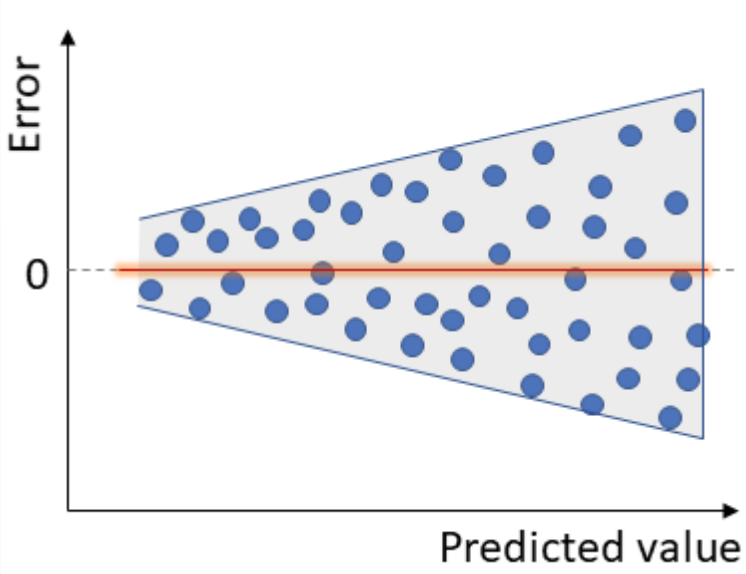


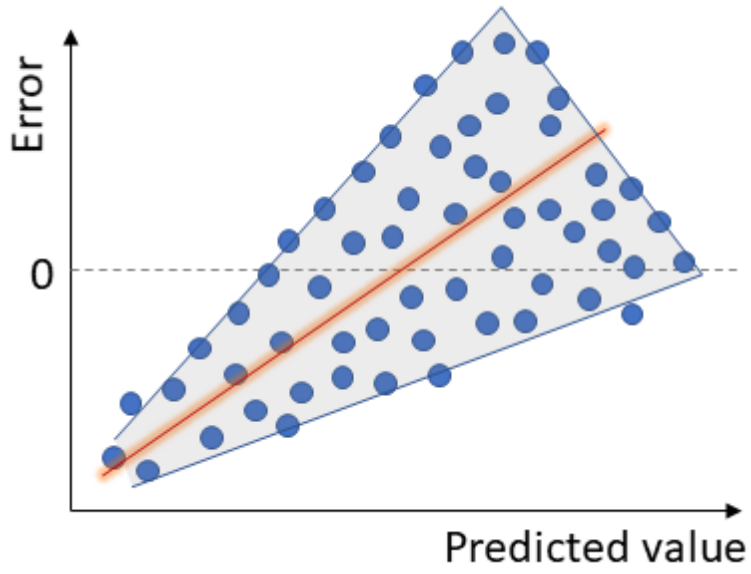


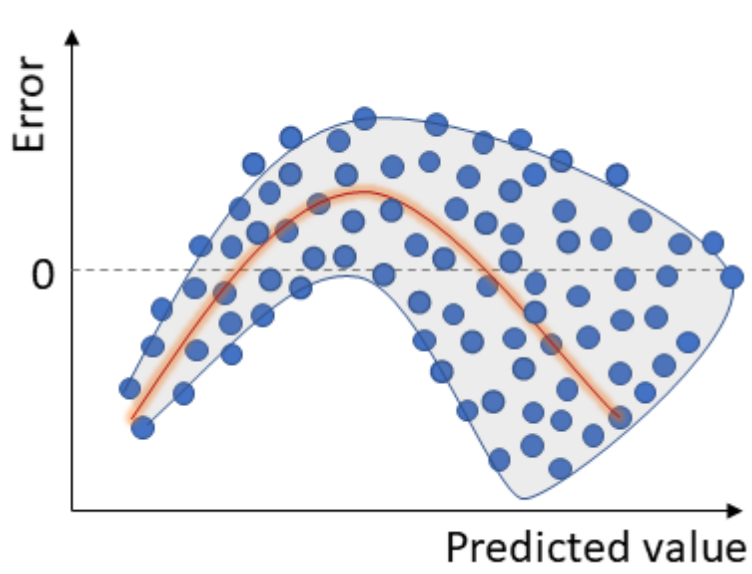


Гетероскедастичность

Можно выявить на диаграмме рассеяния между стандартизированными остатками и предсказанными значениями целевой переменной.







Тест на гетероскедастичность

Тест Бройша–Пагана (Breusch–Pagan test) проверяет, зависит ли дисперсия ошибок от предикторов.

Гипотезы:

H_0: гомоскедастичность (дисперсия постоянна)

H_1: гетероскедастичность

Строим модель регрессии, которая проверяет, объясняется ли квадрат остатков признаками. При гомоскедастичности такая регрессия не значима, ее коэффициенты и R^2 стремятся к нулю, то есть дисперсия ошибок не зависит от предикторов.

Остатки

Анализ остатков нужен для того, чтобы понять, как именно ошибается модель, и можно ли это исправить. Если модель хорошо отражает реальность, то остатки должны быть распределены нормально и разброс их значений должен быть примерно одинаков для всех предсказанных значений (гомоскедастичность). Они не должны коррелировать друг с другом (отсутствие автокорреляции).

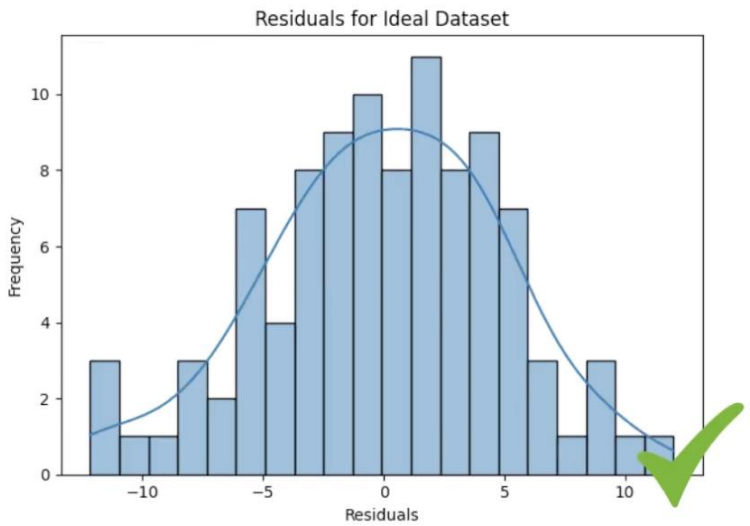
Если цель построения модели – только предсказание, то нормальность остатков не обязательна.

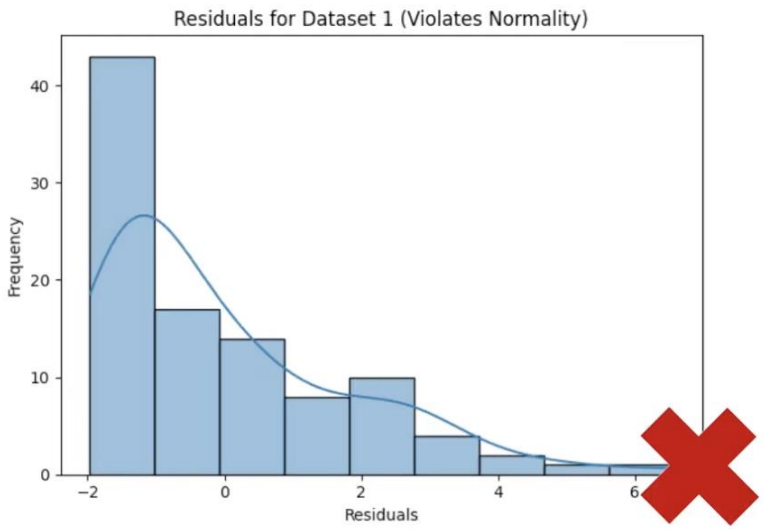
Если цель – статистический вывод, когда необходимо проверить статистическую значимость признаков, специфику их влияния на целевую переменную, то нормальность остатков важна.

При больших выборках распределение коэффициентов регрессии стремится к нормальному, даже если остатки распределены ненормально. Поэтому на выборках от сотен тысяч объектов и выше требование нормальности становится неважным.

Проверка нормальности остатков

- Q-Q Plot (Quantile-Quantile Plot)
- Гистограмма с кривой нормального распределения
- Статистические тесты (Шапиро-Уилка для малых выборок, Колмогорова-Смирнова для больших).





Метрики качества модели линейной регрессии

При оценке модели линейной регрессии важно понимать, насколько точно она предсказывает значения и насколько хорошо объясняет вариацию данных. Для этого используются метрики качества модели.

- R^2 (коэффициент детерминации): показывает какую долю дисперсии целевой переменной объясняет модель.
- Adjusted R^2 (скорректированный R^2): учитывает количество признаков в модели и размер выборки.
- MSE (Mean Squared Error): среднеквадратичная ошибка.
- RMSE (Root Mean Squared Error): корень из MSE.
- MAE (Mean Absolute Error): средняя абсолютная ошибка.
- MAPE (Mean Absolute Percentage Error): средняя абсолютная процентная ошибка.

Коэффициент детерминации

Коэффициент детерминации (R^2) – показывает насколько хорошо модель объясняет вариацию целевой переменной. Иначе говоря это доля дисперсии целевой переменной, объясненная моделью. Лежит в диапазоне от 0 до 1.

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}$$

Если в модели предсказания зарплаты $R^2 = 0.85$,значит модель объясняет 85% вариации зарплаты, а оставшиеся 15% вариации не объяснены. Можно попробовать улучшить модель добавив значимые признаки.

Скорректированный коэффициент детерминации

Скорректированный коэффициент детерминации (Adjusted R^2) учитывает размер выборки и штрафует модель за лишние признаки.

$$R^2_{adj} = 1 - (1 - R^2)\frac{(n-1)}{(n-k)} \leqslant R^2$$

где *n* - количество наблюдений, а *k* - количество признаков.

Может быть отрицательным, если модель очень плохая (хуже, чем просто среднее).

F-статистика

F-статистика используется в регрессионном анализе для проверки общей значимости модели. F-тест проверяет объясняет ли модель целевую переменную лучше, чем модель без предикторов (только с константой).

H_0 (нулевая гипотеза): все коэффициенты при признаках равны нулю

$$w_1 = w_2 = \ldots = w_k = 0$$

H_1 (альтернативная гипотеза): хотя бы один коэффициент ≠ 0

$$F = \frac{R^2/k}{(1-R^2)/(n-k-1)}$$

k – число признаков; n – число наблюдений

$p < 0.05 \rightarrow$ модель значима

$p \geq 0.05 \rightarrow$ нет оснований отвергнуть H_0

Среднеквадратичная ошибка (Mean Squared Error)

Применяется, когда важно сильнее штрафовать большие ошибки. Благодаря возведению ошибки в квадрат большие отклонения вносят непропорционально большой вклад в значение метрики.

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2,$$

где n — количество наблюдений,

y_i - фактическое значение целевой переменной для i-го наблюдения,

$\hat{y}_i$ - предсказанное моделью значение целевой переменной.

Корень из среднеквадратичной ошибки (Root Mean Squared Error)

RMSE также штрафует за большие ошибки, но в отличие от MSE, масштаб ошибки аналогичен исходным данным, что облегчает интерпретацию. Это делает RMSE хорошим выбором для многих практических задач, где важна интерпретируемость результата.

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

Средняя абсолютная ошибка (Mean Absolute Error)

Рассчитывается как среднее абсолютных разностей между фактическими и предсказанными значениями целевой переменной. Лучше применять, когда в данных есть выбросы и не требуется усиленное наказание за большие ошибки.

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

где n - количество наблюдений,

y_i - фактическое значение целевой переменной для i-го наблюдения,

$\hat{y}_i$ - предсказанное моделью значение целевой переменной.

Средняя абсолютная процентная ошибка (Mean Absolute Percentage Error)

Применяют для оценки средней относительной ошибки модели в процентах. Метрика позволяет сравнивать модели, построенные на данных разного масштаба, но не подходит при наличии нулевых или близких к нулю фактических значений.

$$MAPE = \frac{100\%}{n} \sum_{i=1}^{n} \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

MAPE	Качество прогноза
< 10%	Очень хороший
10–20%	Хороший
20–50%	Удовлетворительный
> 50%	Низкое качество

Информационный критерий Акаике

Информационный критерий Акаике (AIC) – это метрика выбора модели, которая оценивает баланс между качеством подгонки и сложностью модели. Часто используется для выбора лучшей линейной регрессии среди нескольких вариантов (с разным числом признаков).

$$AIC = n \ln\left(\frac{RSS}{n}\right) + 2k$$

n – число наблюдений; RSS – сумма квадратов остатков; k – число признаков

Чем меньше AIC, тем лучше модель. AIC сравнивают только между моделями на одних и тех же данных. Само по себе значение AIC ничего не означает – важна разница.

Если разница ΔAIC между моделями:

< 2 – модели примерно равны >10 – модель с большим AIC значительно хуже

Предикторы линейной регрессии

Предикторы (независимые переменные) – это признаки, которые количественно объясняют или прогнозируют целевую переменную.

- Числовые предикторы
  - Непрерывные: возраст, доход, время;
  - Дискретные (счётные): количество детей, число посещений.
- Категориальные предикторы
  - Бинарные: 0/1, да/нет, мужчина/женщина;
  - Номинальные (без порядка) → кодируются через one-hot encoding, превращаются в фиктивные (dummy) переменные;
  - Порядковые (ordinal) → кодируются через ordinal encoding. Можно применять когда категории действительно имеют количественный порядок и примерно равные “шаги” между уровнями. Если это не так, то используем one-hot encoding

Добавление категориальных признаков в модель

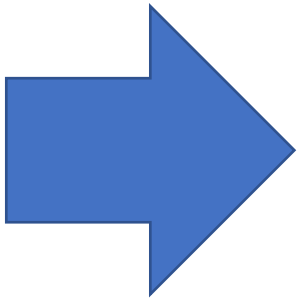
Создание и добавление дамми-переменных (dummy variables) – стандартный способ включить категориальные признаки в регрессионную модель. Дамми-переменные – это бинарные (0/1) переменные, которые кодируют категории.

Важно: в регрессии используют k–1 переменную, чтобы избежать мультиколлинеарности. Если категорий k, создаётся и добавляется в модель k – 1 дамми-переменных. Не создаётся отдельная переменная для «базовой» или «референтной» категории, т.е. категории, с которой будет происходить сравнение остальных категорий. Эта может быть любая категория. Если нет предпочтений, то можно выбрать в качестве референтной категорию с самым частым упоминанием.

Создание дамми-переменных

Исходная переменная «уровень образования» принимает следующие значения: нет (1), среднее (2), высшее (3), послевузовское (4). Можно выбрать высшее образование как референтную категорию.

Уровень образования
Высшее
Нет
Среднее
Послевузовское
Высшее
Среднее



Ed1_no	Ed2_mid	Ed3_post
0	0	0
1	0	0
0	1	0
0	0	1
0	0	0
0	1	0

Модель с дамми-переменными

Целевая переменная: зарплата (Y)

Предиктор: уровень образования, представленный дамми-переменными:

D_no = 1, если нет образования, 0 иначе

D_mid = 1, если среднее образование, 0 иначе

D_post = 1, если послевузовское образование, 0 иначе

Базовая (референтная) категория: высшее образование

Модель линейной регрессии:

$$Y_i = \beta_0 + \beta_1 D_{no} + \beta_2 D_{mid} + \beta_3 D_{post} + \varepsilon_i$$

Коэффициенты при дамми-переменных

$$Y_i = \beta_0 + \beta_1 D_{no} + \beta_2 D_{mid} + \beta_3 D_{post} + \varepsilon_i$$

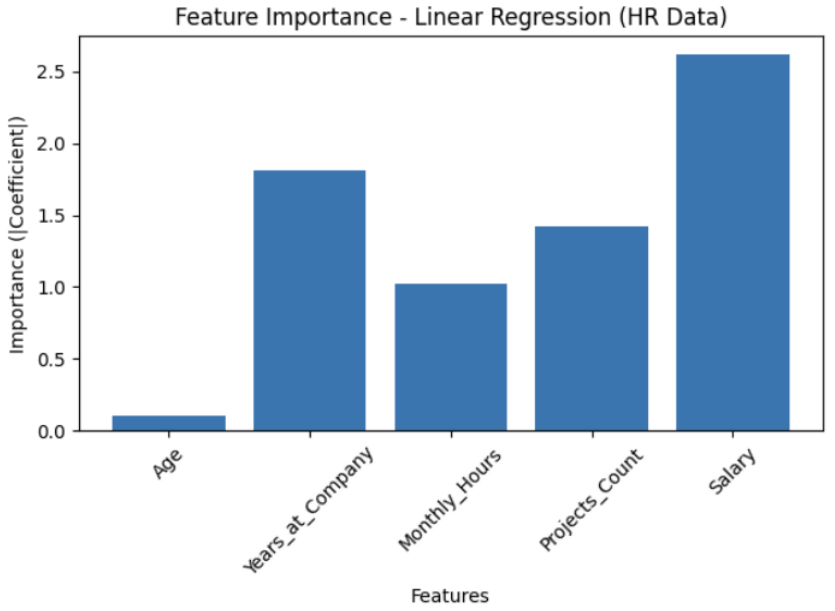
β_0 – средняя зарплата людей с высшим образованием;
β_1 – разница средней зарплаты между людьми без образования и людьми с высшим образованием;
β_2 – разница средней зарплаты между людьми со средним образованием и людьми с высшим образованием;
β_3 – разница средней зарплаты между людьми с послевузовским образованием и людьми с высшим образованием.

- Если коэффициент при дамми-переменной незначимый или близок к нулю, то нет отличий между зарплатами в сравниваемых группах.
- Если $\beta_1 < 0$,значит зарплата у людей без образования в среднем ниже, чем у людей с высшим образованием.
- Если хотим сравнить другие зарплатные группы между собой, то надо менять референтную категорию.

Важность признаков

Важность признаков определяется тем, насколько сильно каждый признак влияет на целевую переменную. Есть несколько способов это посчитать в зависимости от того, что именно понимать под «важностью».

1. **По коэффициентам модели**. Предварительно коэффициенты нужно стандартизировать. Тогда их можно сравнивать по модулю.
2. **Через вклад в R^2**. Можно оценить насколько снижается R^2 при удалении признака. Это показывает вклад признака в объяснение дисперсии.
3. **Через регуляризацию**. Важность можно оценивать по величине коэффициентов после регуляризации.



Эффект взаимодействия

Эффект взаимодействия (interaction effect) в линейной регрессии позволяет учитывать ситуации, когда влияние одного предиктора на целевую переменную зависит от значения другого предиктора. Это способ моделировать не просто сумму эффектов отдельных факторов, а их совместное влияние. Если есть эффект взаимодействия, модель дополняется произведением предикторов:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 (X_1 \cdot X_2) + \varepsilon$$

β_3 отражает силу и направление взаимодействия. Если $\beta_3 \neq 0$,значит эффект X_1 на Y зависит от значения X_2 ,и наоборот.

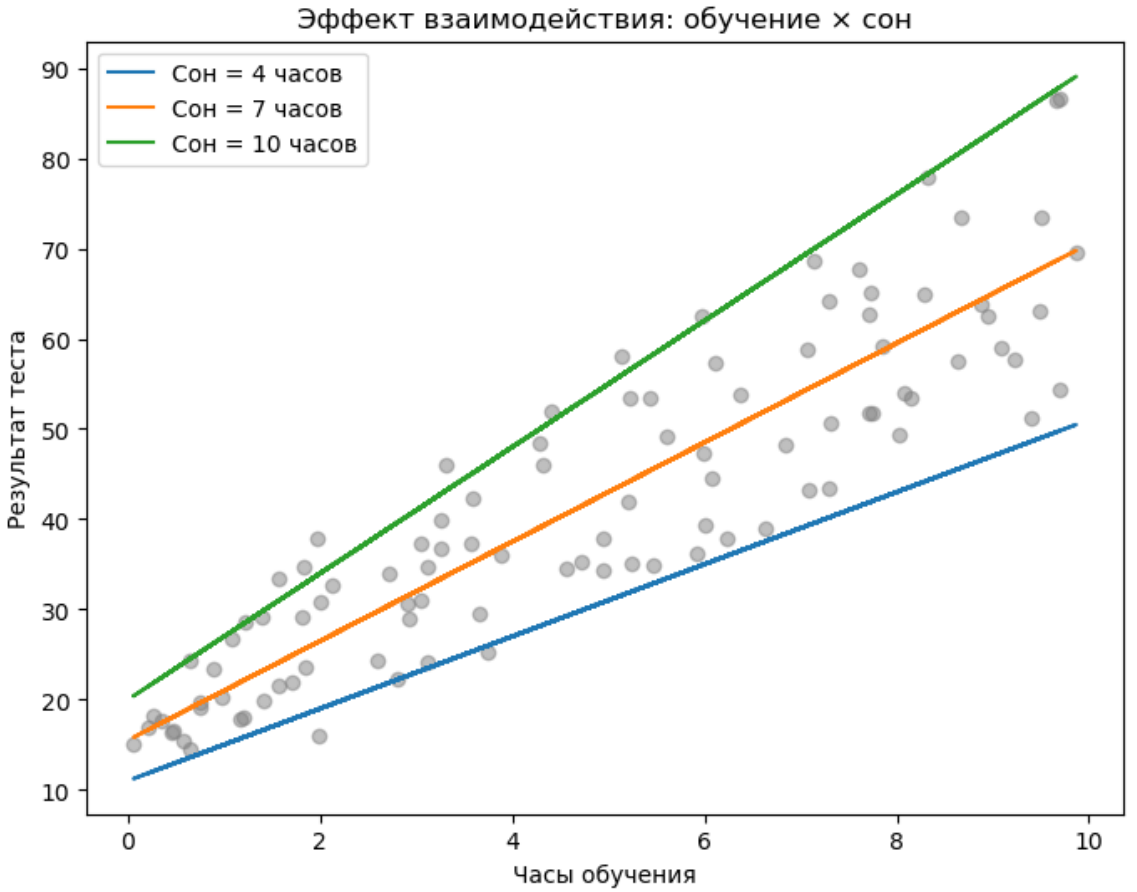
Добавлять в модель стоит только значимые взаимодействия.

Эффект взаимодействия

Исследуем как количество часов обучения (X_1) и количество часов сна (X_2) влияют на результат теста (Y):

- Без взаимодействия: каждый дополнительный час обучения увеличивает баллы за тест на β_1 , независимо от сна.
- С взаимодействием: влияние часов обучения на балл может быть сильнее, если человек хорошо выспался и слабее, если человек устал.

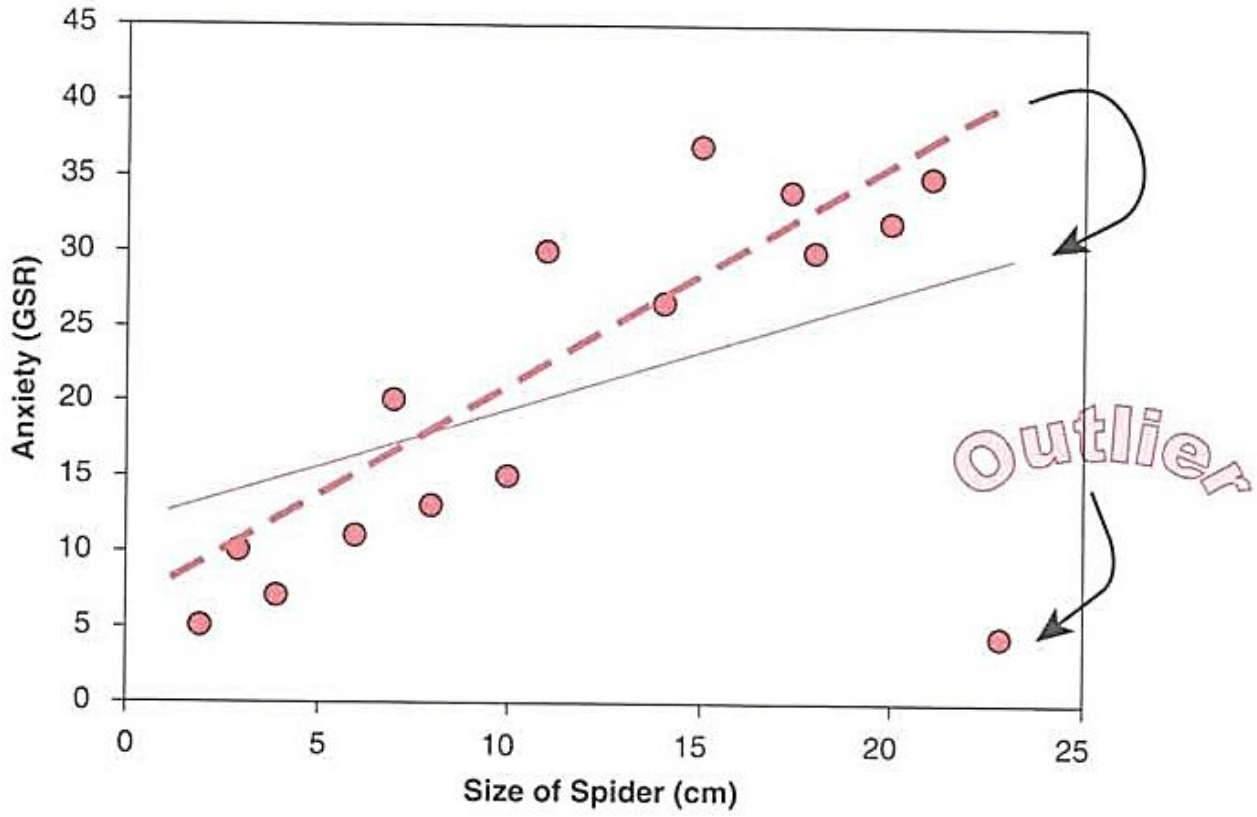
На рисунке чем больше часов сна, тем сильнее влияние часов обучения на результаты теста.



Выбросы и влияющие наблюдения

Выбросы и влияющие наблюдения выявляют потому, что они могут существенно искажать результаты линейной регрессии: менять оценки коэффициентов, их значимость, качество прогнозов и выводы исследования в целом. Поскольку метод наименьших квадратов особенно чувствителен к экстремальным значениям, одна-две нетипичные точки способны перетянуть линию регрессии и создать ложную интерпретацию связи между признаками. После обнаружения таких наблюдений сначала проверяют корректность данных (нет ли ошибки измерения или ввода), затем анализируют их природу – являются ли они случайной аномалией или отражают важную особенность изучаемой совокупности. В зависимости от результата наблюдение можно удалить (если это ошибка), оставить с обоснованием, оценить модель с и без неё для сравнения, либо изменить спецификацию модели.

Выбросы



Выброс (outlier) – это наблюдение с большим остатком, то есть его фактическое значение сильно отличается от предсказанного моделью.

Они могут оказывать влияние на модель, приводить к необъективным оценкам параметров и низкой эффективности прогнозирования.

Выявление выбросов

Рассчитываются стандартные остатки (Standardized Residuals):

$$r_i = \frac{e_i}{\hat{\sigma}_e}$$

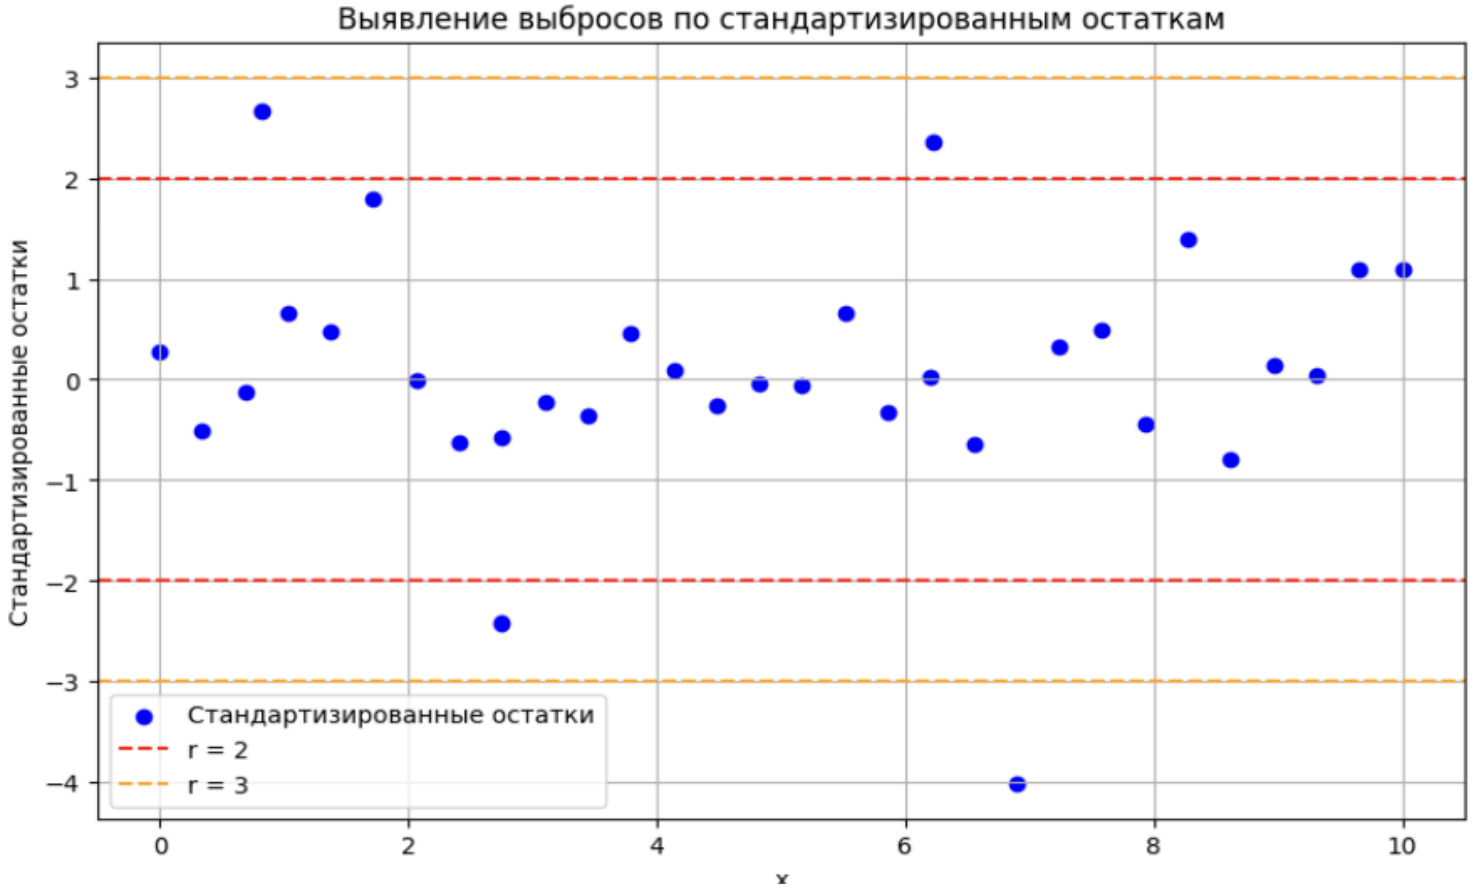
где $\hat{\sigma}_e$ – стандартное отклонение остатков.
Используется правило "2 или 3 сигм":
$|r_i| > 2 \rightarrow$ потенциальный выброс;
$|r_i| > 3 \rightarrow$ сильный выброс.

Эти границы соответствуют «правилу 68-95-99.7» из нормального распределения:

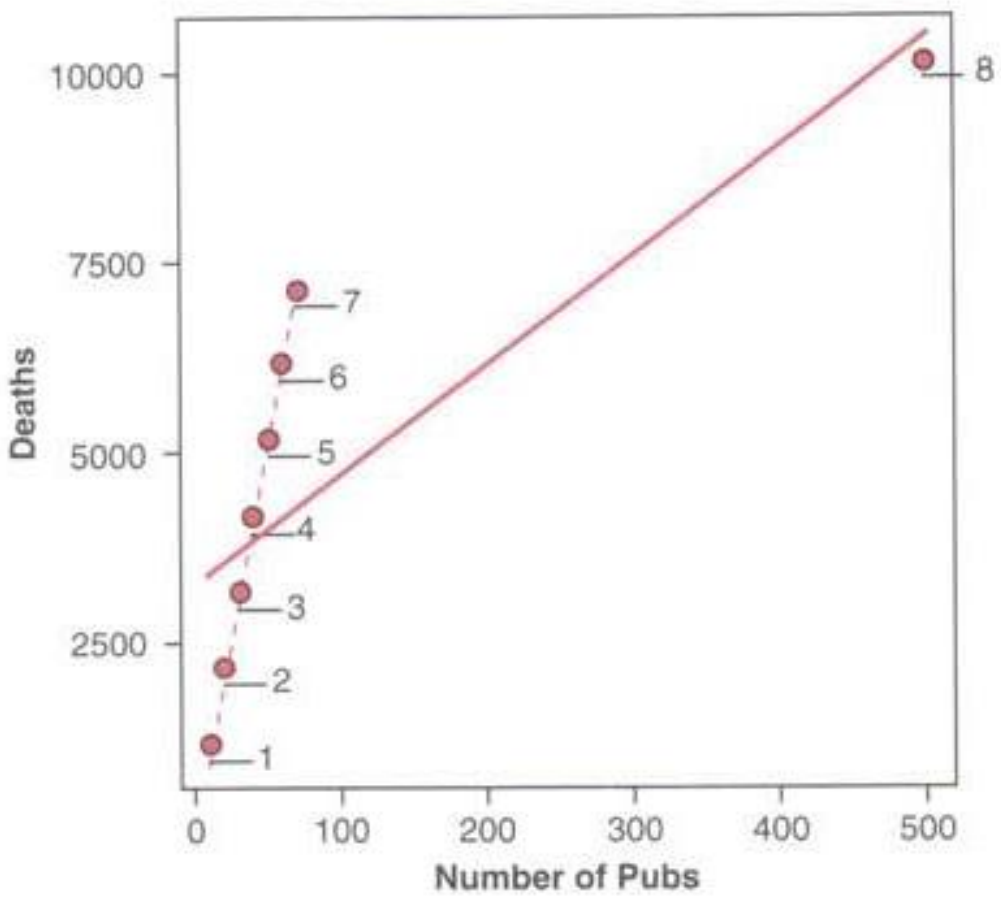
~68% данных внутри 1σ
~95% данных внутри 2σ
~99.7% данных внутри 3σ

То есть, если остатки нормально распределены, выборка за пределами ±3σ встречается крайне редко → сигнал о наличии выброса.

Выявление выбросов



Влияющие наблюдения



Влияющее наблюдение (influential point) – наблюдение, существенно изменяющее параметры модели или результаты предсказания. Его не всегда можно определить по большим остаткам, потому что наблюдение может «перетянуть» линию регрессии под себя. Для его обнаружения используют специальные меры влияния, например, расстояние Кука, DFBETAS или DFFITS.

Выявление влияющих наблюдений: рычаг

Рычаг (Leverage) – мера влияния объекта на регрессию из-за его местоположения в пространстве признаков. Проще говоря, насколько точка необычна по своим значениям признаков. Она может изменять линию регрессии, даже если её значение Y не сильно выбивается.

$$h_i = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{\sum_{j=1}^{n}(x_j - \bar{x})^2}$$

Чем дальше x_i от среднего $\bar{x}$,тем больше h_i.

Leverage высокий → точка необычна по X → может сильно менять линию регрессии.

Высокий leverage ≠ влиятельная точка, это только предупреждение.

Выявление влияющих наблюдений: дистанция Кука

Cook’s Distance – это мера того, насколько удаление наблюдения изменяет коэффициенты регрессии. Сочетает в себе рычаг и остаток.

$$D_i = \frac{r_i^2 \cdot h_i}{p(1 - h_i)^2}$$

r_i – стандартизированный остаток

h_i – рычаг

p – число коэффициентов (включая константу)

D_i > 1 → сильное влияние

D_i > 4/n → потенциальное влияние

Выявление влияющих наблюдений: DFFITS и DFBETAS

DFFITS показывает на сколько изменится предсказанное значение $\hat{y}_i$,если удалить точку.

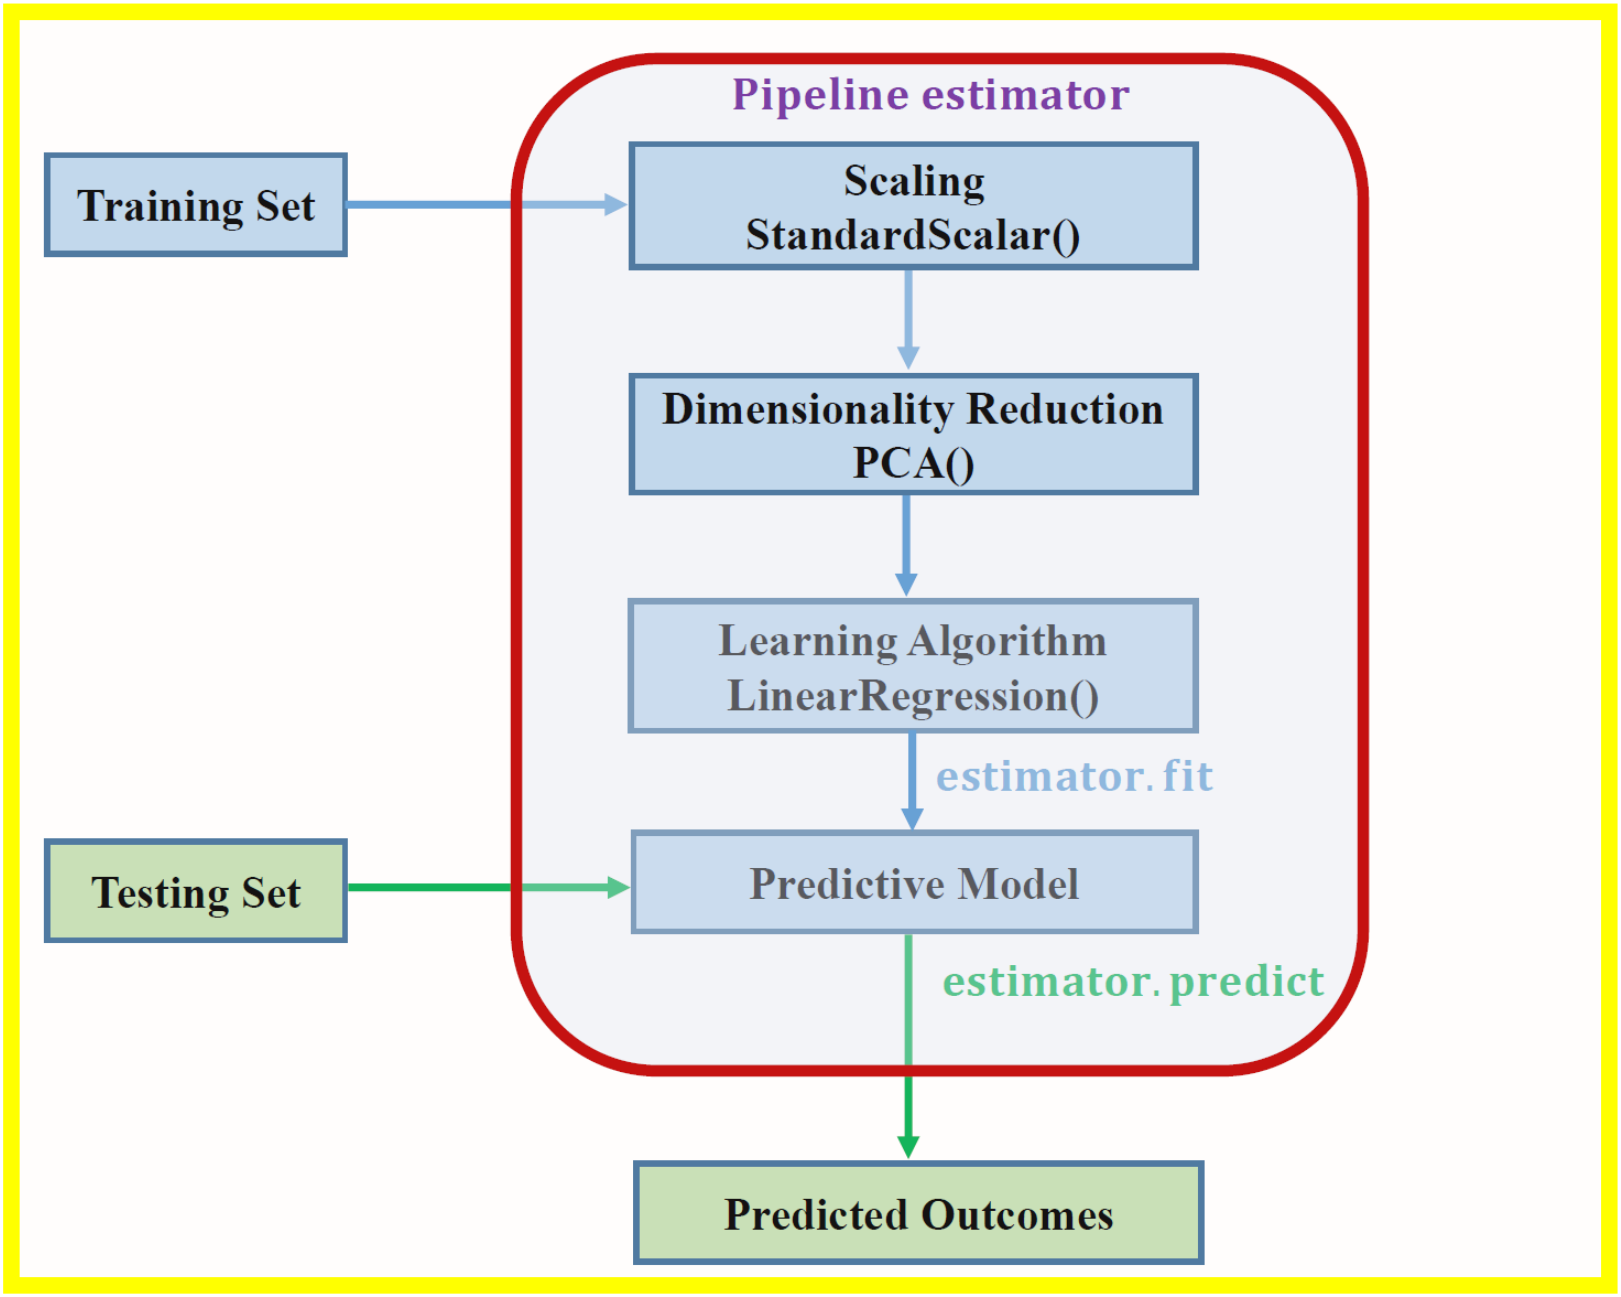
$$| DFFITS_i | > 2\sqrt{\frac{p}{n}}$$

p – число коэффициентов (включая константу); n – размер выборки.
Превышение значения → точка потенциально влияющая

DFBETAS показывает насколько изменение точки влияет на конкретный коэффициент β_j.

$$| DFBETAS_{ij} | > \frac{2}{\sqrt{n}}$$

n – размер выборки; j – номер коэффициента
Превышение значения → точка заметно меняет конкретный коэффициент.


Pipeline estimator
Training Set
Scaling
StandardScalar()
Dimensionality Reduction
PCA()
Learning Algorithm
LinearRegression()
estimator. fit
Testing Set
Predictive Model
estimator. predict
Predicted Outcomes

Конвейер (Pipeline) обучения модели линейной регрессии

1. Предобработка данных и инженерия признаков.
2. Разделение данных на обучающую и тестовую выборки.
3. Проведения кросс-валидации с усреднением метрик по фолдам.
4. Финальное обучение модели на всей обучающей выборке.
5. Оценка качества модели на отложенной тестовой выборке.
6. Интерпретация результатов.

Библиотеки для линейной регрессии в Python

scikit-learn ориентирована на предсказание и production-модели. Строит линейную регрессию и модели с регуляризацией. Удобная интеграция с кросс-валидацией, пайплайнами, GridSearch. При этом меньше инструментов для эконометрического анализа и нет автоматического статистического отчёта. Используем когда важнее точность прогноза, чем интерпретация.

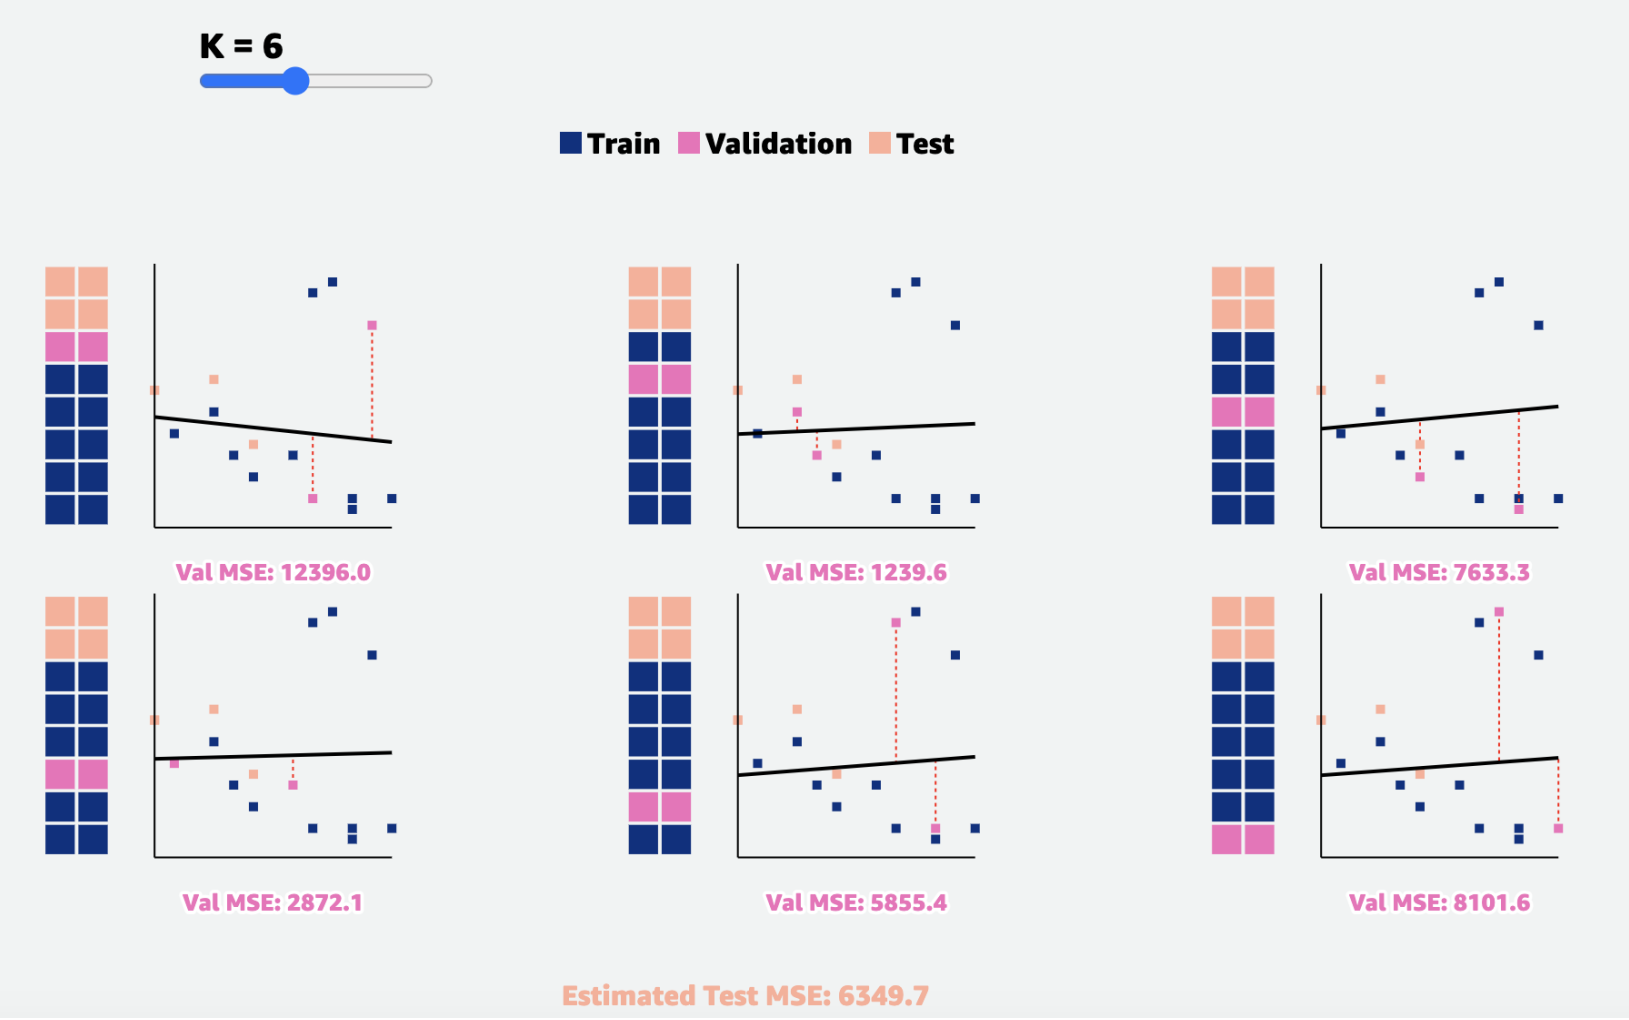
Statsmodels больше подходит для статистического анализа и эконометрики. Ориентирована на интерпретацию модели. После обучения выдаёт полноценный отчёт. Подходит для научных исследований и аналитики с объяснением факторов.

Часто в реальной работе используют оба подхода:

Statsmodels → для анализа значимости факторов;

scikit-learn → для финальной ML-модели.

Кросс-валидация



Кросс-валидация

Кросс-валидация позволяет сравнить спецификации модели. Итоговая метрика – среднее значение ошибок моделей в разных фолдах.

Высокая средняя ошибка → надо корректировать модель или данные.

Ошибки сильно отличаются между фолдами → модель нестабильна, чувствительна к конкретным подвыборкам.

На основе кросс-валидации можно принимать решения:

- Линейная регрессия без регуляризации или Ridge/Lasso;
- Выбор признаков, трансформация данных;
- Разные степени полиномиальной регрессии и пр.

Выбираем модель с наименьшей среднеквадратичной ошибкой и приемлемой стабильностью.

OLS Regression Results

Dep. Variable:	Salary	R-squared:	0.636
Model:	OLS	Adj. R-squared:	0.635
Method:	Least Squares	F-statistic:	522.7
Date:	Thu, 05 Mar 2026	Prob (F-statistic):	0.00
Time:	11:46:58	Log-Likelihood:	-16531.
No. Observations:	1500	AIC	3.307e+04
Df Residuals:	1494	BIC	3.311e+04
Df Model:	5		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
const	2.543e+04	2141.712	11.873	0.000	2.12e+04	2.96e+04
Gender	8895.4558	766.853	11.600	0.000	7391.232	1.04e+04
Experience	4048.3095	100.222	40.394	0.000	3851.719	4244.900
Education	1.517e+04	850.689	17.836	0.000	1.35e+04	1.68e+04
Performance	1.09e+04	497.866	21.895	0.000	9924.383	1.19e+04
OfficePlants	89.4962	231.472	0.387	0.699	-364.548	543.540

Omnibus:	1.454	Durbin-Watson:	2.062
Prob(Omnibus):	0.483	Jarque-Bera (JB):	1.433
Skew:	0.076	Prob(JB):	0.488
Kurtosis:	3.001	Cond. No.	52.9

Коэффициент детерминации – модель объясняет 64% вариации значений целевой переменной

OLS Regression Results

Dep. Variable:	Salary	R-squared:	0.636
Model:	OLS	Adj. R-squared:	0.635
Method:	Least Squares	F-statistic:	522.7
Date:	Thu, 05 Mar 2026	Prob (F-statistic):	0.00
Time:	11:46:58	Log-Likelihood:	-16531.
No. Observations:	1500	AIC:	3.307e+04
Df Residuals:	1494	BIC:	3.311e+04
Df Model:	5		
Covariance Type:	nonrobust		

	coef	std err	t	P>	975]
const	2.543e+04	2141.712	11.873	0.000	2.12e+04 2.96e+04
Gender	8895.4558	766.853	11.600	0.000	7391.232 1.04e+04
Experience	4048.3095	100.222	40.394	0.000	3851.719 4244.900
Education	1.517e+04	850.689	17.836	0.000	1.35e+04 1.68e+04
Performance	1.09e+04	497.866	21.895	0.000	9924.383 1.19e+04
OfficePlants	89.4962	231.472	0.387	0.699	-364.548 543.540

Omnibus:	1.454	Durbin-Watson:	2.062
Prob(Omnibus):	0.483	Jarque-Bera (JB):	1.433
Skew:	0.076	Prob(JB):	0.488
Kurtosis:	3.001	Cond. No.	52.9

Модель статистически значима

Константа – значение целевой переменной, когда все предикторы равны нулю

OLS Regression Results

Dep. Variable:	Salary	R-squared:	0.636
Model:	OLS	Adj. R-squared:	0.635
Method:	Least Squares	F-statistic:	522.7
[illegible]	Thu, 05 Mar 2026	Prob (F-statistic):	0.00
	11:46:58	Log-Likelihood:	-16531.
	1500	AIC:	3.307e+04
	1494	BIC:	3.311e+04
	5		
	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
const	2.543e+04	2141.712	11.873	0.000	2.12e+04	2.96e+04
Gender	8895.4558	766.853	11.600	0.000	7391.232	1.04e+04
Experience	4048.3095	100.222	40.394	0.000	3851.719	4244.900
Education	1.517e+04	850.689	17.836	0.000	1.35e+04	1.68e+04
Performance	1.09e+04	497.866	21.895	0.000	9924.383	1.19e+04
OfficePlants	89.4962	231.472	0.387	0.699	-364.548	543.540

Omnibus:	1.454	Durbin-Watson:	2.062
Prob(Omnibus):	0.483	Jarque-Bera (JB):	1.433
Skew:	0.076	Prob(JB):	0.488
Kurtosis:	3.001	Cond. No.	52.9

OLS Regression Results

Dep. Variable:	Salary	R-squared:	0.636
Model:	OLS	Adj. R-squared:	0.635
Method:	Least Squares	F-statistic:	522.7
Date:	Thu, 05 Mar 2026	Prob (F-statistic):	0.00
Time:	11:46:58	Log-Likelihood:	-16531.
No. Observations:	1500	AIC:	3.307e+04
	1494	BIC:	3.311e+04
	5		
	obust		

		rr	t	P>|t|	[0.025	0.975]
const	2.543e+04	2141.712	11.873	0.000	2.12e+04	2.96e+04
Gender	8895.4558	766.853	11.600	0.000	7391.232	1.04e+04
Experience	4048.3095	100.222	40.394	0.000	3851.719	4244.900
Education	1.517e+04	850.689	17.836	0.000	1.35e+04	1.68e+04
Performance	1.09e+04	497.866	21.895	0.000	9924.383	1.19e+04
OfficePlants	89.4962	231.472	0.387	0.699	-364.548	543.540

Omnibus:	1.454	Durbin-Watson:	2.062
Prob(Omnibus):	0.483	Jarque-Bera (JB):	1.433
Skew:	0.076	Prob(JB):	0.488
Kurtosis:	3.001	Cond. No.	52.9

Коэффициент при переменной означает, что увеличение её значения на единицу приведёт к росту значения зависимой переменной на 4048,3 единиц

OLS Regression Results

Dep. Variable:	Salary	R-squared:	0.636
Model:	OLS	Adj. R-squared:	0.635
	Least Squares	F-statistic:	522.7
	, 05 Mar 2026	Prob (F-statistic):	0.00
	11:46:58	Log-Likelihood:	-16531.
	1500	AIC:	3.307e+04
	1494	BIC:	3.311e+04
	5		
Covariance Type:	non		

	coef	std e				
const	2.543e+04	2141.				
Gender	8895.4558	766.853	11.600	0.000	7391.232	1.04e+04
Experience	4048.3095	100.222	40.394	0.000	3851.719	4244.900
Education	1.517e+04	850.689	17.836	0.000	1.35e+04	1.68e+04
Performance	1.09e+04	497.866	21.895	0.000	9924.383	1.19e+04
OfficePlants	89.4962	231.472	0.387	0.699	-364.548	543.540

Omnibus:	1.454	Durbin-Watson:	2.062
Prob(Omnibus):	0.483	Jarque-Bera (JB):	1.433
Skew:	0.076	Prob(JB):	0.488
Kurtosis:	3.001	Cond. No.	52.9

Коэффициенты регрессионной модели, на их основе формируется уравнение регрессии.

Уравнение регрессии: Salary = 25430 + 8895,5*Gender + 4048,3*Experience + 15170*Education + 10900*Performance + 89,5*OfficePlants

OLS Regression Results

Dep. Variable:	Salary	R-squared:	0.636
Model:	OLS	Adj. R-squared:	0.635
Method:	Least Squares	F-statistic:	522.7
Date:	Thu, 05 Mar 2026	Prob (F-statistic):	0.00
	6:58	Log-Likelihood:	-16531.
	1500	AIC:	3.307e+04
	1494	BIC:	3.311e+04
	5		
	bust		

Стандартная ошибка коэффициента регрессии показывает, насколько сильно оценка коэффициента может колебаться от выборки к выборке.

$$s(b_1) = \sqrt{\frac{1}{n-2} * \frac{\sum (y_i - \hat{y}_i)^2}{\sum (x_i - \bar{x})^2}}$$

	coef	std err				75]
const	2.543e+04	2141.712	11.87			+04
Gender	8895.4558	766.853	11.600	0.000	7391.232	1.04e+04
Experience	4048.3095	100.222	40.394	0.000	3851.719	4244.900
Education	1.517e+04	850.689	17.836	0.000	1.35e+04	1.68e+04
Performance	1.09e+04	497.866	21.895	0.000	9924.383	1.19e+04
OfficePlants	89.4962	231.472	0.387	0.699	-364.548	543.540

Omnibus:	1.454	Durbin-Watson:	2.062
Prob(Omnibus):	0.483	Jarque-Bera (JB):	1.433
Skew:	0.076	Prob(JB):	0.488
Kurtosis:	3.001	Cond. No.	52.9

OLS Regression Results

Dep. Variable:	Salary	R-squared:	0.636
Model:	OLS	Adj. R-squared:	0.635
Method:	Least Squares	F-statistic:	522.7
Date:	Thu, 05 Mar 2026	Prob (F-statistic):	0.00
Time:		:	-16531.
No. Observations:			3.307e+04
Df Residuals:			3.311e+04
Df Model:			
Covariance Type:			

Статистическая значимость коэффициентов регрессии (один не значим)

	coef	s	t|	[0.025	0.975]
const	2.543e+04	2141.712	11.873	0.000	2.12e+04	2.96e+04
Gender	8895.4558	766.853	11.600	0.000	7391.232	1.04e+04
Experience	4048.3095	100.222	40.394	0.000	3851.719	4244.900
Education	1.517e+04	850.689	17.836	0.000	1.35e+04	1.68e+04
Performance	1.09e+04	497.866	21.895	0.000	9924.383	1.19e+04
OfficePlants	89.4962	231.472	0.387	0.699	-364.548	543.540

Omnibus:	1.454	Durbin-Watson:	2.062
Prob(Omnibus):	0.483	Jarque-Bera (JB):	1.433
Skew:	0.076	Prob(JB):	0.488
Kurtosis:	3.001	Cond. No.	52.9

OLS Regression Results

Dep. Variable:	Salary	R-squared:	0.636
Model:	OLS	Adj. R-squared:	0.635
Method:	Least Squares	F-statistic:	522.7
Date:	Thu, 05 Mar 2026	Prob (F-statistic):	0.00
Time:	11:46:58	Log-Likelihood:	-16531.
No. Observations:	1500	AIC:	3.307e+04
Df Residuals:	1494	BIC:	3.311e+04
Df Model:	5		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
cons			873	0.000	2.12e+04	2.96e+04
Gend			600	0.000	7391.232	1.04e+04
Expe			394	0.000	3851.719	4244.900
Educ			836	0.000	1.35e+04	1.68e+04
Performance	1.09e+04	497.866	21.895	0.000	9924.383	1.19e+04
OfficePlants	89.4962	231.472	0.387	0.699	-364.548	543.540

Omnibus:	1.454	Durbin-Watson:	2.062
Prob(Omnibus):	0.483	Jarque-Bera (JB):	1.433
Skew:	0.076	Prob(JB):	0.488
Kurtosis:	3.001	Cond. No.	52.9

Тест на нормальность остатков, их распределение не отличается от нормального

Спасибо за внимание!