

Факультет компьютерных наук | Машинное обучение | Москва 2026

Лекция 7.1.
Полиномиальная регрессия и регуляризация

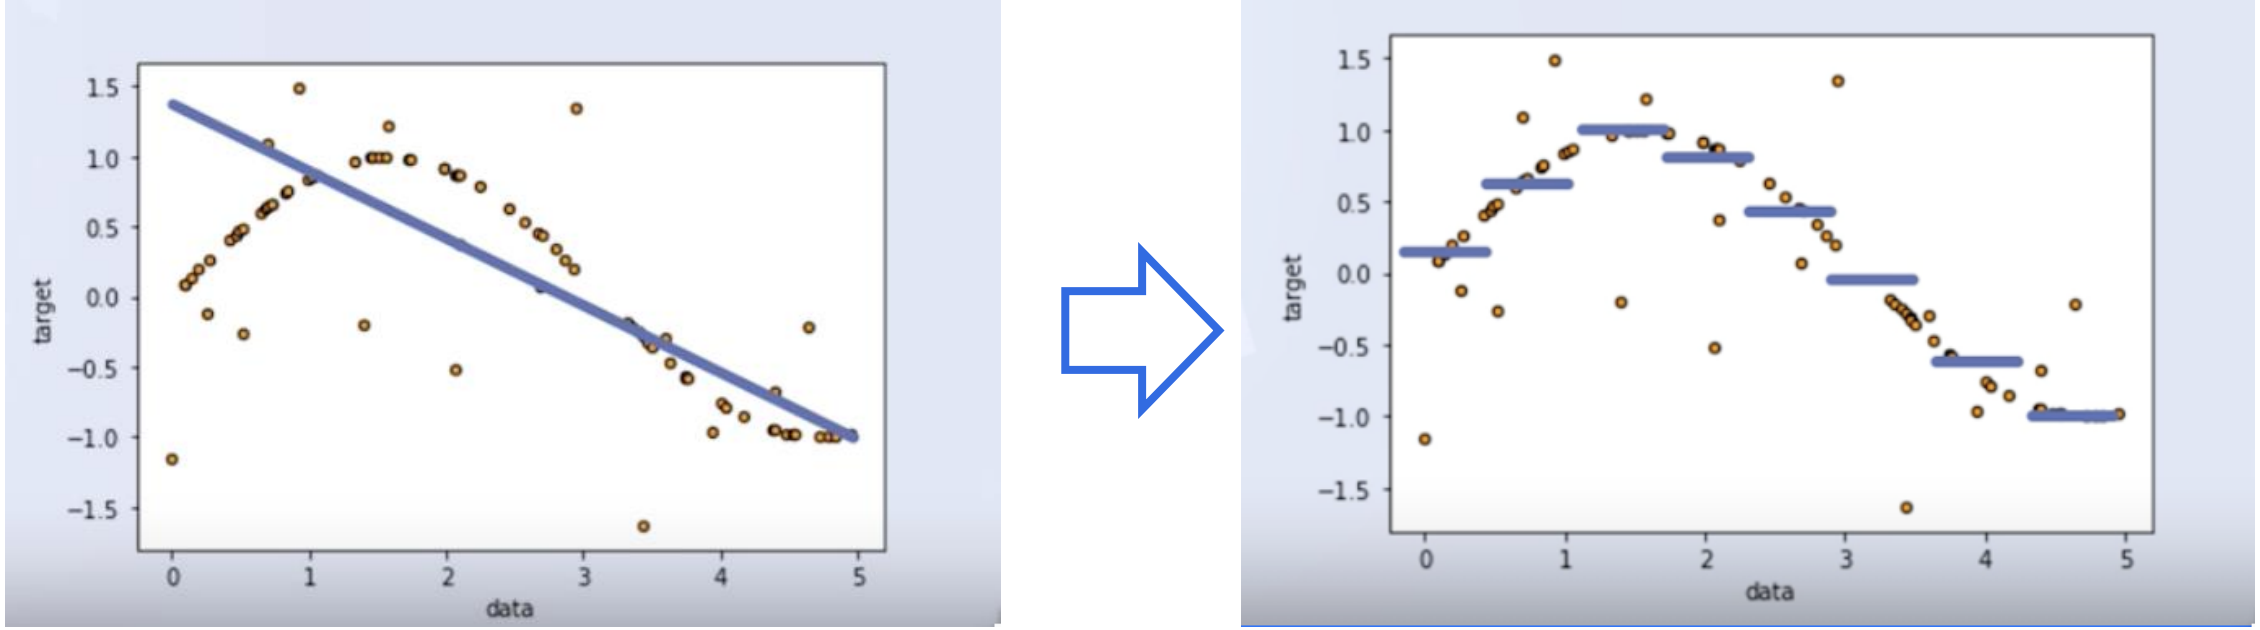
Преподаватель: Меликян Алиса Валерьевна, amelikyan@hse.ru
кандидат наук, доцент Департамента программной инженерии ФКН НИУ ВШЭ

Полиномиальная регрессия

Полиномиальная регрессия – это расширение линейной регрессии, позволяющее моделировать нелинейные зависимости между признаками и целевой переменной за счёт добавления полиномиальных признаков (например, x^2, x^3 и т.д.). Несмотря на то что модель остаётся линейной по параметрам, она способна аппроксимировать сложные кривые и выявлять более гибкие закономерности в данных. Однако с увеличением степени полинома резко возрастает риск переобучения: модель начинает подстраиваться под шум, теряя способность к обобщению на новых данных. Именно поэтому на практике полиномиальная регрессия часто используется в сочетании с методами регуляризации, которые помогают найти баланс между точностью и устойчивостью, контролируя сложность модели.

Нелинейные зависимости

Один из вариантов моделирования нелинейной зависимости – бинаризация числовых признаков, то есть разбиение числовой переменной на интервалы и замена её набором фиктивных (dummy) переменных. Но при этом теряется информация о порядке внутри интервала, а при большом числе интервалов растет размерность модели.



Полиномиальная модель

Полиномиальная модель использует многочлены степени n, чтобы аппроксимировать нелинейные зависимости без явного задания формы функции. Может быть записана как:

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \cdots + \beta_n x^n + \varepsilon$$

$\beta_0, \beta_1, \ldots, \beta_n$ – коэффициенты модели, которые нужно оценить,

n – степень полинома (чем выше, тем гибче модель, но выше риск переобучения),

ε – случайная ошибка или шум.

Особенности полиномиальной модели

Полиномиальная регрессия хорошо описывает данные внутри диапазона наблюдений, но при выходе за его пределы (экстраполяции) часто начинает вести себя нестабильно. Предсказания могут стремительно уходить в плюс или минус бесконечность. Это происходит потому что полином подстраивается под данные, а не под специфику взаимосвязи. Не всегда способен отразить физический или экономический смысл задачи.

Если полиномиальная регрессия недостаточно гибкая, можно использовать нелинейные регрессионные модели, где функция заранее задается: логистическая, экспоненциальная, степенная, логарифмическая и пр.

Пример полиномиальной регрессии

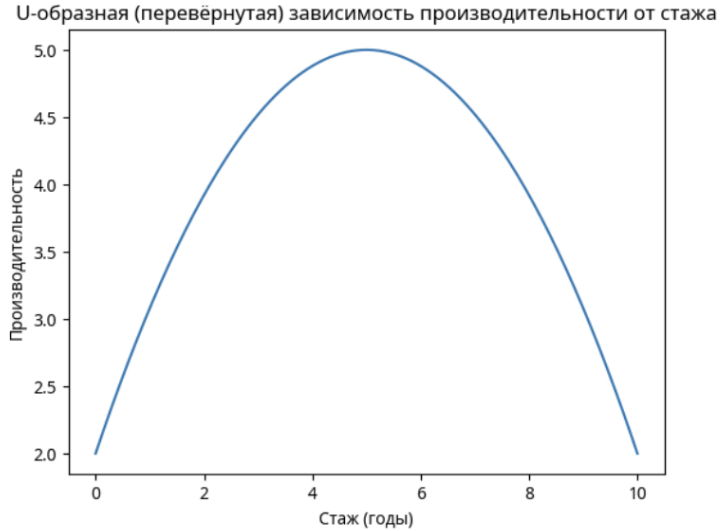
Производительность сотрудника и стаж (U-образная зависимость)

Связь между стажем (tenure) и производительностью часто нелинейная:

- первые месяцы → рост (адаптация)
- 2–4 года → пик
- затем возможен спад (выгорание, рутина)

$$Performance = a + b_1 Tenure + b_2 Tenure^2$$

Если коэффициент b_2 при $Tenure^2$ отрицательный – получаем перевёрнутую U-образную кривую. На основе модели можно определить момент пика эффективности, планировать карьерные треки, вовремя запускать ротацию или развитие.



Пример полиномиальной регрессии

Возможна замедляющаяся отдача от стажа (убывающая предельная отдача).

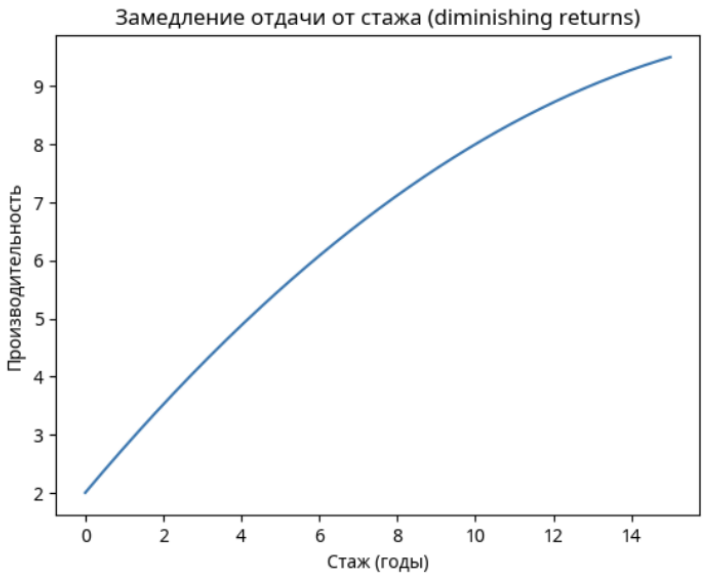
- первые годы → производительность растёт быстро (обучение, рост навыков)
- средний стаж → рост продолжается, но медленнее
- большой стаж → производительность всё ещё растёт, но каждый дополнительный год даёт меньший прирост

$$Performance = a + b_1 Tenure + b_2 Tenure^2$$

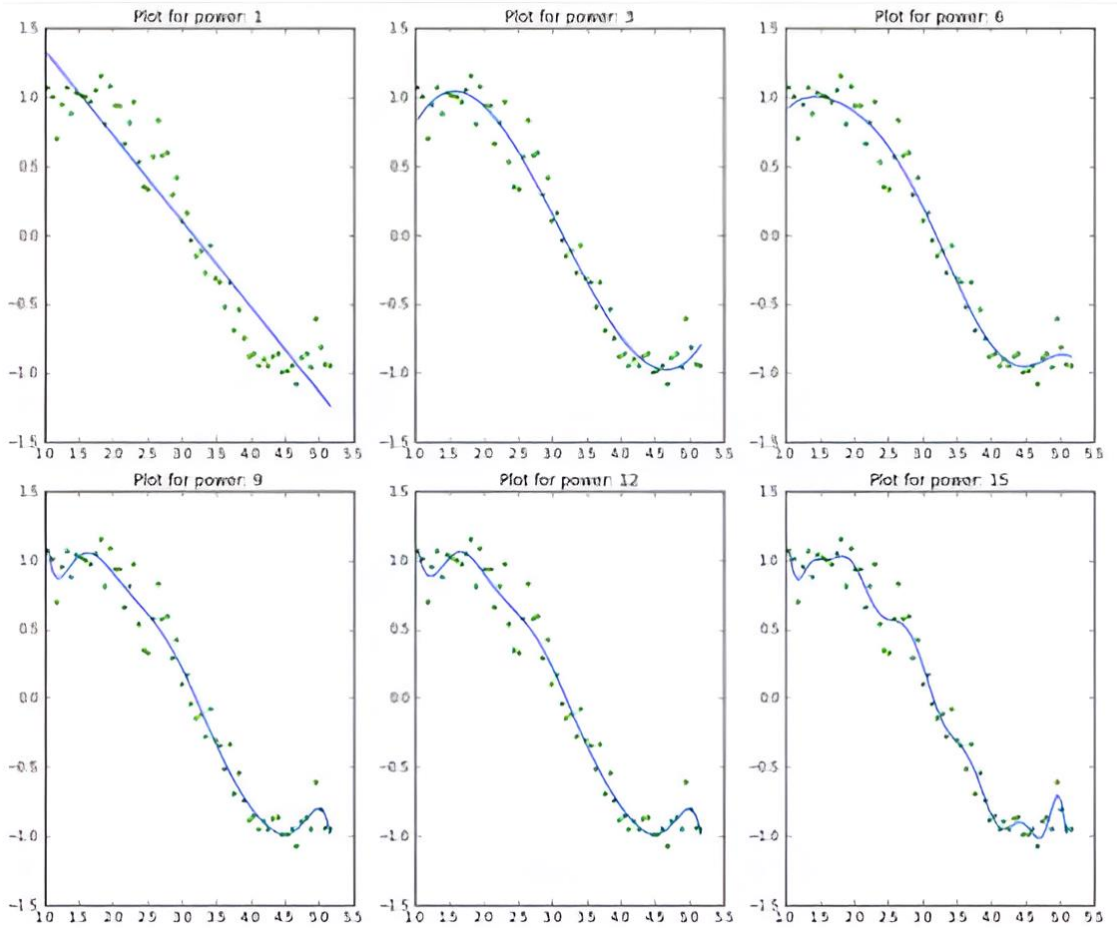
$b_1 > 0, \quad b_2 < 0$ (маленький по модулю)

Кривая вогнутая, но не падает в наблюдаемом диапазоне.

Опыт всегда помогает, но каждый следующий год даёт меньше прироста производительности.

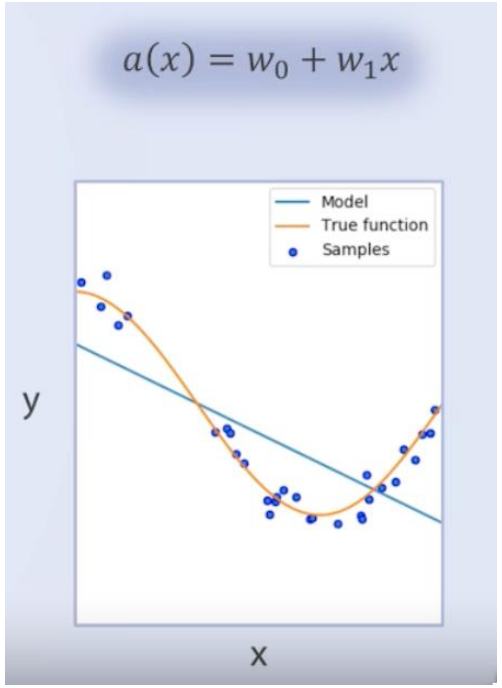


Полиномиальная модель

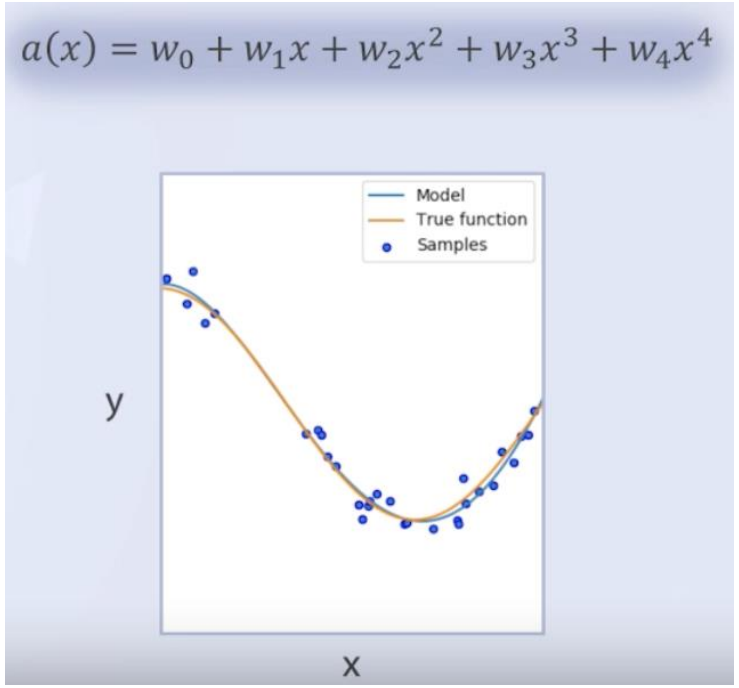


Полиномиальная модель

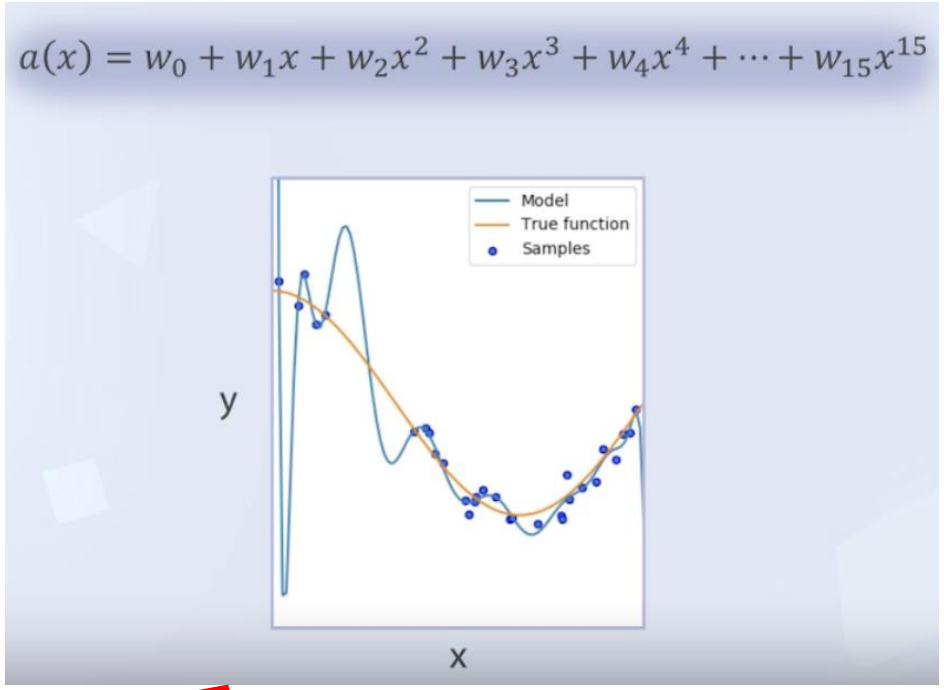
$a(x) = w_0 + w_1 x$



$a(x) = w_0 + w_1 x + w_2 x^2 + w_3 x^3 + w_4 x^4$



$a(x) = w_0 + w_1 x + w_2 x^2 + w_3 x^3 + w_4 x^4 + \cdots + w_{15} x^{15}$



Переобучение

Полиномиальная модель: ограничения

- **Переобучение** – если степень полинома высокая модель может подгоняться под данные. Чем выше степень – тем выше риск переобучения.
- **Плохая экстраполяция** – за пределами обучающего диапазона старшие степени быстро растут, предсказания становятся нереалистичными.
- **Мультиколлинеарность** – признаки сильно коррелированы между собой, что приводит к нестабильности коэффициентов.
- **Сложность интерпретации** – коэффициенты трудно интерпретировать.
- **Чувствительность к выбросам** – если выброс находится на краю диапазона, то полином «изгибается» под него.
- **Проблема выбора степени** - обычно подбирается через кросс-валидацию.

Регуляризация в линейной регрессии

Регуляризация в линейной регрессии – это метод уменьшения переобучения (overfitting) модели путём добавления штрафа за слишком большие коэффициенты.

Обычная линейная регрессия минимизирует только ошибку, а регуляризация добавляет штраф за сложность модели. Это позволяет предотвратить переобучение, чтобы модель не запоминала шум, а лучше обобщала данные.

Регуляризация особенно нужна когда мало данных, много признаков, и наблюдается мультиколлинеарность. Признаки нужно масштабировать перед регуляризацией.

Регуляризация

Наиболее распространённые методы регуляризации в линейных моделях:

- Ridge-регуляризация;
- Lasso-регуляризация;
- Elastic Net.

Функция потерь:

$$Min_{w,b}\,(MSE + penalty) = Min\left[\frac{1}{N}\sum_{i=1}^{N}\left(y_i - f_{w,b}(X_i)\right)^2 + penalty(w)\right]$$

Ridge-регуляризация (гребневая)

L2-регуляризация (Ridge) добавляется штраф за квадраты коэффициентов, то есть штрафуются высокие коэффициенты.

Функция потерь:

$$\frac{1}{n}\sum(y_i - \hat{y}_i)^2 + \lambda \sum w_j^2$$

λ – коэффициент регуляризации

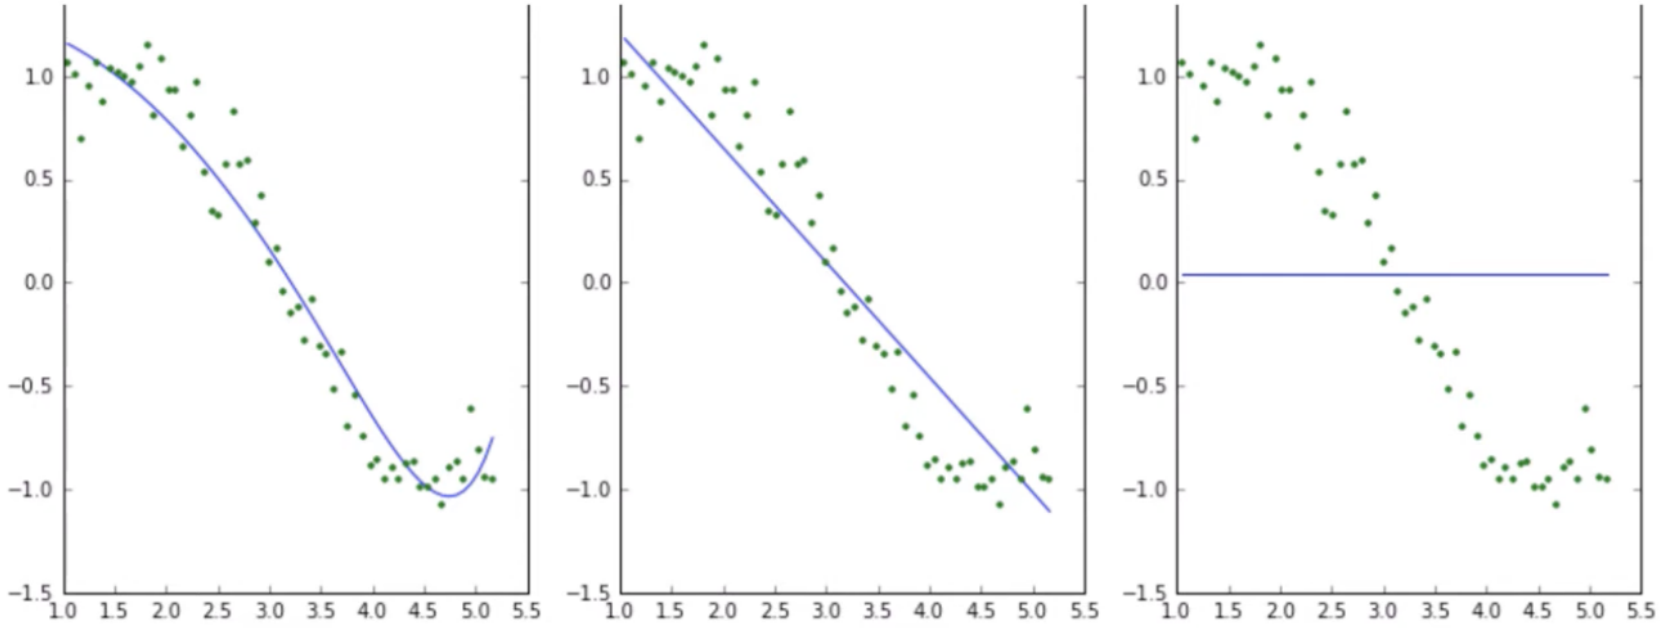
чем больше λ, тем сильнее штраф

После регуляризации коэффициенты уменьшаются, но никогда не становятся ровными нулю. Ridge не осуществляет отбор признаков.

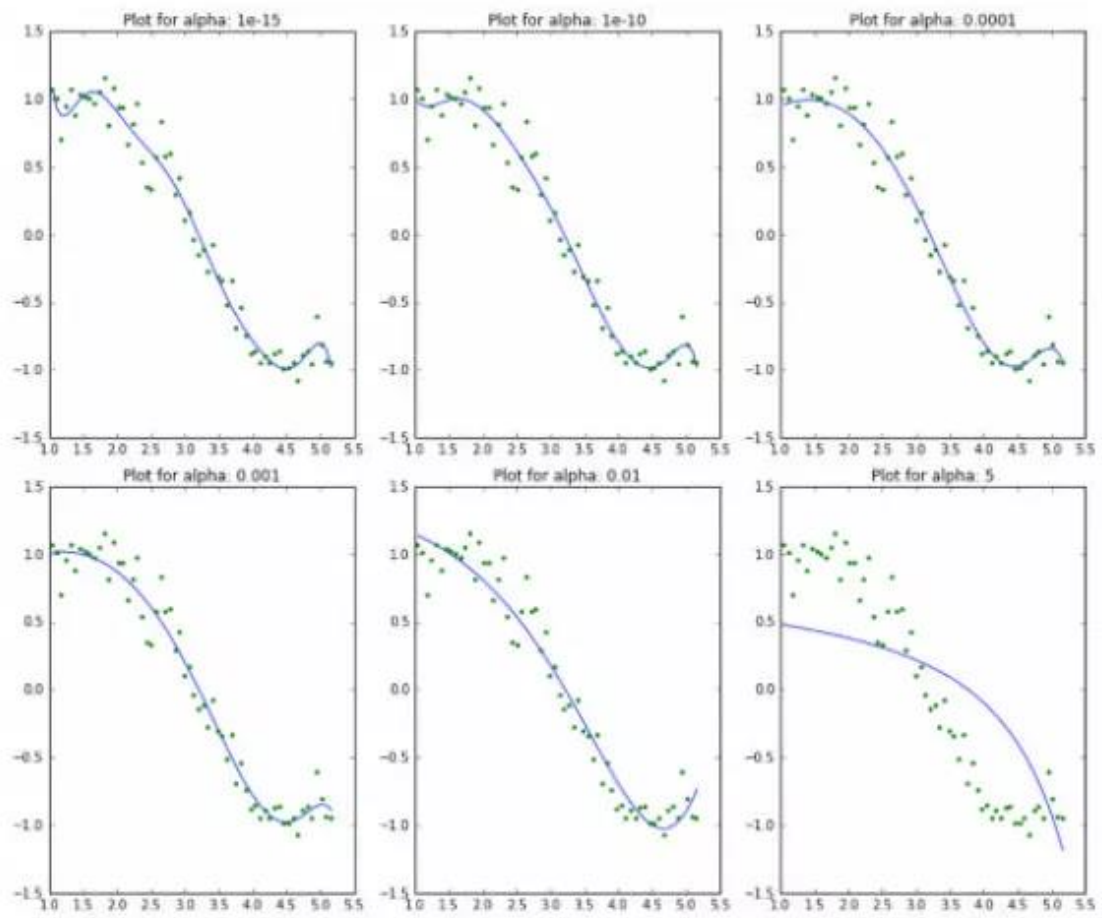
Используется когда все признаки полезны, но есть мультиколлинеарность.

Ridge-регуляризация

As λ increases, the model becomes simpler

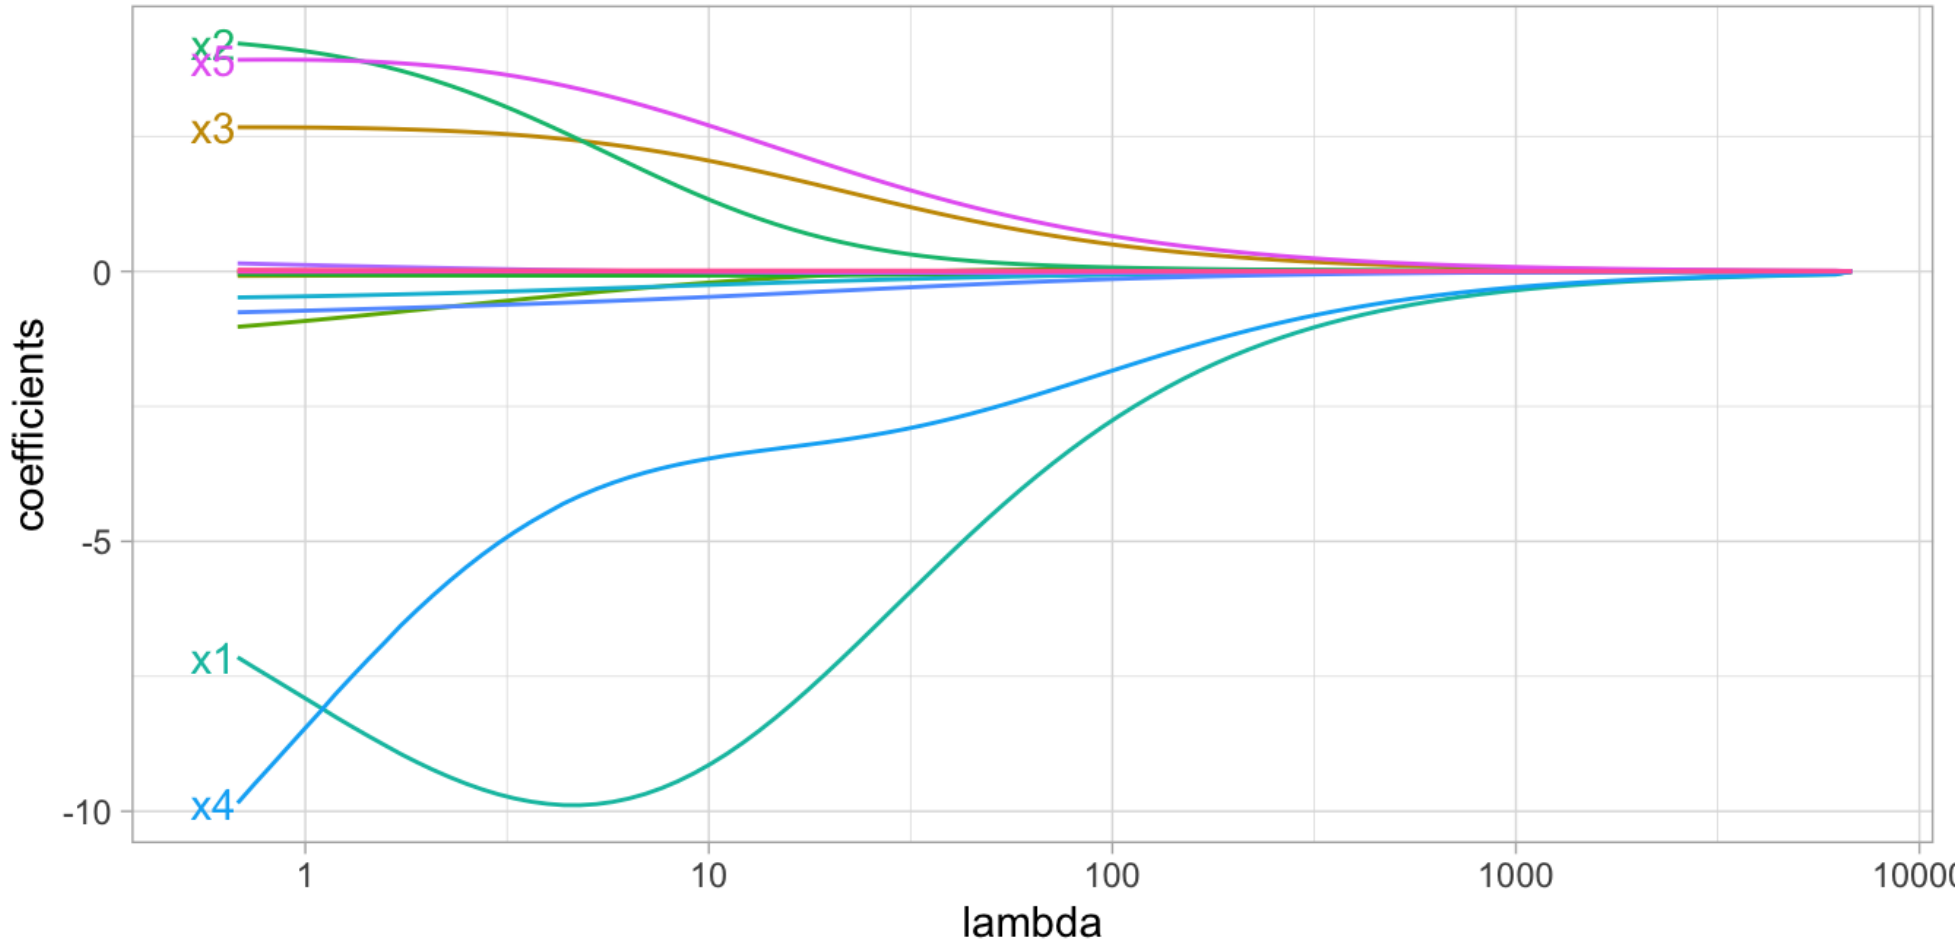


Ridge-регуляризация



Под alpha понимается λ

Ridge-регуляризация



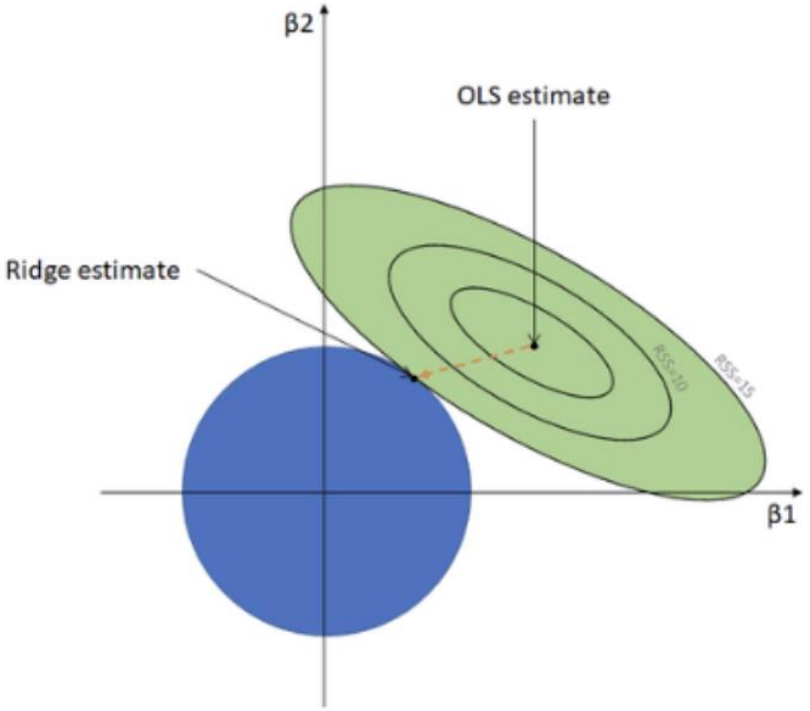
Ridge-регуляризация

Оптимизация ищет точку минимума ошибки, но решение должно лежать внутри круга ограничений. То есть круг определяет допустимую область значения коэффициентов. Поскольку у круга гладкая граница коэффициенты уменьшаются, но почти никогда не становятся ровно нулём, то есть отбора признаков не происходит.

Когда мы ищем компромисс между ошибкой и ограничением, мы чаще всего касаемся круга не в углу. В результате оба веса β_1 и β_2 становятся маленькими, но не нулевыми.

$\beta_1^2 + \beta_2^2 \leq t$, радиус круга = $\sqrt{t}$

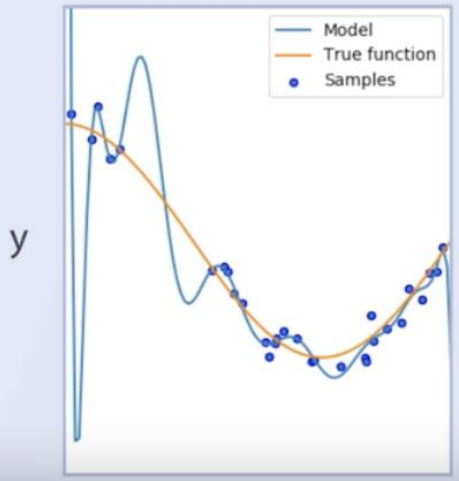
$\lambda \uparrow$(сильнее регуляризация) $\rightarrow t \downarrow \rightarrow$ радиус уменьшается



Ridge-регуляризация

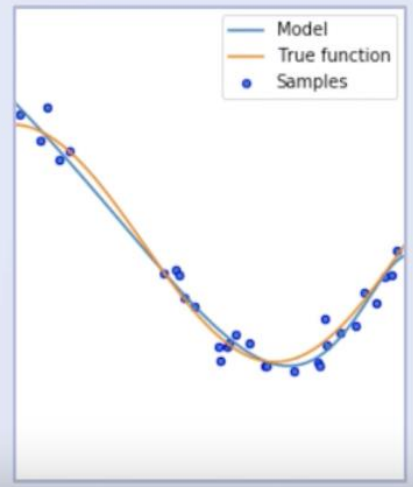
$$a(x) = w_0 + w_1 x + w_2 x^2 + w_3 x^3 + w_4 x^4 + \cdots + w_{15} x^{15}$$

$$\frac{1}{\ell}\sum_{i=1}^{\ell}(a(x_i) - y_i)^2 \to \min_w$$



$$a(x) = w_0 + w_1 x + w_2 x^2 + w_3 x^3 + w_4 x^4 + \cdots + w_{15} x^{15}$$

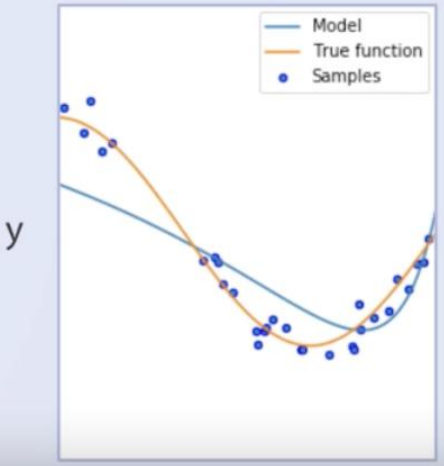
$$\frac{1}{\ell}\sum_{i=1}^{\ell}(a(x_i) - y_i)^2 + 0.01\ \|w\|^2 \to \min_w$$



Ridge-регуляризация

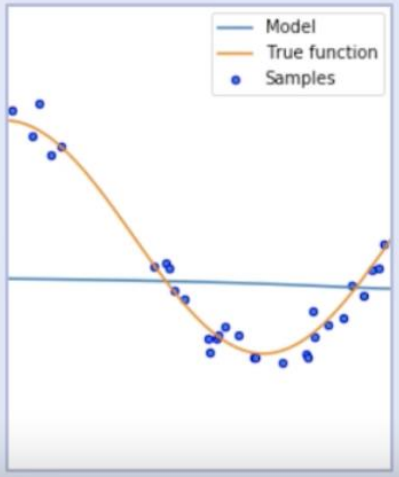
$$a(x) = w_0 + w_1 x + w_2 x^2 + w_3 x^3 + w_4 x^4 + \cdots + w_{15} x^{15}$$

$$\frac{1}{\ell}\sum_{i=1}^{\ell}(a(x_i) - y_i)^2 + 1\ \|w\|^2 \to \min_w$$



$$a(x) = w_0 + w_1 x + w_2 x^2 + w_3 x^3 + w_4 x^4 + \cdots + w_{15} x^{15}$$

$$\frac{1}{\ell}\sum_{i=1}^{\ell}(a(x_i) - y_i)^2 + 100\ \|w\|^2 \to \min_w$$



Lasso-регуляризация (Least Absolute Shrinkage and Selection Operator)

L1-регуляризация (Lasso) добавляется штраф за модуль коэффициентов.

$$\frac{1}{n}\sum(y_i - \hat{y}_i)^2 + \lambda \sum |w_j|$$

Происходит отбор признаков. Некоторые коэффициенты становятся равными нулю. Используется когда признаков много и нужно выбрать самые важные.

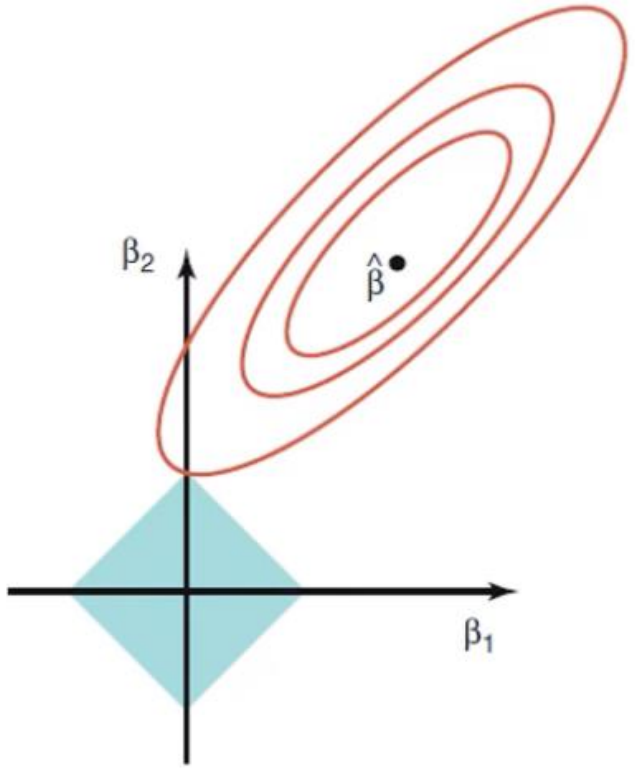
Может снижать влияние мультиколлинеарности, выполняя отбор признаков и обнуляя коэффициенты некоторых коррелирующих признаков.

Lasso-регуляризация

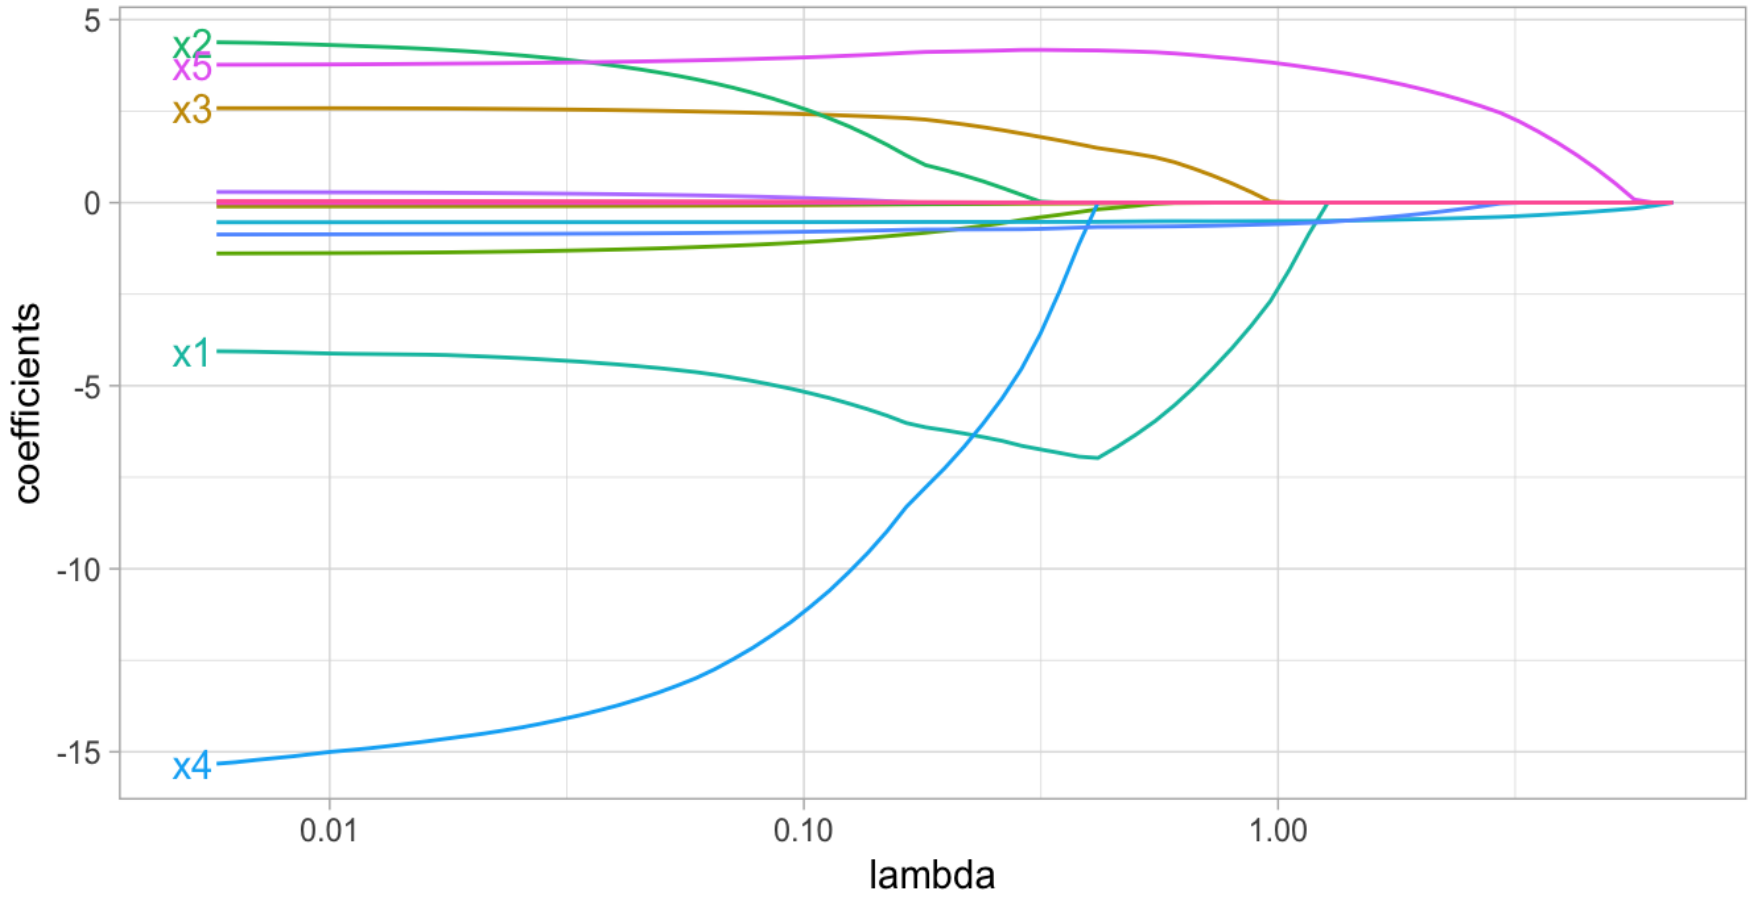
Оптимизация ищет точку минимума ошибки, но решение должно лежать внутри ромба ограничений. Когда мы ищем компромисс между ошибкой и ограничением, мы чаще всего касаемся ромба именно в углу. В результате один из весов β_1 или β_2 может стать нулевым.

$$|\beta_1| + |\beta_2| \leq t$$

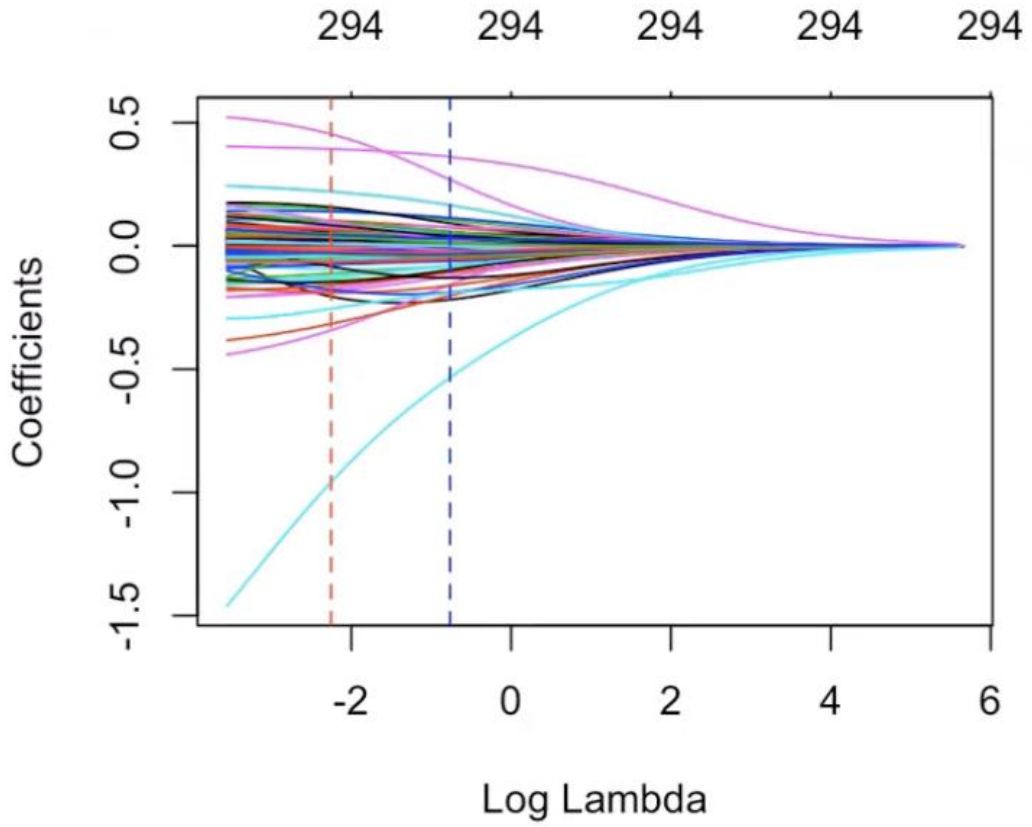
Результат: модель сама выбрасывает ненужные признаки.

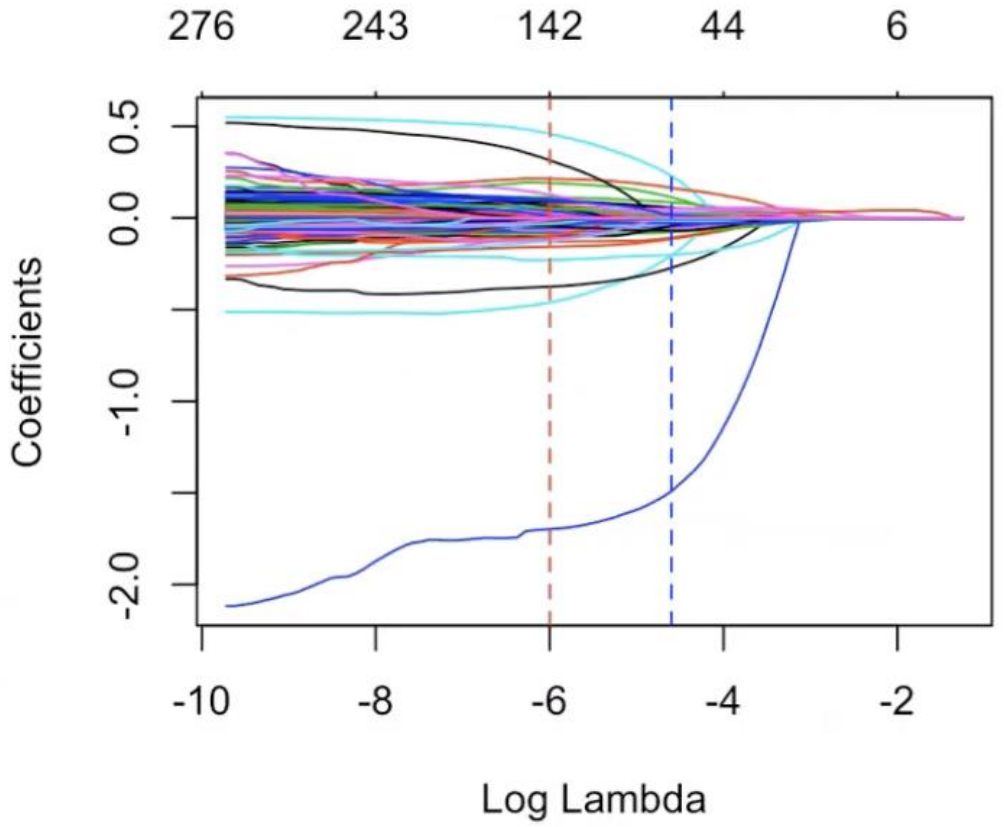


Lasso-регуляризация



Rigde или Lasso?





Elastic Net

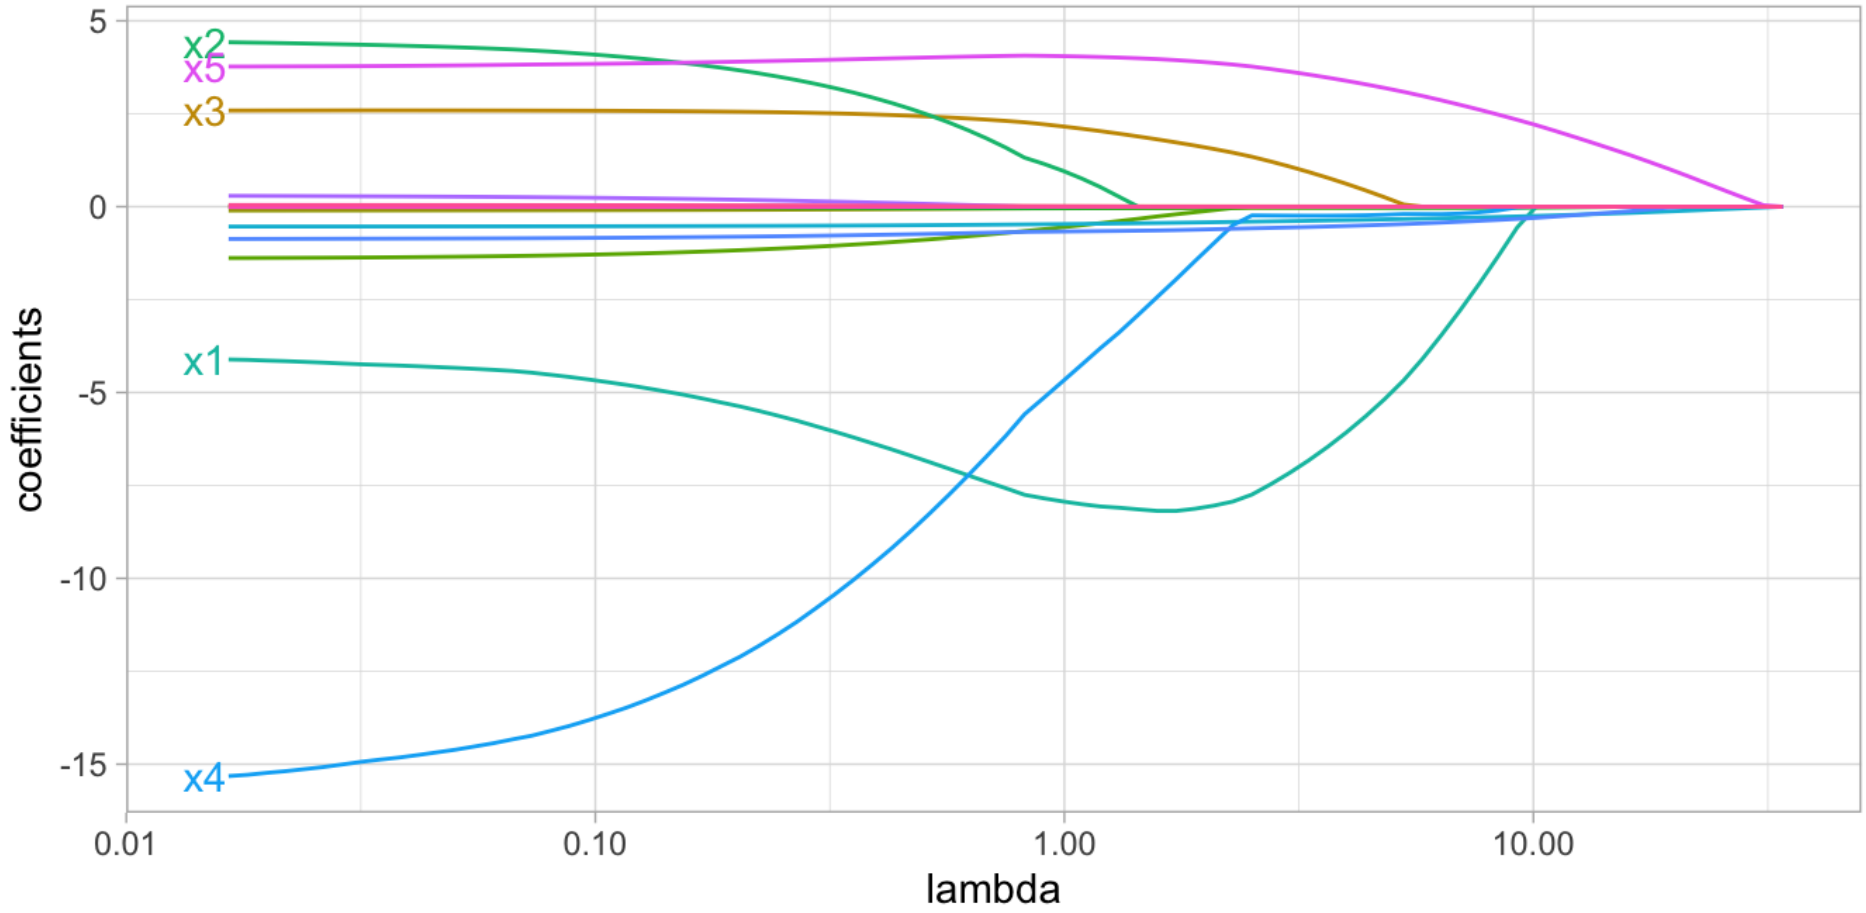
Комбинация L1 и L2. Функция потерь:

$$\frac{1}{n}\sum(y_i - \hat{y}_i)^2 + \lambda_1 \sum |w_j| + \lambda_2 \sum w_j^2$$

Сочетает оба подхода и используется когда много признаков и они коррелируют.

Осуществляет отбор признаков, при этом стабилизирует модель.

Elastic Net



Lambda (λ)

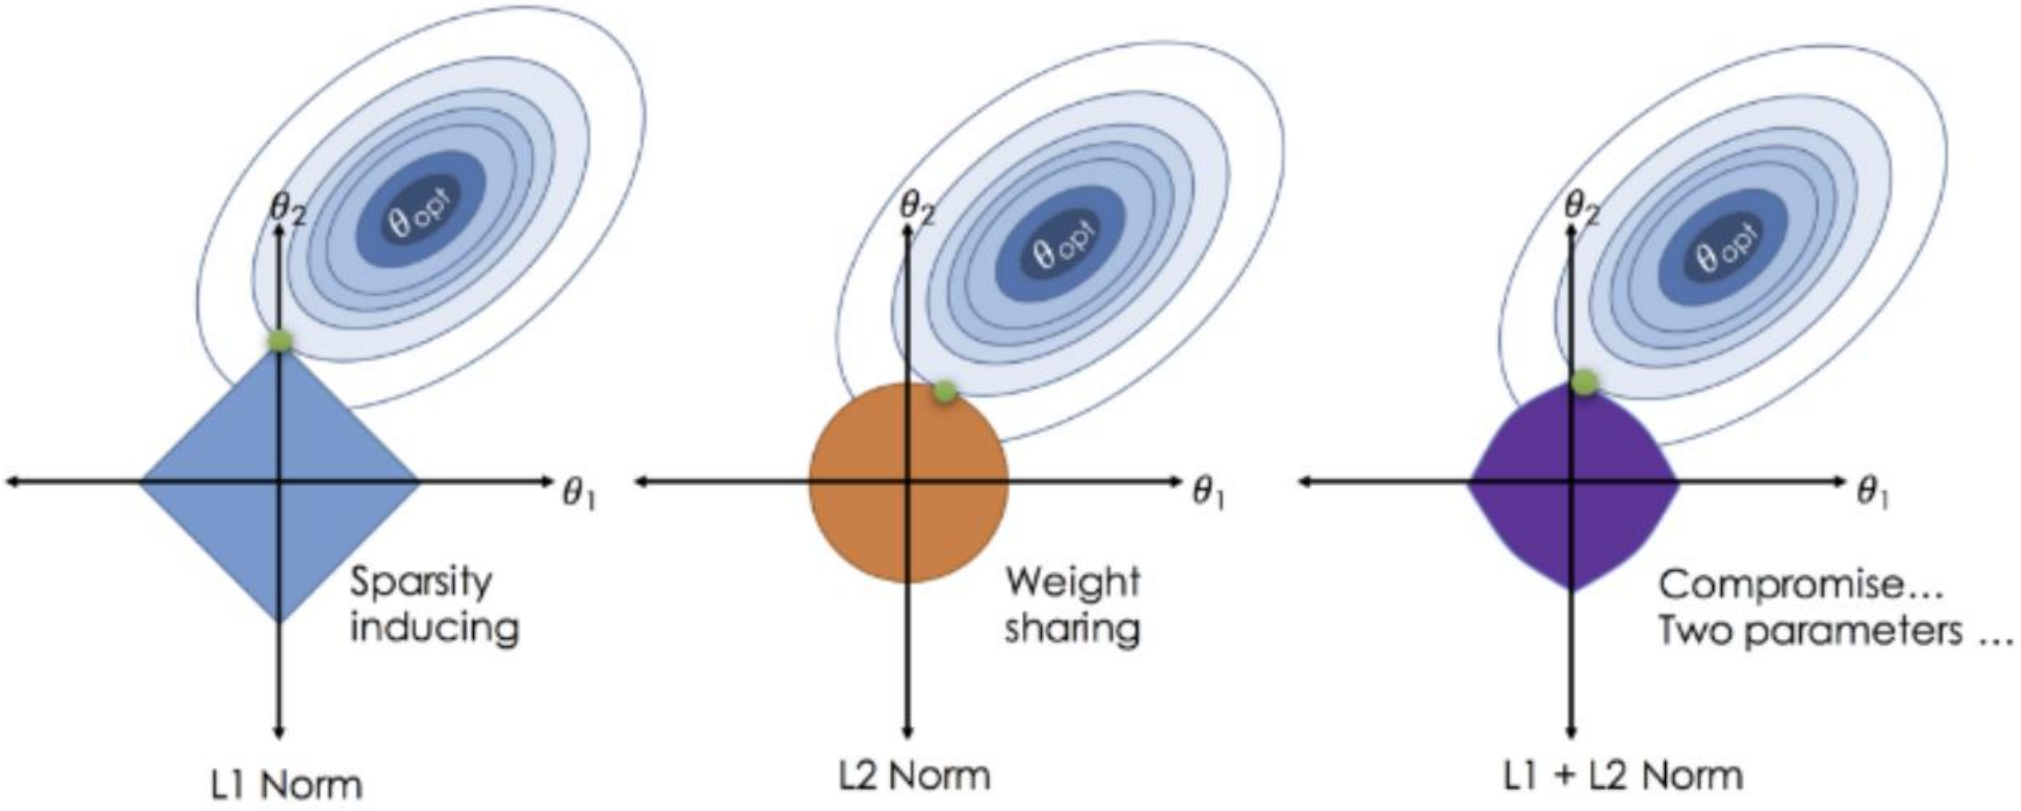
λ	эффект
0	обычная линейная регрессия
маленькое	слабая регуляризация
большое	коэффициенты сильно уменьшаются
очень большое	модель почти константа

Чем больше λ, тем сильнее штраф и тем меньше становятся веса.

- Если λ слишком мало, регуляризация почти не влияет, и риск переобучения сохраняется.
- Если λ слишком велико, модель чрезмерно упрощается и возникает недообучение.

Оптимальное значение подбирается через кросс-валидацию.

Регуляризация



Этапы проведения регуляризации

1. Подготовка данных: one-hot кодирование и масштабирование признаков.
2. Кросс-валидация для подбора параметров регуляризации.
3. Построение модели с регуляризацией.
4. Интерпретация коэффициентов.

Регуляризация не всегда нужна

Регуляризация в линейных моделях не всегда необходима. Есть несколько ситуаций, когда она почти ничего не меняет:

- нет мультиколлинеарности;
- малое число признаков;
- большая выборка;
- признаки уже хорошо отобраны.

Спасибо за внимание!