

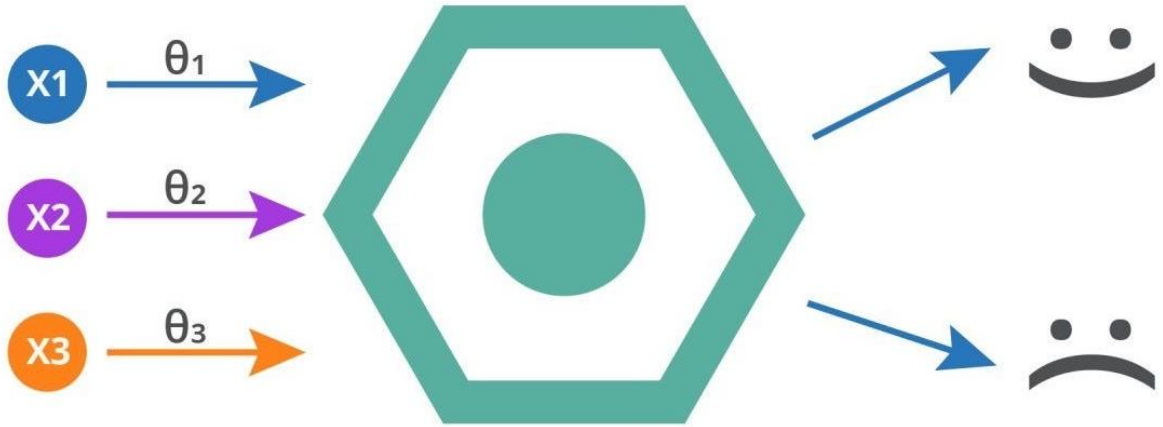
Факультет компьютерных наук | Машинное обучение | Москва 2026

Лекция 7.2.
Бинарная логистическая регрессия

Преподаватель: Меликян Алиса Валерьевна, amelikyan@hse.ru
кандидат наук, доцент Департамента программной инженерии ФКН НИУ ВШЭ

Логистическая регрессия

Логистическая регрессия используется для задач классификации. Оценивает вероятность того, что объект принадлежит к определённому классу. Модель анализирует входные признаки и преобразует их таким образом, чтобы результат лежал в диапазоне от 0 до 1, что удобно интерпретировать как вероятность. Затем на основе выбранного порога принимается решение о классе. Логистическая регрессия ценится за простоту, интерпретируемость и эффективность, особенно на небольших и средних наборах данных, и часто используется как базовая модель или отправная точка для более сложных методов.

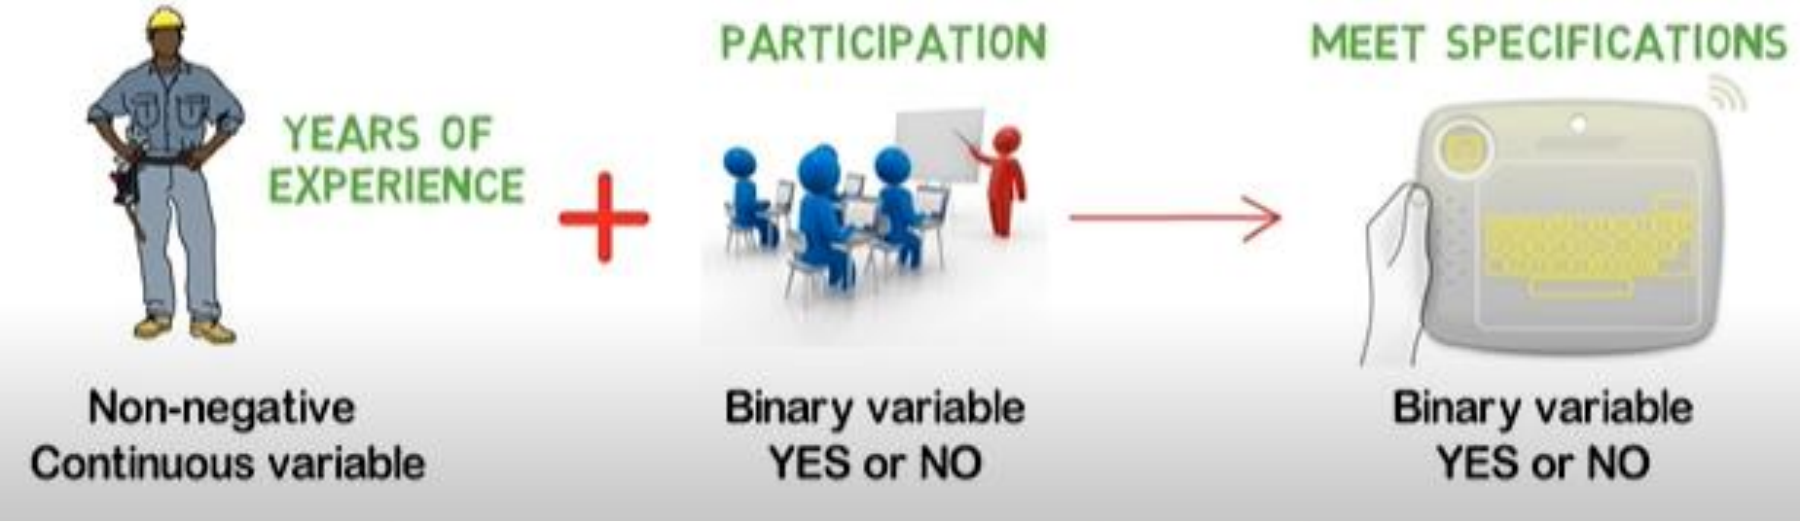


Виды логистической регрессии

- **Бинарная** логистическая регрессия оценивает вероятность принадлежности объекта к одному из двух классов.
- **Мультиномиальная** логистическая регрессия моделирует вероятности для всех классов.
- **Порядковая** логистическая регрессия используется в случаях, когда классы имеют естественный порядок (например, уровни удовлетворённости: низкий, средний, высокий). В отличие от обычной классификации, здесь учитывается упорядоченность категорий.
- **Регуляризованная** логистическая регрессия включает дополнительные ограничения на параметры модели (L1 или L2-регуляризация), что помогает бороться с переобучением и улучшает обобщающую способность модели, особенно при большом числе признаков.

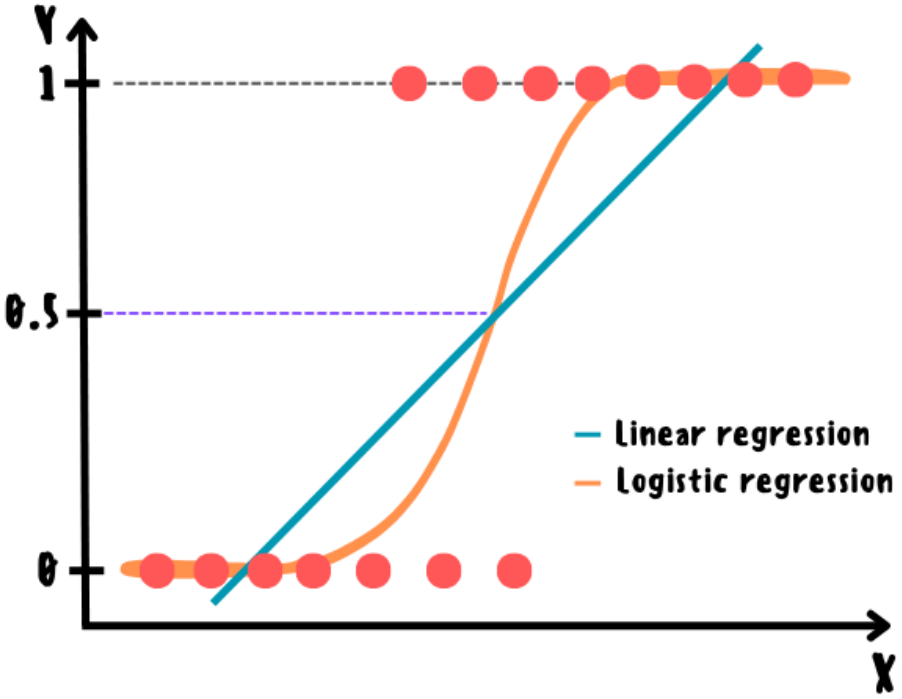
Бинарная логистическая регрессия

Бинарная логистическая регрессия используется для моделирования зависимости между бинарной (дихотомической) целевой переменной и набором признаков, которые могут быть как числовыми, так и категориальными. В задачах такого типа рассматривается некоторое событие с двумя исходами (например, «да/нет» или «0/1»), а модель оценивает вероятность его наступления на основе входных данных. Обучение модели осуществляется с использованием метода максимального правдоподобия.

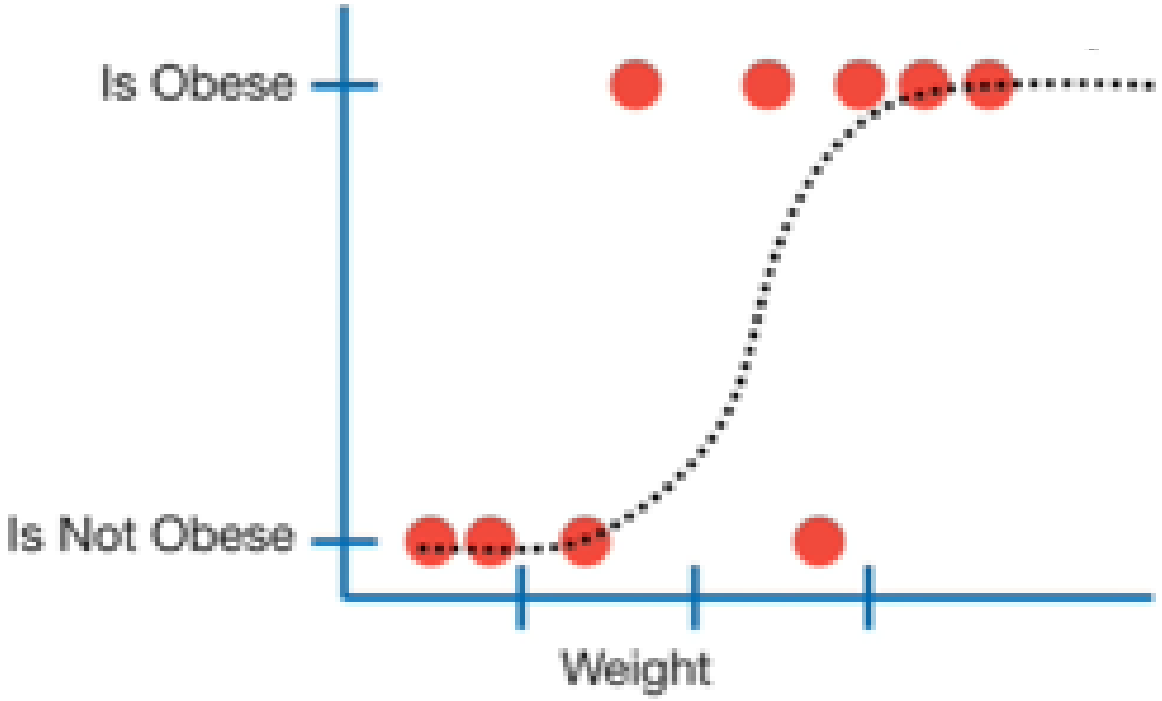


Почему линейная регрессия не подходит?

Линейная регрессия предполагает, что предсказания могут принимать любые вещественные значения. В результате модель может выдавать значения меньше 0 или больше 1, что невозможно интерпретировать как вероятность принадлежности к классу. Чтобы этого избежать, модель оценивает непрерывную величину в диапазоне от 0 до 1. Это достигается за счёт применения логистической (сигмоидной) функции к линейной комбинации признаков, что эквивалентно использованию логит-преобразования и позволяет корректно моделировать вероятности в задачах бинарной классификации.

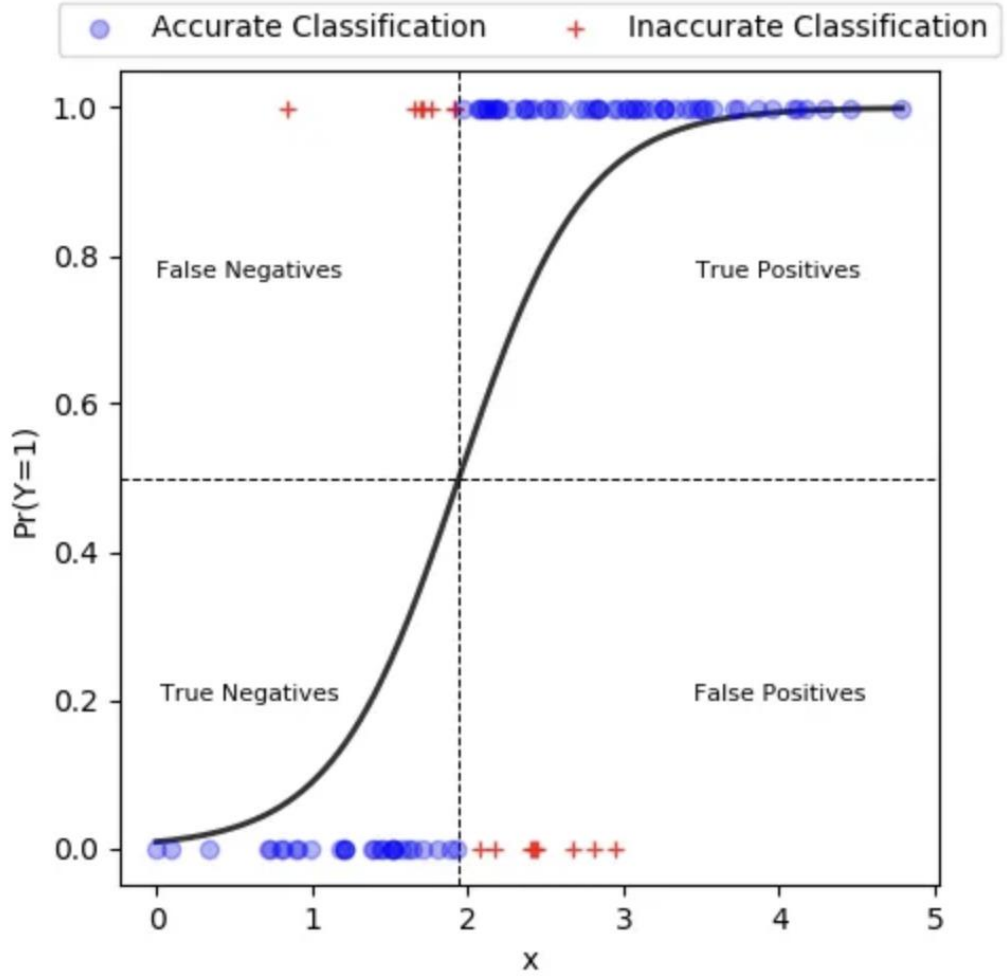


Логистическая кривая



Значения кривой по оси ординат лежат в диапазоне от 0 до 1. В примере на основе кривой можно оценить вероятность ожирения у человека на основе информации о его весе. В целом, чем больше вес, тем выше вероятность ожирения.

Логистическая кривая



Синие точки обозначают правильные классификации, красные – ошибки. Пунктирные линии показывают порог вероятности (обычно 0.5) и соответствующую границу принятия решения. Области на графике разделены на истинно положительные, истинно отрицательные, ложноположительные и ложноотрицательные предсказания.

Вероятности и шансы

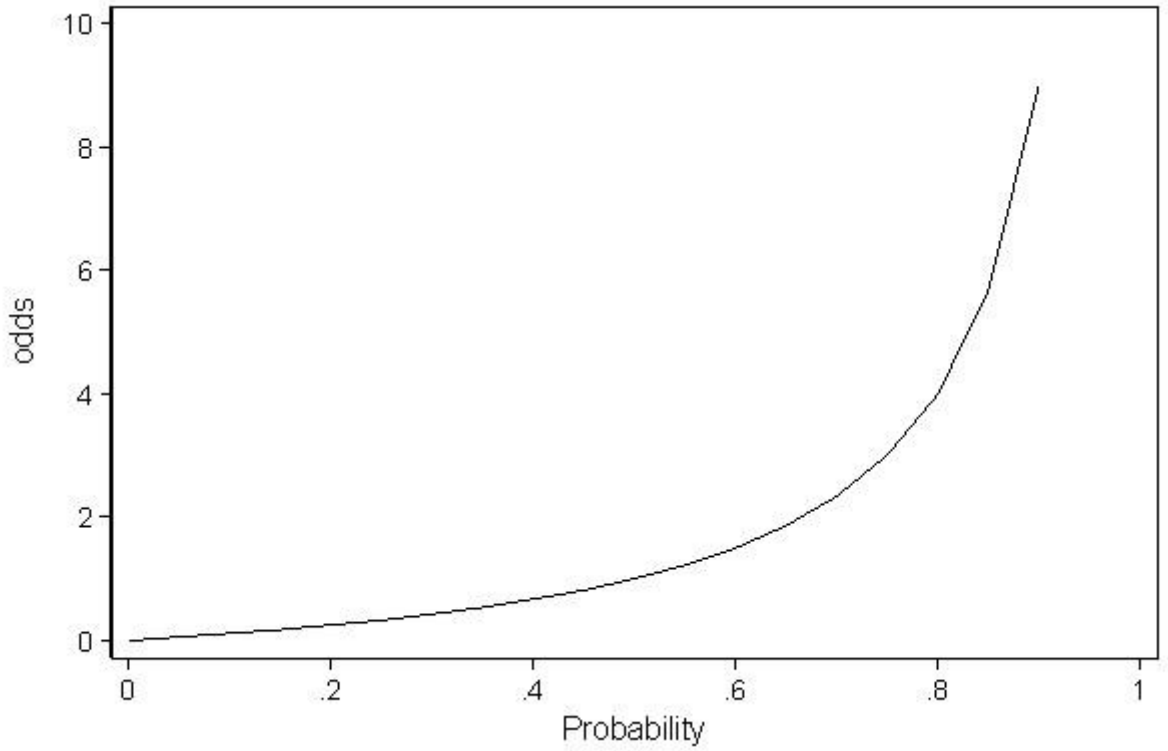
Вероятность события (probability) – это отношение числа случаев, в которых событие произошло, к общему числу попыток.
Пример: если монету бросали 100 раз и в 65 случаях выпал орёл, то оценённая вероятность выпадения орла равна:

$$P(\text{орёл}) = \frac{65}{100} = 0{,}65$$

Шансы (odds) – это отношение числа случаев, в которых событие произошло, к числу случаев, в которых событие не произошло.
Пример: для того же эксперимента:

$$\text{Шансы выпадения орла} = \frac{65}{100 - 65} = \frac{65}{35} = 1{,}86$$

Вероятности и шансы



$$1{,}5 = \frac{0{,}6}{1 - 0{,}6}$$

Вероятности (Probability)	**0,01**	**0,2**	**0,3**	**0,5**	**0,6**
Шансы (Odds)	0,0101	0,25	0,42	1	1,5

Вероятность наступления события

Вероятность наступления события рассчитывается по формуле:

$$p = \frac{1}{1 + e^{-z}}$$

В основе лежит линейная комбинация признаков:

$$z = w_0 + w_1 x_1 + w_2 x_2 + \cdots + w_n x_n$$

к которым применяется сигмоидная функция (логистическая трансформация), преобразующая любое значение в диапазон (0, 1).

Рассчитанная вероятность указывает на исполнение события, соответствующего большей из двух кодировок целевой переменной. Обычно считается, что если значение p меньше, чем 0.5, то наступление события маловероятно.

Логарифм, натуральный логарифм, экспонента

Логарифм отвечает на вопрос: *В какую степень нужно возвести число (основание), чтобы получить другое число (аргумент)?*

$$\log_2 8$$

Здесь основание – 2, а число, которое хотим получить – 8.

$2^3 = 8 \rightarrow$ значит $\log_2 8 = 3$.

Натуральный логарифм - это логарифм с основанием e – число Эйлера ($e \approx 2{,}718$).

$\ln a = \log_e a$

Экспонента – это функция, обратная натуральному логарифму:

$f(x) = \exp(x) = e^x$

Экспонента возвращает число из логарифма.

$$\ln N = x \iff N = e^x$$

Зачем нужна экспонента?

В логистической регрессии модель сначала предсказывает логарифм отношения шансов (log-odds):

$$ln\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k$$

Чтобы перейти от логарифма шансов к самим шансам, нужно убрать логарифм, то есть взять экспоненту:

$$\frac{p}{1-p} = e^{\beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k}$$

Поэтому для интерпретации влияния коэффициентов на шансы целевой переменной мы берём экспоненту от них.

Отношения вероятностей и шансов

Отношение вероятностей (risk ratio, RR)

Вероятность того, что женщина доживёт до пенсионного возраста, составляет 0,9, а мужчина – 0,6.

$$RR = \frac{P(\textit{женщины})}{P(\textit{мужчины})} = \frac{0{,}9}{0{,}6} = 1{,}5$$

У женщин вероятность в 1,5 раза выше, чем у мужчин.

Отношение шансов (odds ratio, OR)

Шансы для женщин: 0,9 / (1 − 0,9) = 0,9 / 0,1 = 9

Шансы для мужчин: = 0,6 / (1 − 0,6) = 0,6 / 0,4 = 1,5

Отношение шансов женщин к мужчинам:

$$OR = \frac{9}{1{,}5} = 6$$

Шансы женщин дожить до пенсионного возраста в 6 раз выше, чем у мужчин.

Метод максимального правдоподобия

Метод направлен на поиск параметров модели, при которых предсказанные вероятности принадлежности к классам наилучшим образом согласуются с наблюдаемыми данными. В качестве критерия качества используется функция правдоподобия (log-likelihood), отражающая степень соответствия между фактическими и предсказанными значениями. Обучение модели сводится к максимизации log-likelihood или, что эквивалентно, к минимизации функции потерь, основанной на нём (log-loss).

Базовой (референтной) моделью является модель без признаков (intercept-only), которая предсказывает одинаковую вероятность для всех объектов, равную доле положительного класса в обучающей выборке. Эта модель служит точкой отсчета (baseline) для оценки качества модели с признаками. Если сложная модель не показывает значимого улучшения метрик, значит признаки не несут полезной информации для разделения классов.

Функция потерь

Для обучения используется логарифмическая функция потерь (log loss):

$$L = -\frac{1}{n}\sum_{i=1}^{n}[y_i log(p_i) + (1 - y_i) log(1 - p_i)]$$

Это просто отрицательный логарифм правдоподобия (log-likelihood), усреднённый по количеству наблюдений.

То есть log loss - это нормированный отрицательный log likelihood.

Максимизация логарифма правдоподобия ≡ Минимизация log loss.

Функция потерь: пример расчёта

Наблюдение i	Истинное y_i	Предсказанная $\hat{p}_i$
1	1	0.9
2	0	0.2
3	1	0.7

$y_1 = 1, \hat{p}_1 = 0.9$: $1 \cdot log\, 0.9 + 0 \cdot log\, 0.1 = -0.10536$
$y_2 = 0, \hat{p}_2 = 0.2$: $0 + 1 \cdot log\, 0.8 = -0.22314$
$y_3 = 1, \hat{p}_3 = 0.7$: $1 \cdot log\, 0.7 + 0 \cdot log\, 0.3 = -0.35667$
Log-likelihood $= -0.10536 - 0.22314 - 0.35667 = -0.68517$
Log-likelihood чаще всего отрицательный, стремимся максимизировать, приближая к нулю.

LogLoss $= -\frac{1}{3} \cdot (-0.68517) = 0.22839$ (стремимся минимизировать)

Статистическая значимость модели

Log-Likelihood:	-316.46
LL-Null:	-482.26
LLR p-value:	5.069e-66

- -482.26 – логарифм функции правдоподобия для “нулевой” модели, где нет признаков (только константа).
- -316.46 – логарифм функции правдоподобия для модели логистической регрессии с параметрами, он выше, чем у нулевой модели.
- 5.069e-66 – это p-value теста отношения правдоподобий (Likelihood Ratio Test), который проверяет является ли модель с признаками значимо лучше нулевой. Очень маленький p-value подтверждает статистическую значимость улучшения модели.

Матрица ошибок (Confusion Matrix)

Actual		Predicted	
		Positive	Negative
	Positive	True Positive (TP)	False Negative (FN)
	Negative	False Positive (FP)	True Negative (TN)

Матрица ошибок показывает сравнение реальных и предсказанных классов. Определение положительного и отрицательного события зависит от задачи. Если мы прогнозируем вероятность наличия заболевания, положительным исходом будет класс «больной пациент», а отрицательным – «здоровый пациент». Если задача заключается в определении вероятности того, что человек здоров, положительным исходом становится класс «здоровый пациент», а отрицательным – «больной пациент».

Positives and Negatives

- TP (*True Positives*) – верно классифицированные положительные истоды (истинно положительные).
- TN (*True Negatives*) – верно классифицированные отрицательные исходы (истинно отрицательные).
- FN (*False Negatives*) – положительные исходы, классифицированные как отрицательные (ложно отрицательные).
- FP (*False Positives*) – отрицательные исходы, классифицированные как положительные (ложно положительные).

Accuracy

Accuracy (Точность) показывает долю всех правильно предсказанных случаев от общего числа. Можно использовать когда классы сбалансированы – примерно одинаковое количество положительных и отрицательных исходов. Если данные несбалансированные, то модель может быть лояльной к большинству и выдавать высокий Accuracy, но плохо находить редкие случаи (например, риск увольнения ключевых сотрудников).

- 50/50 до 60/40 – классы считаются сбалансированными, Accuracy уместна
- 70/30 – умеренный дисбаланс, Accuracy ещё можно использовать, но уже стоит учитывать дополнительные метрики.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Precision

Precision (Точность для положительного класса) показывает долю реально положительных исходов из всех исходов, предсказанных моделью как положительные. Используется когда важно минимизировать ложные срабатывания (FP). Например, при использовании спам-фильтра лучше пропустить спам (FN), чем пометить важное письмо как спам (FP).

$$\text{Precision} = \frac{TP}{TP + FP}$$

Recall

Recall (Полнота / Sensitivity / True Positive Rate) показывает долю найденных моделью положительных из всех реально положительных исходов. Используется, когда важно не пропустить ни одного положительного случая, даже если будут ложные срабатывания (FP). Можно использовать при обнаружении болезней на ранней стадии, когда лучше ошибиться и перепроверить несколько здоровых, чем пропустить больного.

$$\text{Recall} = \frac{TP}{TP + FN}$$

Specificity

Specificity (Специфичность / True Negative Rate) показывает какую долю истинно отрицательных случаев модель правильно определила как отрицательные. Это способность модели не ошибаться на отрицательных примерах. Используется, когда важно не тратить ресурсы на ложные срабатывания, даже если некоторые положительные случаи будут пропущены.

$$\text{Specificity} = \frac{TN}{TN + FP}$$

F1-score

F1-score – гармоническое среднее между Precision и Recall, которое одновременно учитывает и точность, и полноту модели. Метрика полезна, когда важно находить баланс между этими двумя показателями, особенно на несбалансированных данных, где одна из метрик может быть высокой за счёт другой.

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

Precision	Recall	F1-score
0.2	0.6	0.30
0.3	0.8	0.44
0.4	0.7	0.51
0.6	0.3	0.40
0.85	0.7	0.77

Метрики качества на основе матрицы ошибок

Ситуация	Рекомендуемая метрика
Классы сбалансированы	Accuracy
Важны **меньше ложноположительных** (FP)	Precision
Важны **меньше ложноотрицательных** (FN)	Recall
Важен **баланс между Precision и Recall**	F1-score

Вопросы

Компания внедрила автоматизированную систему отбора кандидатов на вакансию. Система оценивает резюме и решает, кого пригласить на интервью.

- Если система пропускает сильного кандидата, то как это называется в терминах матрицы ошибок?

- Если система приглашает слабого кандидата, то как это называется в терминах матрицы ошибок?

Вопросы

Компания внедрила автоматизированную систему отбора кандидатов на вакансию. Система оценивает резюме и решает, кого пригласить на интервью.

- Если система пропускает сильного кандидата, то как это называется в терминах матрицы ошибок?

Ответ: **FN (false negative)**

- Если система приглашает слабого кандидата, то как это называется в терминах матрицы ошибок?

Ответ: **FP (false positive)**

Вопросы

Компания внедрила автоматизированную систему отбора кандидатов на вакансию. Система оценивает резюме и решает, кого пригласить на интервью.

- Что в данном контексте означает высокий Recall (Sensitivity) системы?

- Что означает низкая Specificity системы?

Вопросы

Компания внедрила автоматизированную систему отбора кандидатов на вакансию. Система оценивает резюме и решает, кого пригласить на интервью.

- Что в данном контексте означает высокий Recall (Sensitivity) системы?

Ответ: Высокий Recall означает, что почти все сильные кандидаты будут приглашены на интервью. Система не пропускает талантливых кандидатов.

- Что означает низкая Specificity системы?

Ответ: Низкая Specificity означает, что много слабых кандидатов ошибочно признаются подходящими и приглашаются на интервью. Система путает плохие резюме с хорошими.

Вопросы

Компания внедрила автоматизированную систему отбора кандидатов на вакансию. Система оценивает резюме и решает, кого пригласить на интервью.

Какая ситуация более критична для компании:

- пропустить сильного кандидата
- или пригласить на интервью слабого?

Вопросы

Компания внедрила автоматизированную систему отбора кандидатов на вакансию. Система оценивает резюме и решает, кого пригласить на интервью.

Какая ситуация более критична для компании:

- пропустить сильного кандидата
- или пригласить на интервью слабого?

Ответ: пропустить сильного кандидата критичнее. Это потеря стратегической ценности, в то время как лишние интервью – лишь операционные издержки.

Вопросы

Компания внедрила автоматизированную систему отбора кандидатов на вакансию. Система оценивает резюме и решает, кого пригласить на интервью.

- Как вы бы настроили систему (в сторону Recall или Specificity), если вакансия редкая и очень важная?

Вопросы

Компания внедрила автоматизированную систему отбора кандидатов на вакансию. Система оценивает резюме и решает, кого пригласить на интервью.

- Как вы бы настроили систему (в сторону Recall или Specificity), если вакансия редкая и очень важная?

Ответ: Нужно найти лучшего кандидата любой ценой. Будем стараться увеличить Recall, даже если Specificity упадет. Для топового инженера или руководителя проекта важно, чтобы каждый потенциальный сильный кандидат был рассмотрен, даже если HR придется провести больше интервью.

Вопросы

Компания внедрила автоматизированную систему отбора кандидатов на вакансию. Система оценивает резюме и решает, кого пригласить на интервью.

- Как вы бы настроили систему (в сторону Recall или Specificity), если поток кандидатов очень большой и ресурсы HR ограничены?

Вопросы

Компания внедрила автоматизированную систему отбора кандидатов на вакансию. Система оценивает резюме и решает, кого пригласить на интервью.

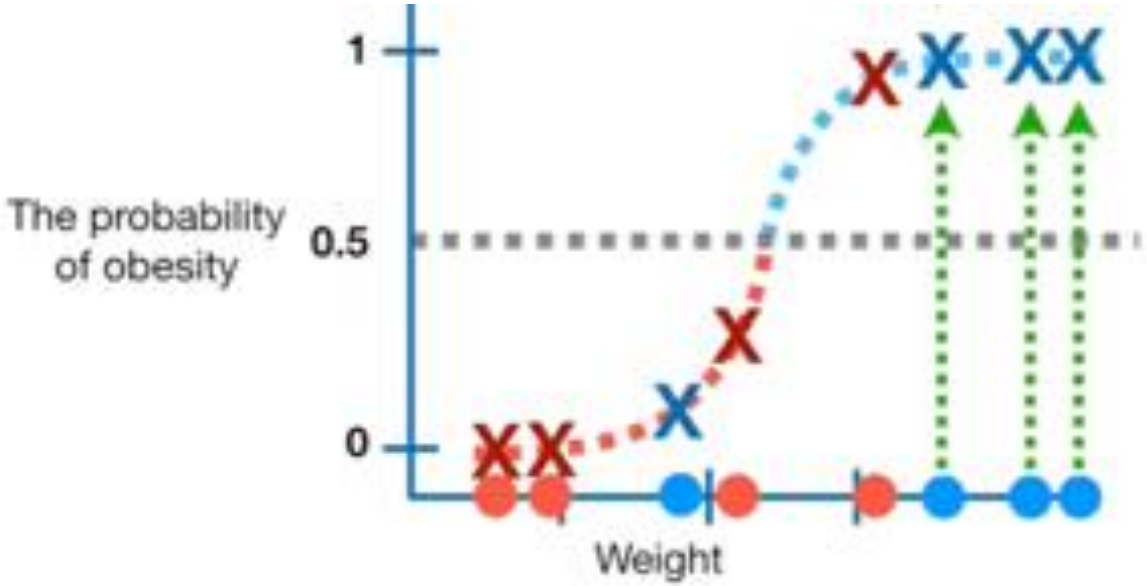
- Как вы бы настроили систему (в сторону Recall или Specificity), если поток кандидатов очень большой и ресурсы HR ограничены?

Ответ: Важно не тратить ресурсы HR на слабых кандидатов. Будем стараться повысить Specificity, чтобы система фильтровала слабых кандидатов. При массовом найме на позиции с высокой текучкой (например, call-центр) ценность каждого индивидуального кандидата ниже, а экономия времени HR важнее.

Порог классификации

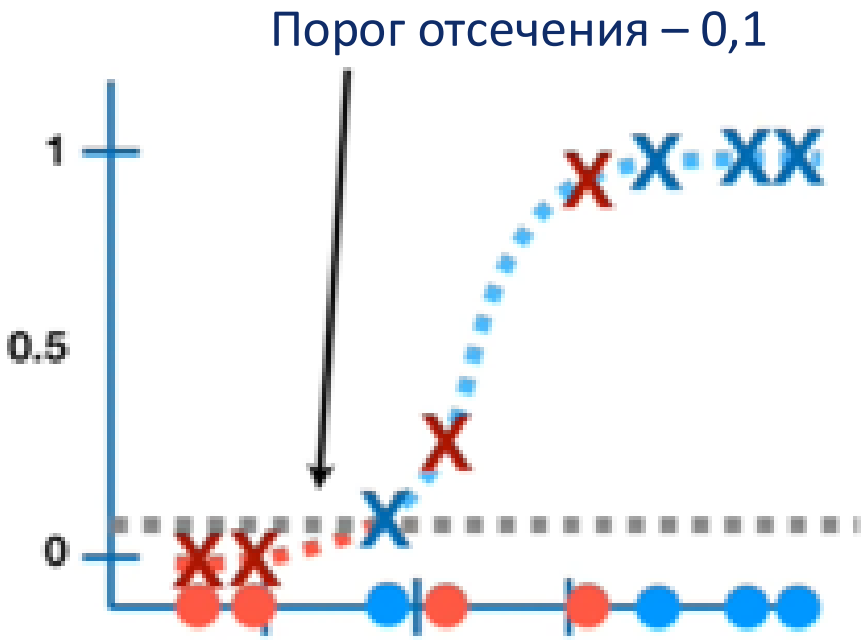
Порог классификации – это значение вероятности, выше которого модель относит объект к положительному классу, а ниже – к отрицательному. По умолчанию часто используют порог 0.5, однако на практике его настраивают в зависимости от задачи и приоритетов бизнеса. Снижение порога увеличивает полноту (Recall), позволяя находить больше положительных случаев, но снижает точность (Precision) за счёт роста ложных срабатываний. Повышение порога, наоборот, делает предсказания более строгими.

Значения в матрице ошибок зависят от порога отсечения



		Actual: Is Obese	Actual: Is Not Obese
Predicted	Is Obese	3	1
Predicted	Is Not Obese	1	3

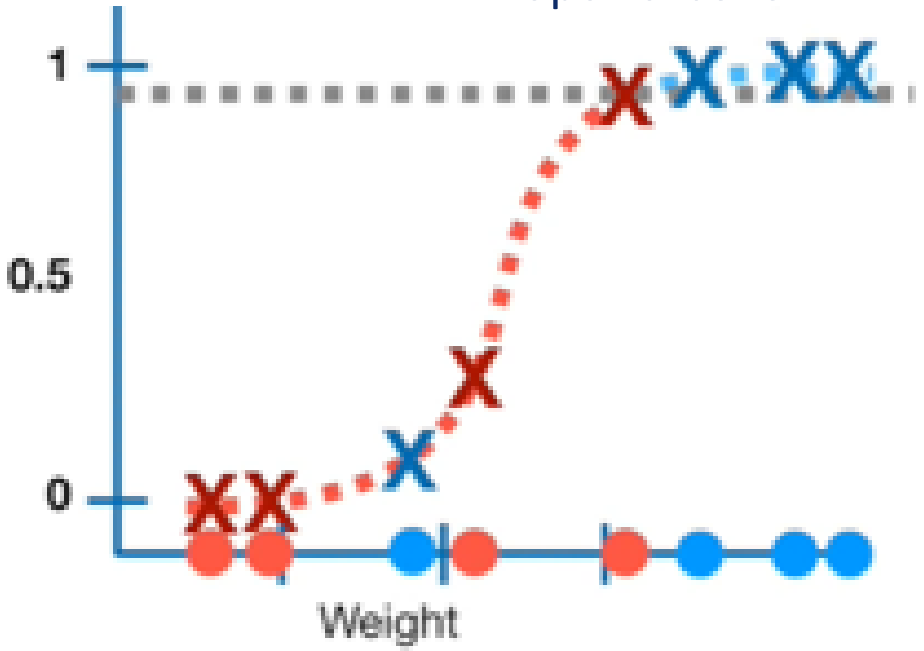
Значения в матрице ошибок зависят от порога отсечения



		Actual: Infected	Actual: Not Infected
Predicted	Infected	4	2
Predicted	Not Infected	0	2

Значения в матрице ошибок зависят от порога отсечения

Порог отсечения – 0,9



		Actual: Is Obese	Actual: Is Not Obese
Predicted	Is Obese	3	0
Predicted	Is Not Obese	1	4

Псевдо R-квадрат

Псевдо R^2 (например, R^2 Кокса и Снелла или Найджелкерка) показывает, насколько модель улучшает прогноз по сравнению с моделью без предикторов. Прямое сравнение с классическим R^2 из линейной регрессии не корректно, потому что у логистической модели нет обычной суммы квадратов ошибок.

R^2 Найджелкерка (Nagelkerke) корректирует R^2 Кокса–Снелла, чтобы верхняя граница была 1, что делает его более интуитивно понятным, похожим на классический R^2.

Если значение близко к 1, это не гарантирует такую же сильную интерпретацию, как в линейной регрессии. Это скорее показатель качества подгонки модели.

$$R^2_{\text{Cox–Snell}} = 1 - \left(\frac{L_0}{L_M}\right)^{\frac{2}{n}}$$

$$R^2_{\text{Nagelkerke}} = \frac{R^2_{\text{Cox–Snell}}}{1 - L_0^{2/n}}$$

L_0 и L_M - это значения функции правдоподобия (log-likelihood).

ROC-кривая

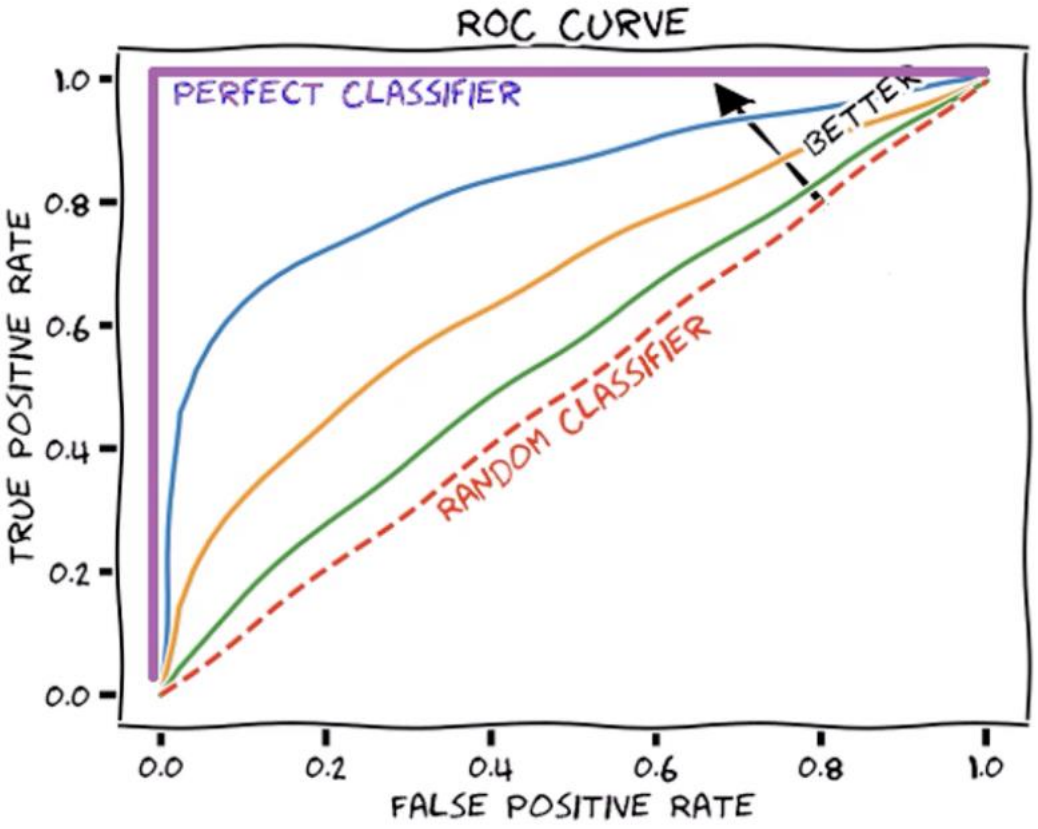
ROC-кривая (Receiver Operating Characteristic, рабочая характеристика приёмника) – графический инструмент для оценки качества бинарной классификации. Название произошло из области обработки сигналов.

Поскольку классификация бинарная, объекты делятся на два класса: положительные исходы и отрицательные исходы. ROC-кривая показывает зависимость доли верно классифицированных положительных примеров (True Positive Rate) от доли неверно классифицированных отрицательных примеров (False Positive Rate) при различных порогах классификации.

Применение ROC-кривой позволяет:

- Сравнивать модели и выбирать модель с наилучшей прогностической силой.
- Анализировать чувствительность и специфичность модели.
- Подбирать оптимальный порог отсечения для классификатора.

ROC-кривая

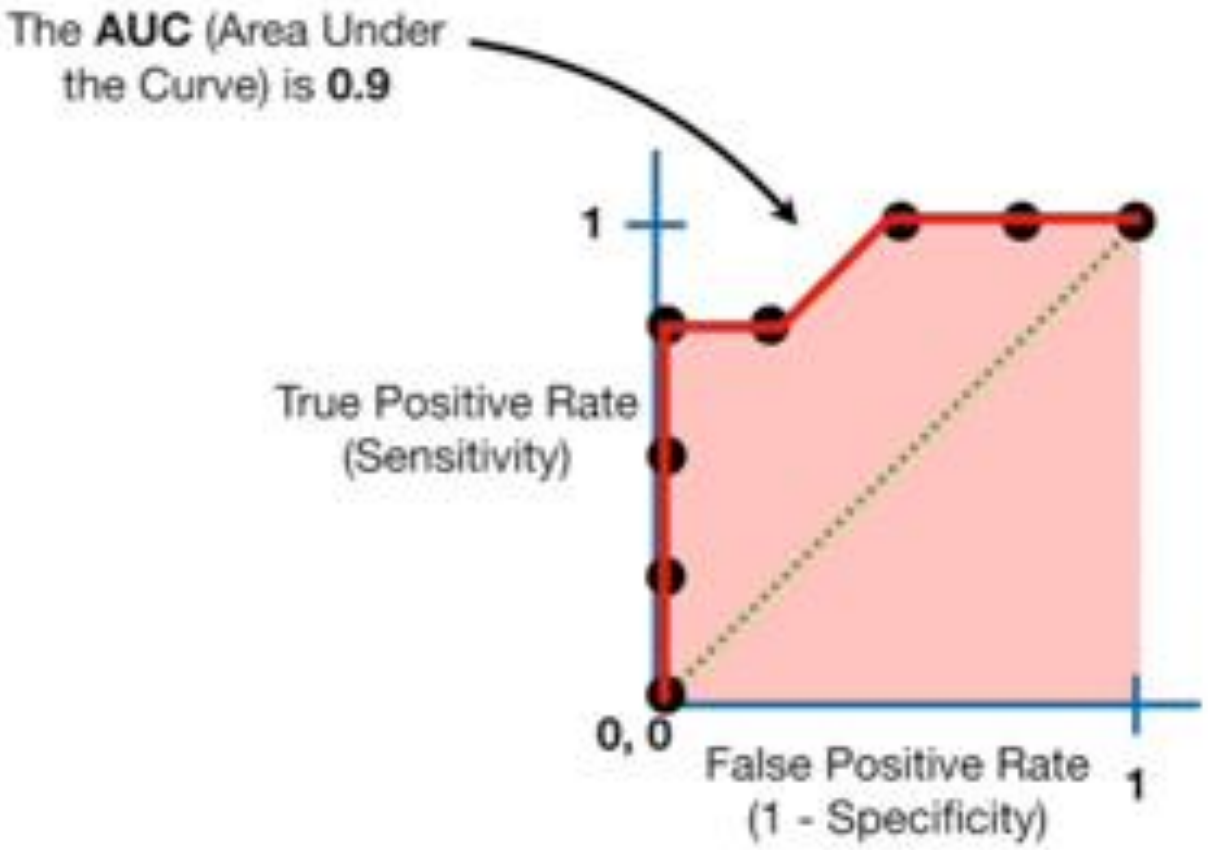


$$\text{True Positive Rate} = \text{Sensitivity} = \frac{\text{True Positives}}{\text{True Positives} + \text{False Negatives}}$$

$$\text{False Positive Rate} = (1 - \text{Specificity}) = \frac{\text{False Positives}}{\text{False Positives} + \text{True Negatives}}$$

http://www.navan.name/roc/

Площадь под кривой (AUC)

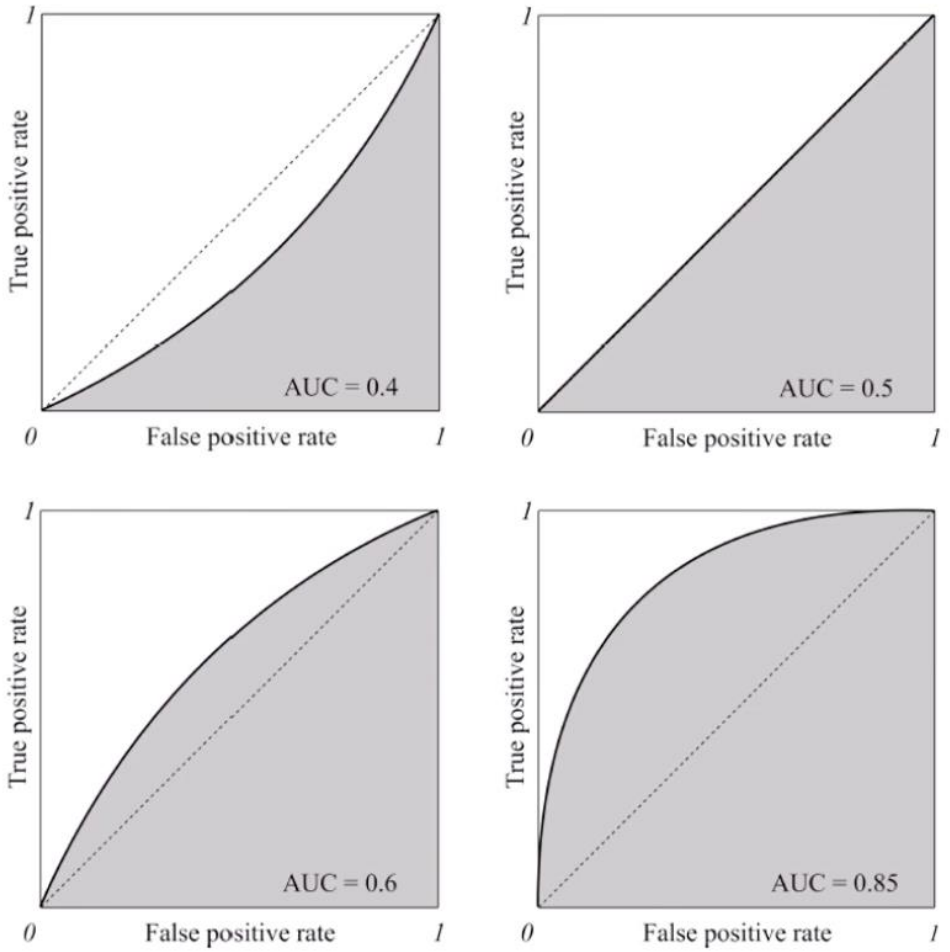


Площадь под кривой (AUC)

Одним из способов сравнения ROC-кривых является оценка площади под кривой (AUC). Теоретически значение AUC может изменяться от 0 до 1, однако на практике кривые моделей чаще всего располагаются выше диагонали случайного угадывания. Поэтому обычно рассматривают диапазон от 0,5 (бесполезный классификатор) до 1,0 (идеальная модель). Показатель AUC особенно полезен для сравнительного анализа нескольких моделей.

Интервал AUC	0,9-1,0	0,8-0,9	0,7-0,8	0,6-0,7	0,5-0,6
Качество модели	Отличное	Очень хорошее	Хорошее	Среднее	Неудовлетворительное

Площадь под кривой (AUC)



Неполнота информации

Для оценки коэффициентов с помощью метода максимального правдоподобия необходимо иметь наблюдения для всех комбинаций значений предикторов. Если какой-то набор комбинаций не представлен в данных, модель «не видела» этого случая и не может корректно оценить вероятность для этой комбинации. Таблицы сопряжённости (contingency tables) помогают это проверить. Чем больше данных для каждой комбинации, тем устойчивее оценка коэффициентов.

Решения:

- Собирать больше данных, чтобы покрыть все комбинации.
- Объединять категории предикторов, чтобы уменьшить количество комбинаций.
- Осуществлять биннинг числовых предикторов.
- Использовать регуляризацию, чтобы смягчить влияние редких комбинаций.

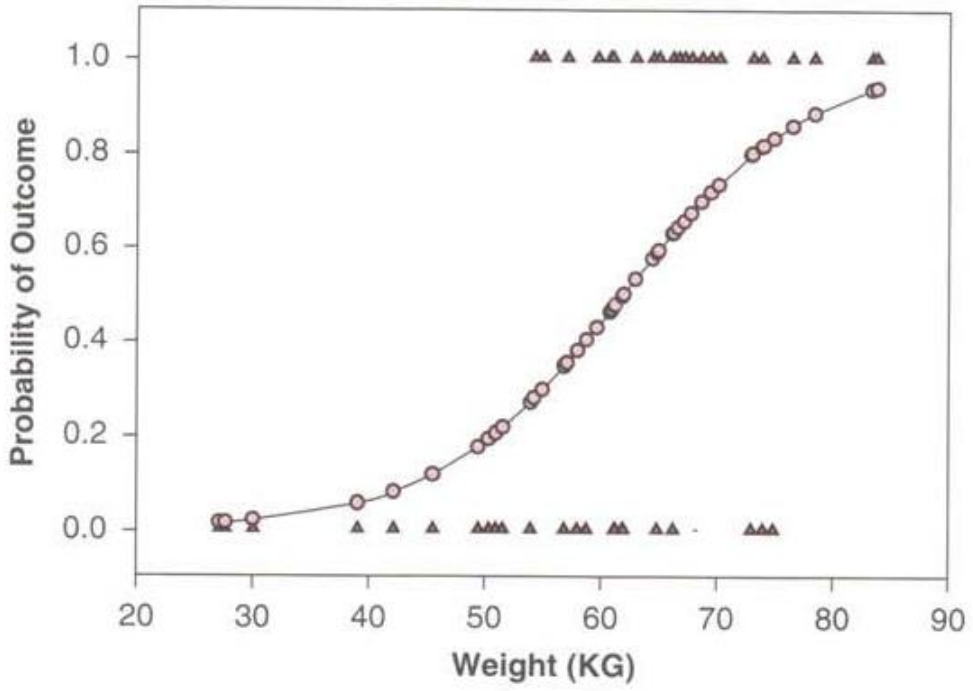
Неполнота информации

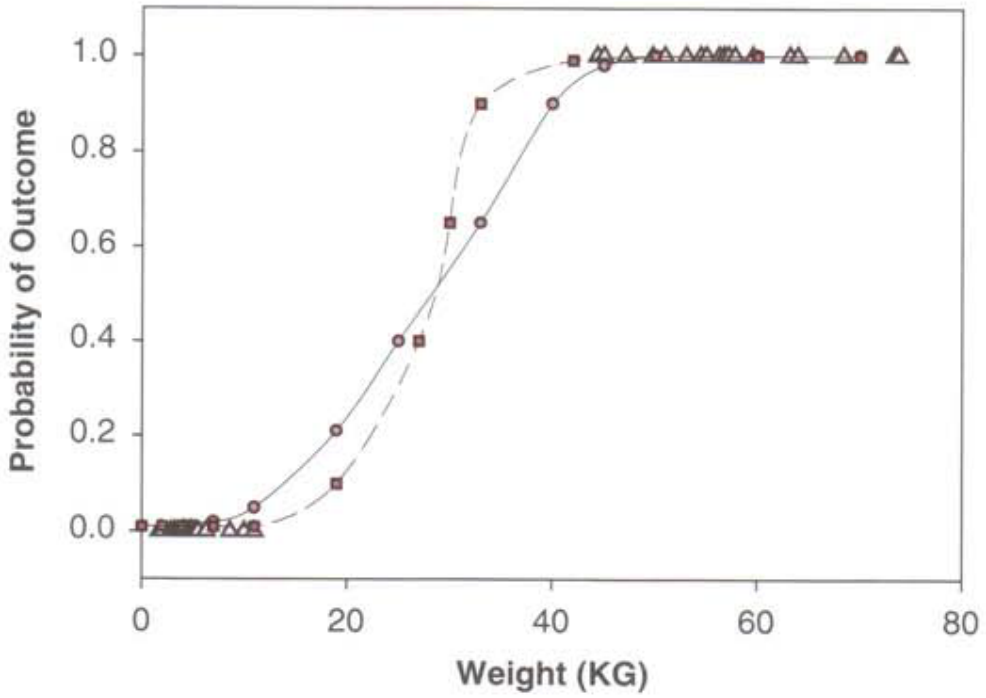
Сотрудник посещает тренинги?	Сотрудник вовлечён в проекты?	Сотрудник будет повышен?
Да	Нет	Да
Да	Да	Да
Нет	Нет	Нет
Нет	Да	????

Полное разделение (Complete separation)

Complete separation возникает, когда комбинация предикторов идеально разделяет два класса исхода. То есть для всех наблюдений одного класса предикторы принимают такие значения, что модель может безошибочно предсказывать их как 1, а для другого класса – как 0. На практике это приводит к тому, что стандартный метод максимального правдоподобия не может найти конечные значения коэффициентов: при попытке подогнать модель коэффициенты уходят в бесконечность, а доверительные интервалы становятся бессмысленными. Проблема часто возникает при небольших выборках или когда один из признаков полностью разделяет классы.

Полное разделение (Complete separation)





Интерпретация коэффициентов: отношение шансов

Отношение шансов (Odds Ratio) показывает во сколько раз изменится отношение шансов положительного исхода при увеличении значения предиктора на единицу. Рассчитывается как exp(B), где B – это коэффициент регрессии.

Если OR > 1, по при увеличении значения предиктора шансы положительного исхода, возрастают. Если OR < 1, то наоборот.

Если $B_1 = 0.7$,то:

$$\text{OR}_1 = e^{0.7} \approx 2.01$$

Это значит, что при увеличении X_1 на единицу шансы положительного исхода увеличиваются примерно в 2 раза.

Интерпретация коэффициентов: отношение шансов

Если предиктор - бинарный признак (пол).

Coef (b)	OR=exp(b)	Вывод
> 0	> 1	У мужчин, по сравнению с женщинами (референтная группа), больше шансов достичь положительного результата (получить кредит, быть принятым на должность, завершить обучение). Exp(b) = 1,6 -> шансы у мужчин на 60% больше
= 0	= 1	Между мужчинами и женщинами нет разницы в шансах на успех (положительный исход события).
< 0	от 0 до 1	У мужчин, по сравнению с женщинами (референтная группа), меньше шансов достичь положительного результата. Exp(b) = 0,6 -> шансы у мужчин на 40% меньше

Интерпретация коэффициентов: отношение шансов

Если предиктор - числовой признак (возраст в годах).

Coef (b)	OR=exp(b)	Вывод
> 0	> 1	Увеличение возраста увеличивает шансы положительного исхода события (получить кредит, быть принятым на должность, завершить обучение). Exp(b) = 2,5 -> увеличение возраста на год увеличивает шансы положительного исхода в 2,5 раза.
= 0	= 1	Возраст не влияет на исход события.
< 0	От 0 до 1	Увеличение возраста снижает шансы положительного исхода события. Exp(b) = 0,15 -> увеличение возраста на год снижает шансы положительного исхода на 85%.

Интерпретация коэффициентов: предельные эффекты

Предельные эффекты (Margins) показывают на сколько процентных пунктов меняется вероятность события при изменении значения предиктора на единицу.
Пример: было 20%, стало 30% → margin = +10 процентных пунктов

Не путайте:

- процентные пункты (п.п.) → разница вероятностей
- проценты (%) → относительное изменение

$$\text{Margin} = \frac{\partial p}{\partial x}$$

$x = 0$

$$p_0 = \frac{1}{1 + e^{-(-2)}} = \frac{1}{1 + e^2} \approx 0.119$$

$x = 1$

$$p_1 = \frac{1}{1 + e^{-(-2+1)}} = \frac{1}{1 + e^1} \approx 0.269$$

$$ME = p_1 - p_0 = 0.269 - 0.119 = 0.150$$

Что выбрать для интерпретации?

Рекомендуется использовать **отношение шансов** (odds ratio), если:

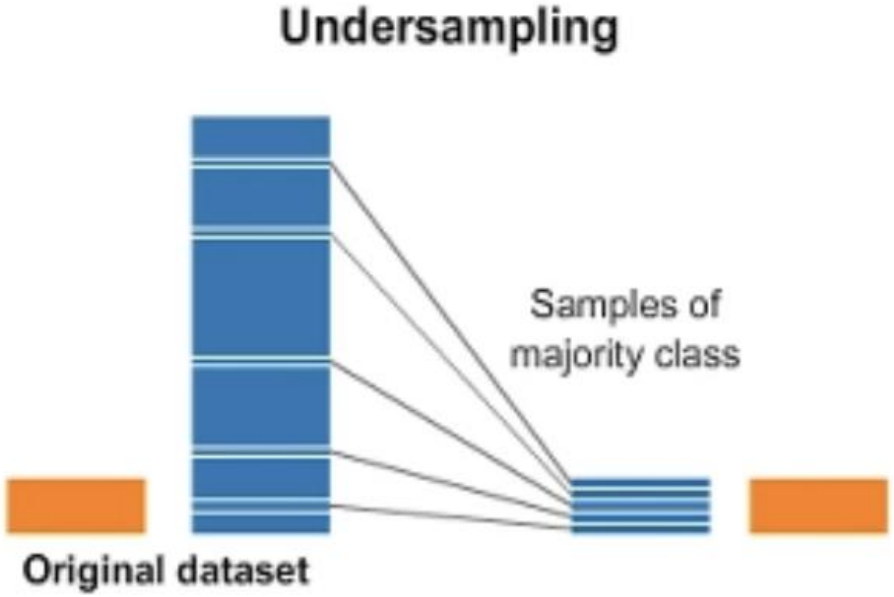
- Нужна интерпретация «во сколько раз».
- Результаты сравниваются с другими исследованиями (в научных статьях часто публикуют именно OR).
- Работа ведется в предметной области, для которой OR – стандарт.

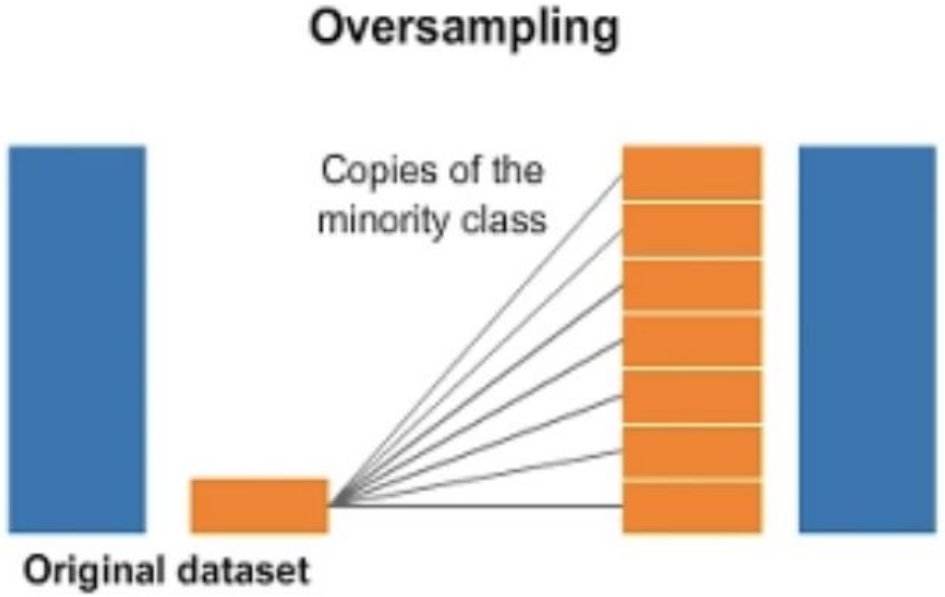
Рекомендуется использовать **предельные эффекты** (margins), если:

- Нужно понятно объяснить результат для бизнеса, например, «вероятность выросла на 10 процентных пунктов».
- Интересует именно вероятность, а не шансы.
- Нужно сравнить влияние переменных с разными шкалами.

Проблема несбалансированных классов

Если не учитывать дисбаланс, модель будет зашумлена и может игнорировать редкие классы, что приведет к плохой производительности на них. Решать проблему можно на уровне данных, алгоритма или оценки модели. Если отношение самого частого к самому редкому классу > 5, дисбаланс серьёзный.





Проблема несбалансированных классов

1. Методы работы на уровне данных (Data-level)

a) **Oversampling** (увеличение редких классов): либо дублируем примеры редкого класса, либо генерируем новые синтетические образцы редкого класса, интерполируя между существующими. При этом можно фокусироваться на сложных для классификации примерах.
Минусы: может приводить к переобучению на синтетические или дублированные данные.

b) **Undersampling** (уменьшение доминирующих классов)*:* удаляем примеры из большого класса либо случайно, либо сохраняя разнообразие.
Минусы: теряем часть информации, может ухудшить общую точность.

c) **Комбинированные методы**: сначала увеличиваем редкие классы, затем удаляем шумные примеры.

Проблема несбалансированных классов

2. Методы на уровне алгоритма (Algorithm-level)

a) **Взвешивание классов**: некоторые модели позволяют задавать вес классов, чтобы ошибки на редком классе учитывались сильнее.

b) **Алгоритмы, устойчивые к дисбалансу**: например, Decision Trees, Random Forest, XGBoost, LightGBM умеют работать с дисбалансом.

Проблема несбалансированных классов

3. Методы на уровне метрик и оценки

a) Не использовать Accuracy, поскольку может быть обманчива при дисбалансе.

b) Использовать метрики для несбалансированных данных
- Precision / Recall по каждому классу
- F1-score (macro / weighted)
- ROC-AUC (по классам)
- Confusion matrix для понимания ошибок модели

При кросс-валидации лучше использовать stratified KFold, чтобы сохранить пропорции классов в каждом фолде.

Спасибо за внимание!